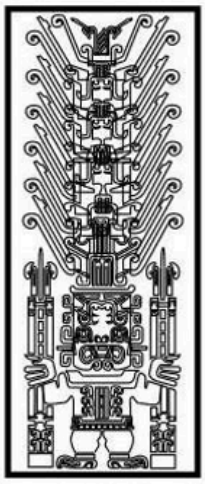
“Año de la Esperanza y el Fortalecimiento de la Democracia”



Universidad Nacional
Federico Villarreal

FACULTAD DE INGENIERÍA ELECTRÓNICA E INFORMÁTICA - FIEI
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA

ESTUDIANTES:

- Borromeo Quispe Allimson
- Huere Marchan Manfred Hober
- Lozano Villalobos Alex
- Pacheco Anton Fátima
- Pauca Muñoz Fabrizzio

CURSO: Gestión y Análisis de Datos e Información

PROFESOR: Ivan Crispin Sanchez

FECHA DE ENTREGA: lunes 13 de octubre de 2026

2026

Sistema Inteligente de Gestión, Predicción y Fidelización de Pacientes para un Centro Dental

Informe final — Introducción y Capítulos I y II · Gestión y Análisis de Datos e Información · FIEI-UNFV 2026 ··

Introducción

Presentación del proyecto

El proyecto "Sistema Inteligente de Gestión, Predicción y Fidelización de Pacientes para un Centro Dental" integra gestión de datos, inteligencia de negocios (BI) y aprendizaje automático en una sola solución. Parte de una base transaccional (OLTP) en SQL Server con pacientes, citas, tratamientos, pagos y médicos. Mediante un proceso ETL, esa información alimenta un DataMart dimensional, sobre el cual se construyen indicadores, análisis OLAP, un dashboard en Power BI y un modelo que estima el riesgo de abandono de cada paciente.

El objetivo general es apoyar las decisiones del centro dental con información histórica integrada y con predicciones que permitan actuar antes de que el paciente abandone su tratamiento.

Problema identificado

Muchos tratamientos odontológicos (ortodoncia, endodoncia, rehabilitación) requieren varias citas a lo largo de semanas o meses. Cuando el paciente deja de asistir, el tratamiento queda incompleto: el paciente no logra el resultado clínico previsto y el centro deja de percibir los ingresos pendientes de ese tratamiento.

En el escenario analizado, el centro detecta estos casos tarde, cuando el paciente ya lleva semanas sin venir. La información de citas, asistencia, tiempos de espera y pagos vive en registros operativos que no se analizan en conjunto, y no existe un criterio objetivo para decidir a qué paciente contactar primero. El problema de decisión es: **¿qué pacientes en tratamiento tienen mayor riesgo de abandonarlo y qué acción de fidelización conviene aplicar a cada uno?**

Importancia de la solución

- **Clínica:** favorece la continuidad de los tratamientos y, con ella, el resultado esperado para el paciente.
- **Económica:** permite priorizar las llamadas y campañas según el riesgo de abandono y el monto pendiente de cada tratamiento, y estimar el retorno de esas acciones con un simulador What-If.
- **De gestión:** reemplaza reportes aislados por indicadores consolidados con trazabilidad desde la base transaccional hasta el dashboard.
- **Académica:** demuestra la integración de DataMart, ETL, OLAP, KPI, BI y Machine Learning que exige el proyecto final del curso.

Alcance general

El proyecto incluye: (1) una base transaccional en SQL Server con registros históricos simulados del centro; (2) un DataMart en esquema estrella; (3) el proceso ETL; (4) indicadores, consultas OLAP y KPI; (5) un módulo de Machine Learning en Python que compara Regresión Logística y Random Forest para clasificar el riesgo de abandono en Alto, Medio y Bajo; y (6) un dashboard en Power BI de tres páginas (ejecutiva, predictiva y simulador What-If).

Queda fuera del alcance la historia clínica detallada, la facturación electrónica, el envío real de mensajes a pacientes y cualquier diagnóstico odontológico. Los datos son simulados y no corresponden a pacientes reales.

Capítulo I: Generalidades

1.1 Descripción dc la organización

El caso de estudio es **Clínica Dental Sonrisa Integral**, un centro odontológico privado de atención ambulatoria ubicado en Lima, Perú. Se trata de un caso simulado: el nombre y los datos descriptivos son ficticios, y se construyeron para representar la operación típica de un centro dental de tamaño mediano.

El centro ofrece odontología general, ortodoncia, endodoncia, rehabilitación oral y odontopediatría, y atiende con cita previa a pacientes particulares. Parte de sus ingresos proviene de tratamientos de varias sesiones que el paciente paga en cuotas, por lo que la asistencia continua del paciente influye directamente en lo que el centro llega a cobrar.

Sus procesos principales son el agendamiento de citas, la atención clínica, el cobro de las cuotas y el seguimiento del paciente.

1.2 Historia, misión, visión y valores

Historia. El centro fue fundado por un grupo de cirujanos dentistas con dos consultorios y una sola especialidad. Con los años incorporó ortodoncia, endodoncia, rehabilitación oral y odontopediatría, y hoy opera con seis consultorios. Al crecer el número de pacientes y de tratamientos de larga duración, el control de citas y pagos en registros separados dejó de ser suficiente para gestionar el negocio.

Misión. Brindar atención odontológica integral, segura y cercana, acompañando a cada paciente hasta completar su tratamiento.

Visión. Ser un centro dental de referencia en Lima por la continuidad y la calidad de sus tratamientos, apoyándose en información confiable para decidir.

Valores.

- Empatía con el paciente
- Responsabilidad clínica
- Transparencia en costos y plazos

- Confidencialidad de los datos del paciente
- Mejora continua

1.3 Organización y organigrama

La Dirección General coordina dos áreas: la Dirección Clínica, que reúne a los odontólogos y especialistas, y Atención al Paciente y Administración, donde se aplica el proyecto.

El proyecto se aplica en Atención al Paciente y Administración

Resaltada: el área donde se aplica el proyecto



organigrama · 2 áreas, 6 unidades

El organigrama muestra solo las unidades que participan en el proceso de citas y tratamientos.

1.4 Área involucrada

El proyecto interviene en el área de **Atención al Paciente y Administración**, que concentra el agendamiento de citas, la recepción, el cobro de cuotas y el seguimiento posterior a la atención. Los usuarios de la solución son la Dirección General y la Jefatura de Atención al Paciente, que deciden a qué pacientes contactar y qué campañas de fidelización realizar.

Los datos que esta área genera son la materia prima del DataMart y del modelo predictivo:

Dato	Dónde se registra	Uso en el proyecto
Citas y asistencia	Agenda de recepción	Asistencias, ausencias y días desde la última cita
Tiempo de espera	Recepción (hora de llegada y hora de ingreso al consultorio)	Minutos de espera por atención
Pagos	Caja	Monto cobrado y porcentaje del tratamiento pagado
Estado del tratamiento	Odontólogo tratante	Completado, Abandonado o En curso (variable objetivo del modelo)

1.5 Descripción del proceso

El proceso analizado es la **gestión de citas y el seguimiento de tratamientos**. Va desde que el paciente acepta un plan de tratamiento hasta que lo completa o deja de asistir:

1. **Registro y plan de tratamiento.** El odontólogo define el tratamiento, su costo total y el número estimado de citas, y recepción registra al paciente.
2. **Agendamiento.** Recepción programa las citas en la agenda del consultorio.
3. **Recepción y espera.** El paciente llega, registra su ingreso y espera hasta ser llamado.
4. **Atención clínica.** El odontólogo realiza el procedimiento y anota la evolución.
5. **Cobro.** El paciente paga en caja la cuota que corresponde a la sesión.
6. **Siguiente cita.** Se programa la próxima sesión, hasta completar el tratamiento.
7. **Seguimiento.** Si el paciente falta, recepción intenta contactarlo.

Cada paso deja datos que alimentan el análisis: asistencia o ausencia, minutos de espera y monto cobrado. De ese conjunto sale la tabla de hechos del DataMart, con una fila por atención.

1.6 Diagrama AS-IS

En el proceso actual, el centro agenda, atiende y cobra sin una vista consolidada del paciente. Cuando alguien falta, la reacción depende de qué recepción revise la agenda y decida a quién llamar.



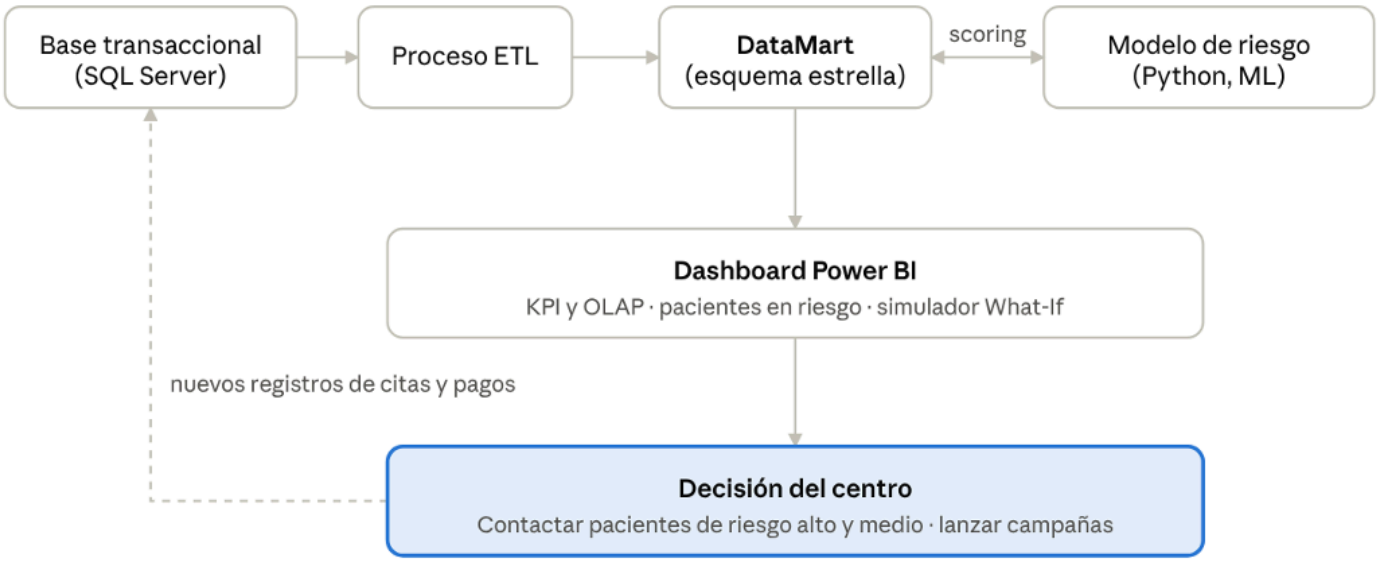
proceso AS-IS · 6 pasos, 1 decisión

La ruta de la inasistencia no tiene alertas ni prioridades, y por eso puede terminar en un tratamiento abandonado.

1.7 Propuesta TO-BE

La propuesta conecta la operación con el análisis: los registros de citas, esperas y pagos se integran en un DataMart, el modelo calcula el riesgo de abandono de cada paciente en tratamiento y el dashboard lo pone a disposición de quien decide.

Con el sistema, el centro actúa antes de que el paciente abandone



proceso TO-BE · 6 componentes

El modelo devuelve al DataMart la probabilidad y el nivel de riesgo (Alto, Medio, Bajo), que Power BI muestra junto con los KPI. Con esa lista, el centro puede contactar primero a los pacientes de mayor riesgo y estimar con el simulador What-If el efecto de recuperar una parte de ellos. Los nuevos registros de citas y pagos vuelven a alimentar el ciclo.

Capítulo II: Proyecto o tarea académica (marco teórico)

2.1 Inteligencia de negocios

La inteligencia de negocios (BI, por sus siglas en inglés) es el conjunto de estrategias, procesos y herramientas que transforman los datos de una organización en información útil para decidir (Curto Díaz & Conesa Caralt, 2010). Hernández Ramírez (2011) lo describe como un conjunto de conceptos y métodos para mejorar el proceso de decisión, normalmente construido sobre un almacén de datos. Sus componentes habituales son las fuentes de datos, el proceso ETL, el almacén de datos, el análisis multidimensional (OLAP) y los cuadros de mando que presentan los resultados al usuario de negocio.

Una solución de BI responde sobre todo a qué pasó y por qué pasó. Este proyecto la complementa con Machine Learning para estimar qué puede pasar, de modo que el análisis descriptivo y el predictivo conviven en un mismo dashboard.

2.2 Data Warehouse y DataMart

Un Data Warehouse (almacén de datos) es una colección de datos integrada e histórica, construida para apoyar el análisis y la toma de decisiones (Rivadera, 2010; Chaudhuri & Dayal, 1997). Un DataMart es un repositorio similar, pero limitado a un área o proceso del negocio, y esa delimitación es su principal diferencia con el almacén completo (Rivadera, 2010).

Los datos llegan al almacén mediante un proceso de extracción, transformación y carga (ETL) que los limpia y los homogeniza antes de cargarlos (Chaudhuri & Dayal, 1997). La tabla resume en qué se diferencia del sistema transaccional del que provienen.

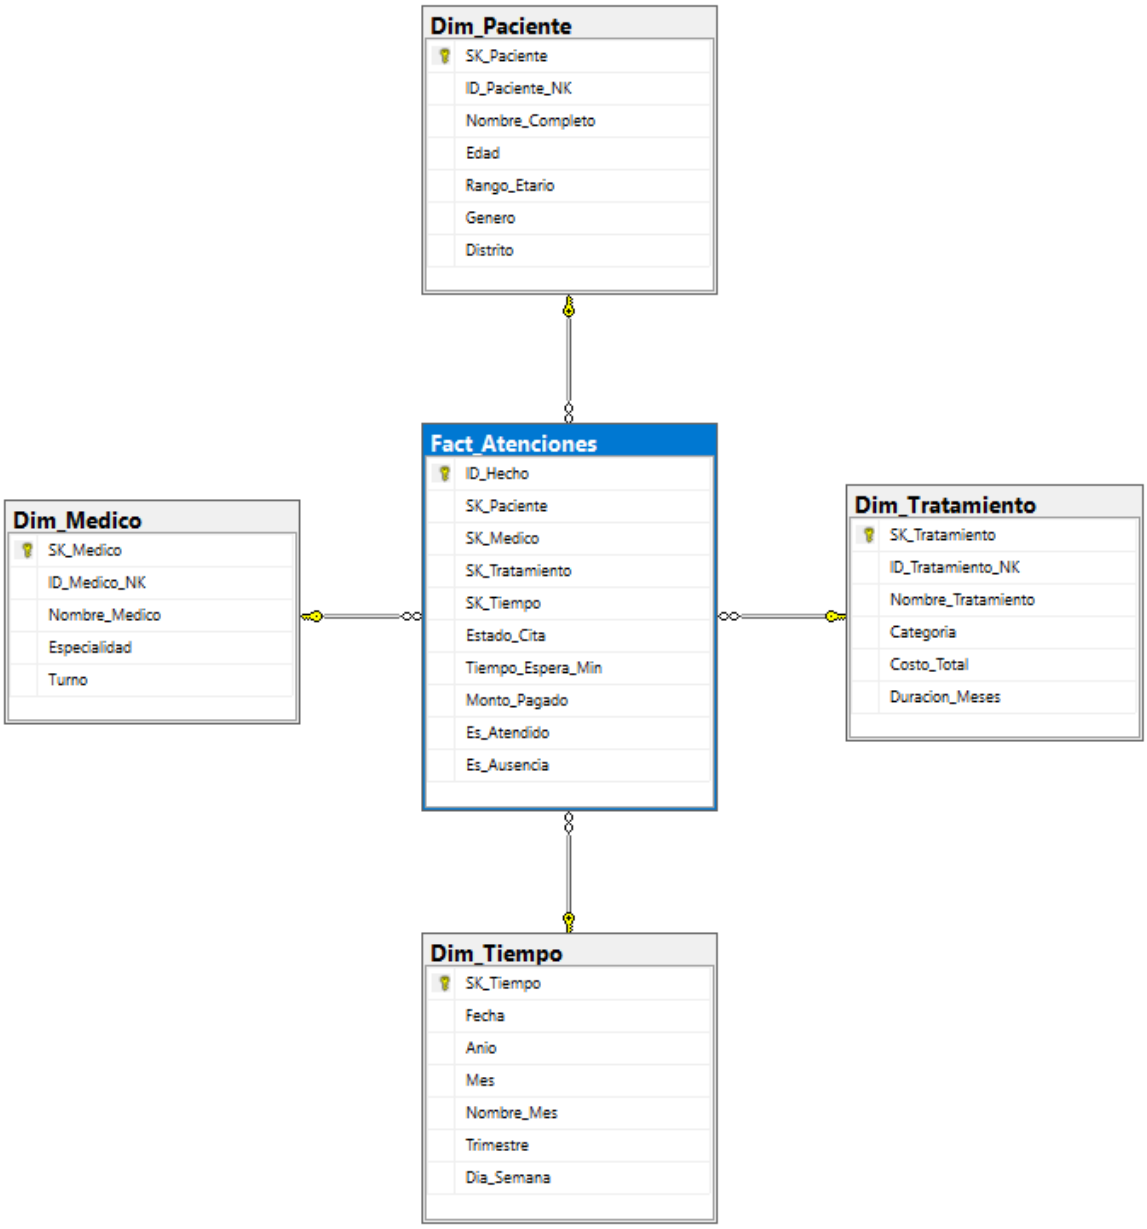
Característica	Base transaccional (OLTP)	DataMart (OLAP)
Propósito	Registrar la operación diaria	Analizar para decidir
Datos	Actuales, detallados	Históricos, integrados
Estructura	Normalizada, muchas tablas	Dimensional, hechos y dimensiones
En el proyecto	Pacientes, citas, tratamientos, pagos	Atenciones, indicadores y riesgo de abandono

2.3 Modelos dimensionales

El modelado dimensional organiza los datos en tablas de hechos, que guardan las medidas de un evento del negocio, y tablas de dimensiones, que aportan el contexto para analizarlas: quién, qué, cuándo (Kimball & Ross, 2013). Cuando una tabla de hechos queda al centro y las dimensiones a su alrededor, el modelo se conoce como esquema estrella. Si las dimensiones se normalizan en varias tablas, se obtiene un esquema copo de nieve.

Kimball y Ross (2013) proponen diseñar el modelo con cuatro decisiones, en este orden: el proceso de negocio, la granularidad, las dimensiones y los hechos. Para este proyecto, el proceso es la atención al

paciente y la granularidad es una fila por atención. El diseño preliminar se muestra a continuación y se detalla en el Capítulo III.



esquema estrella preliminar · 1 hecho, 4 dimensiones

Las medidas viven en la tabla de hechos; las dimensiones permiten filtrarlas y agruparlas.

2.4 Datos, información y conocimiento

La inteligencia de negocios se apoya en distinguir tres niveles: los datos, la información y el conocimiento, y en cómo cada uno contribuye a decidir mejor dentro de una organización (Prada Madrid, 2008). La tabla los define con un ejemplo del centro dental.

Nivel	Qué es	Ejemplo en el centro dental

Dato	Registro aislado, sin contexto	35
Información	Dato con contexto y significado	La espera promedio en ortodoncia fue de 35 minutos en marzo
Conocimiento	Comprensión que permite actuar	Los pacientes con esperas largas y pagos atrasados tienden a abandonar, por lo que conviene contactarlos primero

En el proyecto, el ETL convierte registros en datos limpios, el DataMart y los KPI los vuelven información, y el modelo predictivo junto con las recomendaciones busca producir conocimiento accionable. El patrón del ejemplo es una hipótesis que el modelo debe confirmar con los datos.

2.5 Dimensiones, medidas, jerarquías y granularidad

Estos cuatro conceptos son la base del diseño de un DataMart (Kimball & Ross, 2013). La tabla los define y los ilustra con el caso del centro dental.

Concepto	Definición	Ejemplo en el proyecto
Dimensión	Tabla con los atributos que describen el contexto de un hecho	Paciente, tratamiento, tiempo, médico
Medida	Valor numérico que se agrega o se compara	Monto cobrado, minutos de espera, asistencias, ausencias
Jerarquía	Niveles de una dimensión, de lo general a lo detallado	Día, mes, trimestre, año
Granularidad	Nivel de detalle de cada fila de la tabla de hechos	Una fila por atención del paciente

La granularidad se fija antes que las dimensiones y las medidas, porque de ella depende qué preguntas puede responder el modelo. Con una fila por atención, el DataMart permite agregar hacia arriba (por mes o por médico) sin perder el detalle de cada cita.

2.6 Cubos OLAP

Un cubo OLAP organiza las medidas según varias dimensiones a la vez, por ejemplo el monto cobrado por mes, por tratamiento y por médico (Chaudhuri & Dayal, 1997). Sobre ese cubo se aplican operaciones que permiten explorar los datos sin escribir una consulta distinta para cada pregunta.

Operación	Qué hace	Ejemplo en el centro dental

Roll-up	Agrega a un nivel superior de la jerarquía	Pasar de ingresos por mes a ingresos por trimestre
Drill-down	Baja a un nivel más detallado	Pasar de ingresos por tratamiento a ingresos por médico
Slice	Fija un valor de una dimensión	Ver solo los pacientes de ortodoncia
Dice	Selecciona un subcubo con varias dimensiones	Ortodoncia y endodoncia durante un trimestre
Pivot	Rota los ejes del análisis	Cambiar tratamientos por filas y meses por columnas

En este proyecto, el análisis OLAP se implementa con consultas agregadas en T-SQL sobre el DataMart y con las jerarquías y filtros del modelo de Power BI.

2.7 Indicadores de gestión y KPI

Un indicador clave de desempeño (KPI) es una medida ligada a los factores críticos de éxito de una organización, que permite saber si se cumplen sus objetivos y decidir a tiempo (Arosemena Doss, 2022). El cuadro de mando integral propone observarlos desde cuatro perspectivas: financiera, clientes, procesos internos y aprendizaje y crecimiento (Kaplan & Norton, 2000). Para consultorios dentales y de salud privados, Arosemena Doss (2022) sugiere indicadores como la tasa de inasistencia de pacientes y la tasa de aceptación de tratamientos.

La tabla muestra los KPI de referencia para este proyecto. Su definición final, con metas y fuentes, se presenta en el Capítulo III.

KPI	Fórmula	Perspectiva	Pregunta de negocio
Tasa de inasistencia	Citas con falta ÷ citas programadas	Procesos internos	¿Cuántas citas se pierden?
Tasa de abandono	Tratamientos abandonados ÷ (completados + abandonados)	Clientes	¿Cuántos pacientes no terminan su tratamiento?
Porcentaje cobrado	Monto cobrado ÷ costo total del tratamiento	Financiera	¿Cuánto del ingreso previsto se ha cobrado?
Tiempo medio de espera	Minutos de espera ÷ número de atenciones	Clientes	¿Cuánto espera el paciente?

2.8 Machine Learning e Inteligencia Artificial

La inteligencia artificial reúne técnicas que permiten a un sistema realizar tareas que normalmente requieren inteligencia humana. El aprendizaje automático (Machine Learning) es la parte de la IA en la que el modelo aprende patrones a partir de los datos,en lugar de seguir reglas escritas a mano (Hernández Orallo et al., 2004).

Aprendizaje supervisado y no supervisado. En el aprendizaje supervisado, cada registro de entrenamiento incluye la respuesta correcta (la variable objetivo) y el modelo aprende a predecirla. En el no supervisado no existe esa respuesta y el modelo busca estructura, como grupos de registros parecidos (Hernández Orallo et al., 2004).

El problema del proyecto. Es un problema de clasificación supervisada. La variable objetivo indica si el tratamiento terminó abandonado o completado, dato que se conoce en los tratamientos ya cerrados. El modelo se entrena con ese historial y luego se aplica a los pacientes que siguen en tratamiento, cuyo desenlace aún no se conoce.

Regresión logística. Estima la probabilidad de abandono a partir de las variables de entrada mediante la función logística:

$$P(\text{abandono} = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k)}}$$

Cada coeficiente indica cómo cambia esa probabilidad cuando varía una variable, lo que facilita la interpretación.

Random Forest. Es un conjunto de muchos árboles de decisión, entrenados con muestras aleatorias de los datos y de las variables, cuya clase final se decide por votación (Breiman, 2001). Suele captar relaciones no lineales y permite medir qué variables pesan más en la predicción.

Evaluación. Los dos modelos se comparan sobre un conjunto de prueba que no se usó para entrenar, con las métricas de la tabla, y no por apreciación visual.

Métrica	Qué mide	Por qué importa en este caso
Accuracy	Proporción de aciertos sobre el total	Da una vista general, pero engaña si pocos pacientes abandonan
Precisión	De los pacientes marcados en riesgo, cuántos abandonan de verdad	Evita gastar llamadas en pacientes que no lo necesitan
Recall	De los pacientes que abandonan, cuántos detecta el modelo	Evita perder pacientes sin haberlos contactado
F1-score	Media armónica de precision y recall	Resume ambos valores para comparar modelos
Matriz de confusión	Conteo de verdaderos y falsos positivos y negativos	Muestra qué tipo de error comete cada modelo

Variables de entrada. El modelo usa variables como los días desde la última cita, el tiempo de espera, el porcentaje del tratamiento pagado y las faltas acumuladas. Un estudio en una clínica odontológica docente de Lima, con 160 pacientes, encontró que el factor económico (30 %), la calidad del servicio (29,4 %) y el tiempo de espera (28,1 %) fueron los más vinculados al abandono (Meza Rincón, 2025). Eso respalda incluir el pago y la espera entre las variables. En un estudio sobre ortodoncia en escolares y adultos jóvenes de Santiago de Cuba, haber faltado a seis o más citas se asoció con el abandono del tratamiento (Rodríguez Rey et al., 2017), lo que respalda incluir las faltas acumuladas.

Fuga de información. Las variables se calculan solo con información anterior a una fecha de corte, y la etiqueta se define con lo que ocurre después. Así se evita la fuga de información (data leakage), que ocurre cuando una variable ya contiene la respuesta y produce métricas poco realistas. Además, la separación entre entrenamiento y prueba se hace por paciente, sin repetir a un mismo paciente en ambos conjuntos.

Antecedente. Valenzuela-Núñez et al. (2023) predijeron el ausentismo a citas médicas en un hospital regional de Chile con cinco algoritmos supervisados, entre ellos la regresión logística, y dividieron los datos de forma temporal entre entrenamiento y prueba. El mejor modelo fue una máquina de vectores de soporte, con un AUC de 85,1 %. Su enfoque respalda comparar varios algoritmos con métricas y separar los datos por fecha.

Segmentación. Los algoritmos de clustering agrupan pacientes con comportamientos parecidos sin necesitar etiquetas. Pueden servir como complemento para describir perfiles, pero no reemplazan al clasificador: sus grupos no tienen un nivel de riesgo asociado y no se evalúan con las métricas anteriores.

Capítulo III: Desarrollo de la solución

3.1 Análisis de requerimientos.

El desarrollo del Sistema Inteligente de Gestión, Predicción y Fidelización de Pacientes se fundamenta en requerimientos estructurados en cuatro dimensiones clave para garantizar la alineación entre las necesidades clínicas, operativas y tecnológicas.

Requerimientos de Negocio

- Identificar de manera proactiva a los pacientes en tratamiento odontológico que presentan un alto riesgo de abandono antes de su finalización clínica.
- Priorizar las gestiones del área de Atención al Paciente y Administración (llamadas, recordatorios, campañas) basándose en un criterio objetivo de riesgo y el monto financiero pendiente de cada tratamiento.
- Estimar el impacto y retorno financiero de las acciones de fidelización mediante un simulador de escenarios (What-If) que cuantifique los ingresos recuperables.
- Reemplazar la revisión manual de agendas operativas por una vista consolidada que permita una toma de decisiones informada por parte de la Dirección General y la Jefatura de Atención al Paciente.

Requerimientos de Información y Analítica

- Disponer de indicadores clave de desempeño (KPI) históricos y actuales, tales como la tasa de inasistencia, tasa de abandono, porcentaje cobrado y tiempo medio de espera.
- Habilitar el análisis multidimensional (OLAP) de las atenciones filtrado por dimensiones descriptivas: tiempo (año, trimestre, mes, día de la semana), paciente (demografía, barrio), médico (especialidad) y tratamiento (costo, duración).
- Mantener la trazabilidad total de la información, permitiendo navegar desde las métricas agregadas del dashboard hasta el nivel atómico de cada cita médica.

Requerimientos Predictivos (Machine Learning)

- Implementar un modelo de clasificación supervisada capaz de calcular la probabilidad probabilística de que un paciente abandone el tratamiento (Target_Abandono).
- Desplegar un algoritmo (Random Forest) que maneje relaciones no lineales, soporte distribuciones no normales y permita extraer cuantitativamente la importancia de las variables (Feature Importance).
- Categorizar los resultados predictivos en niveles de alerta accionables (Riesgo Alto, Medio, Bajo) para facilitar la lectura por parte del usuario final.
- Evaluar el rendimiento del modelo priorizando la métrica de Sensibilidad (Recall) para minimizar los falsos negativos, dado el alto costo de oportunidad de perder un paciente sin intentar retenerlo.

Requerimientos Técnicos y de Arquitectura

- Construir la solución centralizada sobre un motor de base de datos SQL Server, dividida lógicamente en un esquema de aterrizaje (stg), un sistema transaccional normalizado (oltp) y un modelo dimensional en esquema estrella (dw).
- Desarrollar un proceso ETL (Extracción, Transformación y Carga) automatizado mediante T-SQL que ingeste datos crudos desde archivos CSV, transforme tipos de datos, elimine duplicados mediante funciones de ventana y garantice la integridad referencial.
- Automatizar el intercambio de datos con el entorno de Inteligencia Artificial en Python, permitiendo consultar las vistas analíticas (ej. dw.vw_Dataset_ML) y exportar las clasificaciones directamente a la tabla Resultados_Prediccion_IA en el Data Mart.
- Desplegar la capa de visualización en Power BI combinando indicadores descriptivos (KPI) con la

salida del modelo predictivo en un entorno interactivo.

3.2 Preguntas de negocio.

3.3 Indicadores y perspectivas de análisis.

3.4 Modelo conceptual.

El modelo conceptual describe, sin entrar en detalles técnicos de implementación, cómo funciona el centro dental y qué elementos del negocio es necesario registrar. La operación gira en torno a un hecho central: el **paciente** solicita una **cita** para ser atendido por un **odontólogo**, quien le aplica un **tratamiento** del catálogo de procedimientos de la clínica.

El flujo general de la clínica es el siguiente: (1) el paciente se registra con sus datos demográficos y de salud relevantes; (2) se programa una cita, indicando la fecha de programación y la fecha en que será atendido; (3) opcionalmente se le envía un mensaje de texto (SMS) recordatorio; (4) el día de la cita el paciente asiste o no asiste (inasistencia o *no-show*); y (5) a la cita se le asocia el costo del tratamiento aplicado, que representa el ingreso que la clínica obtiene o deja de percibir.

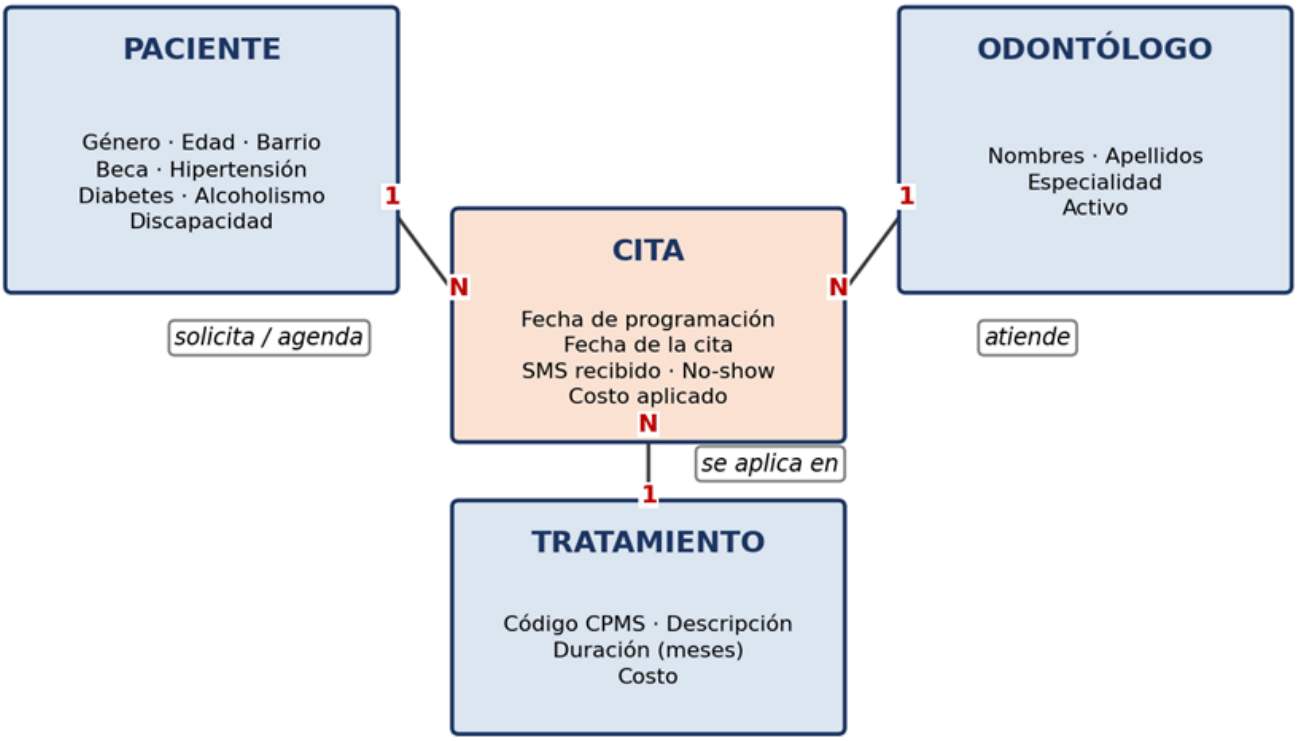


Figura 3.1. *Modelo conceptual del centro dental: entidades y relaciones principales.*

Tabla 3.1. *Entidades del modelo conceptual.*

Entidad	Descripción	Atributos principales
Paciente	Persona que solicita atención odontológica en la clínica.	Género, edad, barrio, beca, hipertensión, diabetes, alcoholismo y discapacidad.
Odontólogo	Profesional de la salud que atiende las citas.	Nombres, apellidos, especialidad y estado activo.

Tratamiento	Procedimiento odontológico del catálogo CPMS, con su costo y duración estimada.	Código CPMS, descripción, duración en meses y costo.
Cita	Evento que vincula a un paciente, un odontólogo y un tratamiento en una fecha determinada.	Fecha de programación, fecha de la cita, SMS recibido, inasistencia (*no-show*) y costo aplicado.

Las relaciones entre las entidades son las siguientes:

- Un paciente puede tener **muchas citas**; cada cita pertenece a un único paciente (1:N).
- Un odontólogo atiende **muchas citas**; cada cita es atendida por un único odontólogo (1:N).
- Un tratamiento se aplica en **muchas citas**; cada cita tiene asociado un único tratamiento (1:N).

De este modo, la entidad **Cita** es la entidad transaccional que conecta a las demás y sobre la cual se medirá posteriormente el comportamiento de los pacientes.

3.5 Análisis de la base OLTP.

La base transaccional (OLTP) soporta la operación diaria de la clínica. Se implementó en SQL Server dentro de la base de datos DentalCenterDB, en el esquema oltp, y está compuesta por cuatro tablas: Pacientes, Odontologos, Tratamientos y Citas. Antes de llegar a ellas, los datos crudos de los archivos CSV aterrizan en el esquema stg (*staging*), cuyas tablas Raw_NoShow y Raw_CPMS definen todas sus columnas como texto (NVARCHAR) y aceptan valores nulos, de modo que la carga masiva no falle por problemas de formato y la validación y conversión de tipos se realice posteriormente en el proceso ETL.

Las características de diseño más relevantes del esquema transaccional son:

- **Llaves primarias naturales y autoincrementales.** Pacientes e IdCita conservan el identificador del sistema origen (BIGINT e INT, respectivamente), mientras que Odontologos y Tratamientos usan IDENTITY(1,1).
- **Tipos de datos ajustados al dominio.** Los indicadores de salud y de beca se modelan como BIT; la discapacidad como TINYINT; los costos como DECIMAL(10,2); y la fecha de programación como DATETIME2(0) (precisión de segundos), diferenciándose de la fecha de la cita, que es de tipo DATE.
- **Integridad y valores por defecto.** Las columnas son NOT NULL y los indicadores tienen valor por defecto (DEFAULT 0; Activo con DEFAULT 1), lo que evita registros incompletos.
- **Normalización.** Cada entidad del negocio tiene su propia tabla y los datos del paciente, del odontólogo y del tratamiento no se repiten en cada cita, sino que se referencian mediante llaves foráneas.

Tabla 3.2. *Estructura de la tabla oltp.Pacientes.*

Columna	Tipo	Restricción	Descripción
IdPaciente	BIGINT	PK	Identificador del paciente (PatientId del origen).

Genero	CHAR(1)	NOT NULL	Género (M/F).
Edad	SMALLINT	NOT NULL	Edad en años.
Barrio	NVARCHAR(100)	NOT NULL	Barrio de residencia.
Beca	BIT	DEFAULT 0	Indica si cuenta con beca o programa social.
Hipertension	BIT	DEFAULT 0	Indicador de hipertensión.
Diabetes	BIT	DEFAULT 0	Indicador de diabetes.
Alcoholismo	BIT	DEFAULT 0	Indicador de alcoholismo.
Discapacidad	TINYINT	DEFAULT 0	Nivel de discapacidad (0 = ninguna).

Tabla 3.3. *Estructura de la tabla oltp.Odontologos.*

Columna	Tipo	Restricción	Descripción
IdOdontologo	INT	PK, IDENTITY	Identificador del odontólogo.
Nombres	NVARCHAR(100)	NOT NULL	Nombres del profesional.
Apellidos	NVARCHAR(100)	NOT NULL	Apellidos del profesional.
Especialidad	NVARCHAR(100)	NOT NULL	Especialidad (general, endodoncia, ortodoncia).
Activo	BIT	DEFAULT 1	Indica si el profesional está activo.

Tabla 3.4. *Estructura de la tabla oltp.Tratamientos.*

Columna	Tipo	Restricción	Descripción
IdTratamiento	INT	PK, IDENTITY	Identificador del tratamiento.
CodigoCPMS	VARCHAR(50)	NOT NULL	Código del procedimiento según el catálogo CPMS.
Descripcion	NVARCHAR(500)	NOT NULL	Descripción del procedimiento.
DuracionMeses	INT	DEFAULT 1	Duración estimada del tratamiento en meses (campo operativo).
Costo	DECIMAL(10,2)	NOT NULL	Tarifa del procedimiento.

Tabla 3.5. *Estructura de la tabla oltp.Citas.*

Columna	Tipo	Restricción	Descripción

IdCita	INT	PK	Identificador de la cita (AppointmentID del origen).
IdPaciente	BIGINT	FK	Paciente que solicita la cita.
IdOdontologo	INT	FK	Odontólogo que atiende la cita.
IdTratamiento	INT	NOT NULL	Tratamiento asociado a la cita.
FechaProgramacion	DATETIME2(0)	NOT NULL	Fecha y hora en que se registró la cita.
FechaCita	DATE	NOT NULL	Fecha en que debe realizarse la atención.
SMSRecibido	BIT	DEFAULT 0	Indica si el paciente recibió recordatorio por SMS.
NoShow	VARCHAR(3)	NOT NULL	Resultado de asistencia: Yes (no asistió) / No (asistió).
CostoAplicado	DECIMAL(10,2)	NOT NULL	Costo del tratamiento aplicado a la cita.

3.6 Relaciones identificadas.

En el esquema transaccional, la tabla oltp.Citas actúa como tabla hija de las otras tres entidades. Las relaciones se establecen a través de llaves foráneas, de forma que ninguna cita puede existir sin un paciente y un odontólogo válidos.

Tabla 3.6. *Relaciones del esquema OLTP.*

Tabla hija (N)	Tabla padre (1)	Tipo	Detalle
oltp.Citas.IdPaciente	oltp.Pacientes.IdPaciente	FK declarada	Un paciente tiene muchas citas; cada cita pertenece a un solo paciente.
oltp.Citas.IdOdontologo	oltp.Odontologos.IdOdontologo	FK declarada	Un odontólogo atiende muchas citas; cada cita es atendida por un solo odontólogo.

oltp.Citas.IdTratamiento	oltp.Tratamientos.IdTratamiento	Relación lógica	Un tratamiento se aplica en muchas citas; el ETL asigna únicamente identificadores existentes en el catálogo.

La integridad referencial se refuerza además en el proceso de carga: el procedimiento stg.usp_CargarOLTP solo inserta citas cuyo IdPaciente ya existe en oltp.Pacientes, y el orden de creación y eliminación de tablas en el script DDL (primero Citas, luego las tablas padre) respeta las dependencias entre ellas.

Observación. En el script actual la relación entre Citas y Tratamientos está implementada de forma lógica (el ETL calcula IdTratamiento dentro del rango de identificadores del catálogo), pero no se declara como restricción FOREIGN KEY. Para que el motor de base de datos la garantice, puede formalizarse con la siguiente sentencia:

```
ALTER TABLE oltp.Citas
  ADD CONSTRAINT FK_Citas_Tratamientos
  FOREIGN KEY (IdTratamiento) REFERENCES oltp.Tratamientos(IdTratamiento);
```

En el Data Mart se identifican relaciones análogas: la tabla de hechos dw.Fact_Atenciones referencia a cada dimensión mediante llaves foráneas sobre las llaves subrogadas (SK_Paciente, SK_Medico, SK_Tratamiento y SK_Tiempo), tal como se detalla en las secciones 3.9 a 3.12.

3.7 Nivel de granularidad.

La granularidad define qué representa exactamente cada registro de la tabla de hechos. En este proyecto se establece que **cada registro corresponde a una cita médica**, es decir, a una atención odontológica programada para un paciente, con un odontólogo y un tratamiento en una fecha determinada, independientemente de que el paciente haya asistido o no.

Esta definición se garantiza en el modelo mediante tres mecanismos: (a) IdCita es la llave primaria de oltp.Citas; (b) IdCita tiene una restricción UNIQUE en dw.Fact_Atenciones; y (c) el proceso ETL elimina duplicados por AppointmentID antes de cargar la cita (sección 3.13).

Tabla 3.7. *Granularidad por capa de datos.*

Capa / tabla	Un registro representa	Observación
stg.Raw_NoShow	Una fila del archivo CSV	Puede contener duplicados y valores inválidos.
oltp.Pacientes	Un paciente	Se conserva un único registro por IdPaciente.

oltp.Citas	Una cita	Un paciente puede tener varias citas.
dw.Fact_Atenciones	Una cita médica	Grano atómico del Data Mart; no se agrega información.

Definir el grano al nivel de cita permite analizar la información con el máximo detalle y agregarla después por cualquiera de las dimensiones: por mes o año, por barrio, por especialidad del odontólogo o por tratamiento. Con ello se responden preguntas como: ¿cuál es la tasa de inasistencia por barrio y mes?, ¿cuántos ingresos se pierden por especialidad? o ¿cuánto tiempo de espera precede a una ausencia?

3.8 Modelo conceptual ampliado.

El modelo conceptual ampliado extiende la base operativa con las capas necesarias para la analítica de negocio y la inteligencia artificial. Los datos fluyen desde los archivos CSV hasta el área de *staging*, se depuran y almacenan en el OLTP, se transforman al modelo dimensional del Data Mart y, desde allí, alimentan tanto los indicadores de gestión como el modelo predictivo de inasistencia. Los resultados de la predicción regresan al Data Mart y son consumidos por Power BI.

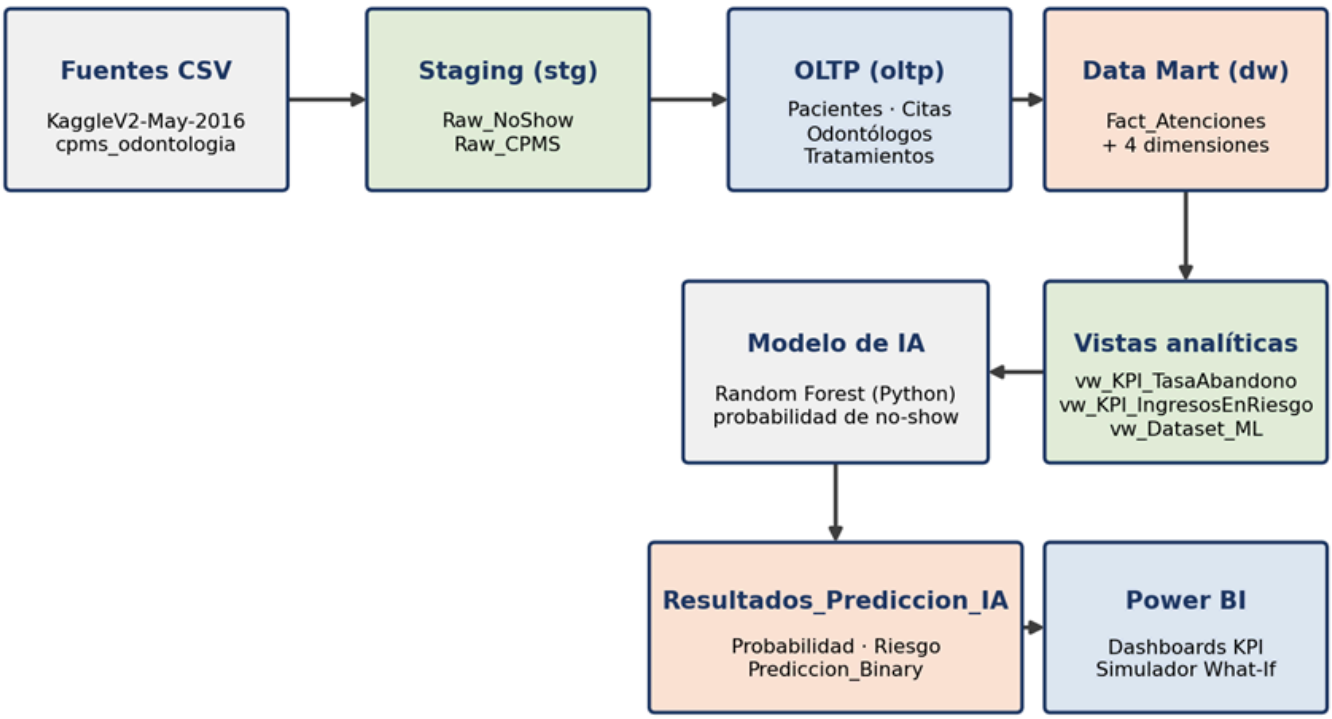


Figura 3.2. *Modelo conceptual ampliado: de la operación diaria a la analítica y la IA.*

Para esta preparación analítica, la base incorpora los siguientes componentes:

- **Data Mart dimensional (`dw`)**, con una tabla de hechos y cuatro dimensiones, optimizado para consultas analíticas. La dimensión de tiempo incluye el trimestre y el día de la semana, que permiten estudiar patrones estacionales de ausencia.

- **Variables calculadas en la tabla de hechos** (Estado_Cita, Es_Atendido y Es_Ausencia), que dejan la información lista para el análisis y para el aprendizaje automático.
- **Vistas analíticas**, que encapsulan los indicadores clave y el conjunto de datos de entrenamiento para el modelo predictivo.
- **Tabla de resultados de IA (`dw.Resultados_Prediccion_IA`)**, donde se almacena, por cada cita evaluada, la probabilidad de ausencia, la categoría de riesgo (por ejemplo, Alto, Medio o Bajo), la predicción binaria y la fecha de evaluación.

Tabla 3.8. *Vistas analíticas del Data Mart.*

Vista	Nivel de análisis	Medidas / campos
dw.vw_KPI_TasaAbandono	Año, mes y barrio	TotalCitas, CitasAbandonadas (suma de Es_Ausencia) y PorcentajeAbandono.
dw.vw_KPI_IngresosEnRiesgo	Año, mes y especialidad	IngresoTotalEstimado e IngresosEnRiesgoPerdidos (monto de las citas con ausencia).
dw.vw_Dataset_ML	Una fila por cita	ID_Hecho, Edad, Tiempo_Espera_Min, Duracion_Meses, Monto_Pagado y Target_Abandono (variable objetivo).

La vista dw.vw_Dataset_ML entrega al modelo predictivo las variables explicativas (edad del paciente, tiempo de espera en minutos, duración del tratamiento en meses y monto pagado) junto con la variable objetivo (Target_Abandono), que indica si la cita terminó en ausencia. Como esta vista identifica cada fila por ID_Hecho y la tabla de resultados por IdCita, ambos identificadores se relacionan a través de dw.Fact_Atenciones, que contiene los dos campos. Las variables de salud y de contacto (por ejemplo, SMS recibido o enfermedades crónicas) se conservan en el OLTP y pueden incorporarse al Data Mart como atributos adicionales en futuras iteraciones. Con las predicciones almacenadas, la clínica puede priorizar recordatorios y acciones de fidelización sobre los pacientes con mayor riesgo de ausencia y estimar el retorno económico de recuperarlos.

3.9 Modelo lógico del DataMart.

El Data Mart sigue el enfoque dimensional de Kimball bajo un **esquema estrella**: una tabla de hechos central (dw.Fact_Atenciones) rodeada por cuatro tablas de dimensiones (Dim_Paciente, Dim_Medico, Dim_Tratamiento y Dim_Tiempo). Todas las tablas analíticas residen en el esquema dw, separadas lógicamente de la capa de aterrizaje (stg) y de la base transaccional (oltp).

Las decisiones principales del diseño lógico se resumen a continuación:

- **Llaves subrogadas.** Cada dimensión tiene una llave primaria artificial de tipo INT IDENTITY(1,1) (SK_Paciente, SK_Medico, SK_Tratamiento) que aísla al Data Mart de los cambios en los identificadores del sistema origen y optimiza los *joins*. La tabla de hechos tiene su propia llave autoincremental, ID_Hecho.

- **Claves de negocio conservadas.** El identificador original (IdPaciente, IdOdontologo, IdTratamiento) se mantiene en la dimensión; en Dim_Paciente y Dim_Medico se protege con una restricción UNIQUE, evitando duplicados.
- **Clave inteligente de tiempo.** Dim_Tiempo usa como llave SK_Tiempo un entero con formato AAAAMMDD (por ejemplo, 20160429), legible y ordenable.
- **Integridad referencial.** La tabla de hechos declara llaves foráneas hacia las cuatro dimensiones, de modo que no pueden existir atenciones sin sus descriptores.
- **Dimensiones no versionadas.** Las dimensiones se cargan de forma incremental, insertando solo los miembros nuevos; cada miembro conserva los valores con que fue cargado por primera vez.

Tabla 3.9. *Llaves del modelo lógico del Data Mart.*

Tabla	Llave primaria	Llave de negocio	Llaves foráneas
dw.Dim_Paciente	SK_Paciente	IdPaciente (UNIQUE)	—
dw.Dim_Medico	SK_Medico	IdOdontologo (UNIQUE)	—
dw.Dim_Tratamiento	SK_Tratamiento	IdTratamiento	—
dw.Dim_Tiempo	SK_Tiempo	Fecha	—
dw.Fact_Atenciones	ID_Hecho	IdCita (UNIQUE)	SK_Paciente, SK_Medico, SK_Tratamiento, SK_Tiempo
dw.Resultados_Prediccion_IA	IdCita	—	Relación lógica con Fact_Atenciones.IdCita

3.10 Tablas de dimensiones.

Las dimensiones contienen los atributos descriptivos que permiten filtrar, agrupar y etiquetar las medidas de la tabla de hechos. A continuación se describe cada una.

3.10.1 Dim_Tiempo

Describe la fecha de la cita y permite analizar la información por año, trimestre, mes y día de la semana. Se alimenta con las fechas distintas de oltp.Citas.FechaCita. La fecha de programación no tiene dimensión propia: se utiliza para calcular la medida Tiempo_Espera_Min en la tabla de hechos. Jerarquía: Año → Trimestre → Mes → Fecha.

Tabla 3.10. *Estructura de dw.Dim_Tiempo.*

Columna	Tipo	Descripción
SK_Tiempo	INT (PK)	Llave de la dimensión con formato AAAAMMDD.
Fecha	DATE	Fecha calendario de la cita.

Anio	SMALLINT	Año.
Mes	TINYINT	Número de mes (1–12).
NombreMes	VARCHAR(12)	Nombre del mes en español.
Trimestre	TINYINT	Trimestre del año (1–4).
Dia_Semana	VARCHAR(15)	Nombre del día de la semana en español.

3.10.2 Dim_Paciente

Contiene los atributos demográficos del paciente utilizados para segmentar el análisis, en especial el barrio, la edad y el género. Se alimenta desde oltp.Pacientes.

Tabla 3.11. *Estructura de dw.Dim_Paciente.*

Columna	Tipo	Descripción
SK_Paciente	INT (PK, IDENTITY)	Llave subrogada del paciente.
IdPaciente	BIGINT (UNIQUE)	Clave de negocio proveniente del OLTP.
Genero	CHAR(1)	Género del paciente.
Edad	SMALLINT	Edad del paciente.
Barrio	NVARCHAR(100)	Barrio de residencia.

3.10.3 Dim_Medico

Describe al odontólogo que atiende la cita y permite analizar el desempeño por profesional y especialidad. Se alimenta desde oltp.Odontologos, concatenando nombres y apellidos en un único campo.

Tabla 3.12. *Estructura de dw.Dim_Medico.*

Columna	Tipo	Descripción
SK_Medico	INT (PK, IDENTITY)	Llave subrogada del odontólogo.
IdOdontologo	INT (UNIQUE)	Clave de negocio proveniente del OLTP.
NombreCompleto	NVARCHAR(200)	Nombres y apellidos concatenados.
Especialidad	NVARCHAR(100)	Especialidad odontológica.

3.10.4 Dim_Tratamiento

Describe el procedimiento odontológico aplicado, tomado del catálogo CPMS, junto con su duración estimada y su costo. Se alimenta desde oltp.Tratamientos.

Tabla 3.13. *Estructura de dw.Dim_Tratamiento.*

Columna	Tipo	Descripción
SK_Tratamiento	INT (PK,	Llave subrogada del tratamiento.

	IDENTITY)	
IdTratamiento	INT	Clave de negocio proveniente del OLTP.
Descripcion	NVARCHAR(500)	Descripción del procedimiento.
Duracion_Meses	INT	Duración estimada del tratamiento, en meses.
Costo_Total	DECIMAL(10,2)	Costo del tratamiento según el catálogo (proviene de Tratamientos.Costo).

3.11 Tabla(s) de hechos.

La tabla dw.Fact_Atenciones es el centro del modelo dimensional. Su grano es **una fila por cita médica** (sección 3.7) y almacena las medidas numéricas del proceso de atención, las variables calculadas para análisis y aprendizaje automático, y las llaves hacia las cuatro dimensiones.

Tabla 3.14. *Estructura de dw.Fact_Atenciones.*

Columna	Tipo	Rol	Descripción
ID_Hecho	INT	PK (IDENTITY)	Llave subrogada del hecho.
IdCita	INT	Dimensión degenerada (UNIQUE)	Identificador de la cita en el OLTP; garantiza una fila por cita y evita duplicados en el ETL.
SK_Paciente	INT	FK	Paciente atendido (Dim_Paciente).
SK_Medico	INT	FK	Odontólogo que atiende (Dim_Medico).
SK_Tratamiento	INT	FK	Tratamiento aplicado (Dim_Tratamiento).
SK_Tiempo	INT	FK	Fecha de la cita (Dim_Tiempo).
Estado_Cita	VARCHAR(20)	Atributo	'Atendido' o 'Ausencia/No-Show'.
Tiempo_Espera_Min	INT	Medida	Minutos entre la programación y la fecha de la cita.
Monto_Pagado	DECIMAL(10,2)	Medida	Monto asociado a la cita (costo aplicado).
Es_Atendido	INT	Indicador	1 si el paciente asistió; 0 en caso contrario.
Es_Ausencia	INT	Indicador	1 si el paciente no asistió; 0 en caso contrario.

Las medidas se comportan de la siguiente manera: Monto_Pagado es **aditiva** y se puede sumar por cualquier dimensión; Es_Atendido y Es_Ausencia son **aditivas** como conteos de citas atendidas y ausentes (SUM), y Es_Ausencia dividida entre el total de citas produce la tasa de abandono; Tiempo_Espera_Min **no se suma**, sino que se analiza mediante promedio, mínimo y máximo. A modo de ejemplo, la tasa de ausencia por especialidad se obtiene con la siguiente consulta:

```
SELECT m.Especialidad,
      COUNT(*) AS TotalCitas,
      SUM(f.Es_Ausencia) AS Ausencias,
      CAST(SUM(f.Es_Ausencia) * 100.0 / COUNT(*) AS DECIMAL(5,2)) AS PorcentajeAusencia
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Medico m ON m.SK_Medico = f.SK_Medico
GROUP BY m.Especialidad
ORDER BY PorcentajeAusencia DESC;
```

Complementariamente, la tabla dw.Resultados_Prediccion_IA almacena la salida del modelo predictivo por cita (Probabilidad, Riesgo, Prediccion_Binary y FechaEvaluacion) y se relaciona con la tabla de hechos mediante IdCita, lo que permite cruzar el riesgo estimado con cualquier dimensión.

3.12 Modelo dimensional.

El modelo dimensional resultante es un esquema estrella: la tabla de hechos `Fact_Atenciones` ocupa el centro y se conecta con las dimensiones Paciente, Médico, Tratamiento y Tiempo mediante relaciones uno a muchos (1:N) sobre las llaves subrogadas. La figura siguiente presenta el esquema con sus llaves y tipos de datos.

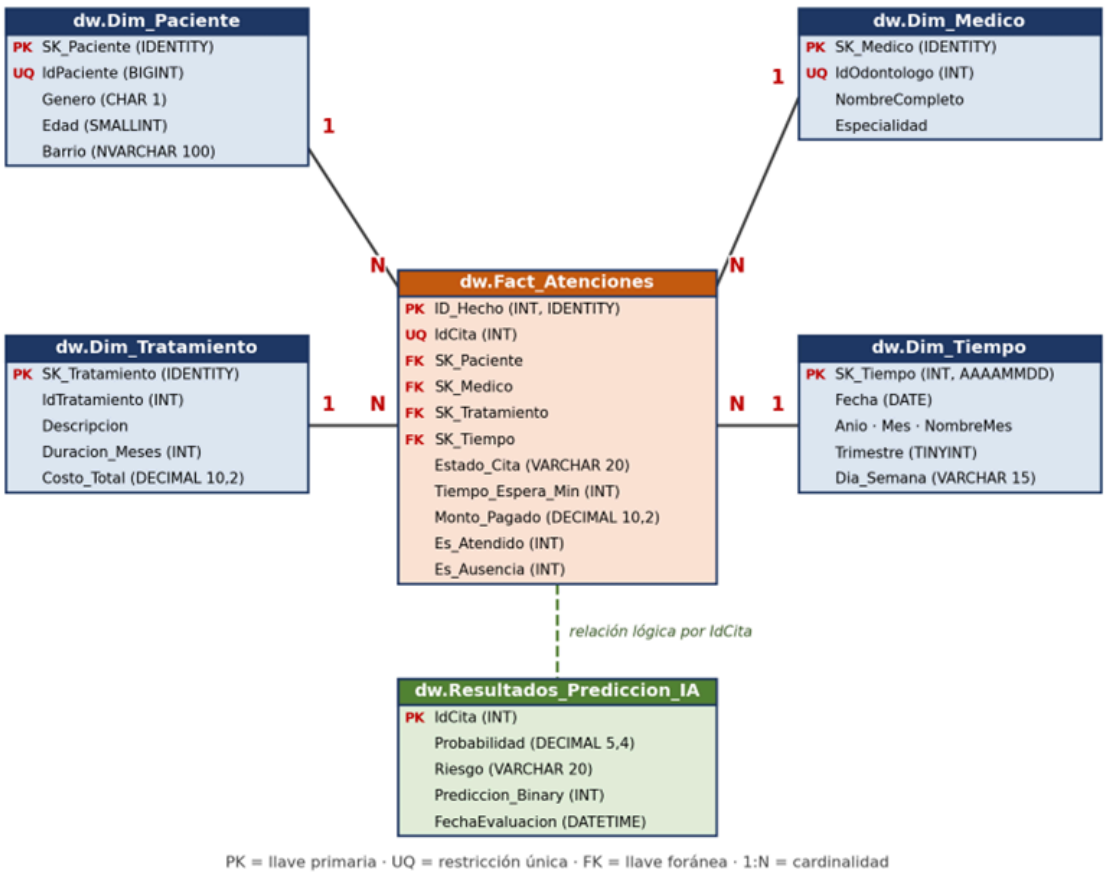


Figura 3.3. *Esquema estrella del Data Mart (diagrama de referencia).*

En el esquema estrella, cada dimensión se vincula directamente con la tabla de hechos, sin dimensiones intermedias, lo que simplifica las consultas y favorece el rendimiento de las agregaciones. La tabla `Resultados_Prediccion_IA` se muestra con una relación lógica por `IdCita`, ya que su función es registrar la salida del modelo de IA sobre las citas existentes en la tabla de hechos.

3.13 Proceso ETL.

El proceso ETL (extracción, transformación y carga) traslada los datos desde los archivos CSV hasta el Data Mart en dos etapas encadenadas: de los archivos crudos al OLTP, y del OLTP al modelo dimensional. Está implementado con *scripts* de T-SQL y dos procedimientos almacenados: stg.usp_CargarOLTP y dw.usp_ETL_CargarDataMart.

3.13.1 Extracción de los archivos CSV

La extracción se realiza con la instrucción BULK INSERT, que carga cada archivo directamente en su tabla de *staging*, omitiendo la fila de encabezado (FIRSTROW = 2). Antes de cada carga, las tablas de *staging* se vacían con TRUNCATE TABLE, de manera que siempre reflejen el contenido del archivo más reciente.

Tabla 3.15. *Fuentes de datos del proceso ETL.*

Archivo	Tabla de staging	Contenido
KaggleV2-May-2016.csv	stg.Raw_NoShow	Citas médicas y datos del paciente (dataset público *Medical Appointment No Shows*): identificadores, género, fechas, edad, barrio, indicadores de salud, SMS e inasistencia.
cpms_odontologia.csv	stg.Raw_CPMS	Catálogo de procedimientos odontológicos: código, descripción y tarifa.

3.13.2 Transformación y limpieza

La transformación se realiza en stg.usp_CargarOLTP y convierte el texto crudo en datos tipados y validados. Se utiliza TRY_CAST, que devuelve NULL en lugar de producir un error cuando un valor no se puede convertir, lo que permite descartar o corregir registros inválidos sin interrumpir el proceso.

Tabla 3.16. *Reglas de transformación de origen a destino.*

Campo de origen	Campo de destino	Regla aplicada
PatientId	Pacientes.IdPaciente	Conversión a BIGINT; se descartan nulos y valores no numéricos.
Gender	Pacientes.Genero	UPPER(LEFT(Gender, 1)): primera letra en mayúscula.
Age	Pacientes.Edad	Conversión a SMALLINT; solo se aceptan edades entre 0 y 120.
Neighbourhood	Pacientes.Barrio	Copia directa.

Scholarship, Hipertension, Diabetes, Alcoholism	Beca, Hipertension, Diabetes, Alcoholismo	Conversión a BIT; los nulos se reemplazan por 0.
Handcap	Pacientes.Discapacidad	Conversión a TINYINT; los nulos se reemplazan por 0.
AppointmentID	Citas.IdCita	Conversión a INT.
ScheduledDay	Citas.FechaProgramacion	Se toman los primeros 19 caracteres y se convierte a DATETIME2.
AppointmentDay	Citas.FechaCita	Se toman los primeros 10 caracteres y se convierte a DATE.
SMS_received	Citas.SMSRecibido	1 si el valor es '1'; en caso contrario 0.
NoShow	Citas.NoShow	Se conserva el texto Yes/No; en el Data Mart se traduce a Estado_Cita, Es_Atendido y Es_Ausencia.
Codigo, Descripcion, Tarifa	Tratamientos.CodigoCPMS, Descripcion, Costo	Se reemplaza la coma decimal por punto y se convierte a DECIMAL(10,2); si la tarifa es inválida se asigna 45.00. La columna DuracionMeses se fija en 1.
(calculado)	Citas.IdOdontologo, Citas.IdTratamiento	Asignación determinística a partir de CHECKSUM(AppointmentID), ya que el origen no registra odontólogo ni tratamiento.
(calculado)	Citas.CostoAplicado	Costo del tratamiento asignado; 50.00 si no se encuentra.

Dado que el dataset de origen no incluye información sobre el odontólogo ni sobre el tratamiento de cada cita, el ETL los asigna de forma determinística: el identificador del odontólogo se obtiene como (ABS(CHECKSUM(AppointmentID)) % 3) + 1 y el del tratamiento como un valor derivado de CHECKSUM(AppointmentID, 7) dentro del rango del catálogo. Al ser determinística, la asignación es reproducible en cada ejecución. Los tres odontólogos corresponden a personal base insertado en el Script 3 (Odontología General, Endodoncia y Ortodoncia). Si el catálogo CPMS llega vacío, el procedimiento carga un catálogo mínimo de seis tratamientos odontológicos, con duraciones de 1 a 12 meses (por ejemplo, 12 meses para el control mensual de ortodoncia).

3.13.3 Desduplicación

El archivo de origen contiene una fila por cita, de modo que un mismo paciente aparece repetido tantas veces como citas tenga. Para cargar entidades únicas, el ETL utiliza la función de ventana ROW_NUMBER() y conserva solo la primera fila de cada grupo (FilaNum = 1).

Tabla 3.17. *Reglas de desduplicación.*

Entidad	Criterio de partición y orden	Resultado
Paciente	PARTITION BY PatientId ORDER BY AppointmentID DESC	Un registro por paciente, con los datos de su cita más reciente.
Cita	PARTITION BY AppointmentID ORDER BY ScheduledDay DESC	Un registro por cita, aun si el identificador se repite en el archivo.

Adicionalmente, la carga es incremental: solo se insertan pacientes y citas que aún no existen en el destino (NOT IN), y únicamente se cargan citas cuyo paciente fue aceptado en oltp.Pacientes, preservando la integridad referencial. Las citas de pacientes descartados por edad inválida no ingresan al modelo.

3.13.4 Carga al Data Mart

El procedimiento dw.usp_ETL_CargarDataMart realiza la carga dimensional en el siguiente orden: primero las dimensiones (Dim_Paciente, Dim_Medico, Dim_Tratamiento y Dim_Tiempo) y finalmente la tabla de hechos. Este orden es necesario porque la tabla de hechos requiere las llaves subrogadas de las dimensiones para resolver sus llaves foráneas.

- **Dim_Medico:** el nombre completo se construye concatenando Nombres y Apellidos.
- **Dim_Tiempo:** a partir de las fechas distintas de las citas se genera la llave AAAAMMDD mediante CONVERT(VARCHAR(8), FechaCita, 112), y se derivan el nombre del mes (DATENAME(MONTH, ...)), el trimestre (DATEPART(QUARTER, ...)) y el día de la semana (DATENAME(WEEKDAY, ...)); el procedimiento ejecuta SET LANGUAGE Spanish para que los nombres salgan en español.
- **Fact_Atenciones:** se relaciona cada cita con las llaves subrogadas de sus dimensiones; Tiempo_Espera_Min se calcula con DATEDIFF(MINUTE, ...) entre la programación y la fecha de la cita; el resultado Yes/No se traduce a Estado_Cita ('Atendido' o 'Ausencia/No-Show') y a los indicadores Es_Atendido y Es_Ausencia; y Monto_Pagado toma el valor de CostoAplicado.

3.14 Carga y actualización de datos.

La implementación completa se organiza en tres *scripts* de T-SQL que separan la responsabilidad de crear la estructura, definir la lógica de procesamiento y ejecutar las cargas. Esta separación facilita el mantenimiento: la estructura y la lógica se definen una sola vez, y solo el tercer *script* se vuelve a ejecutar cuando se requiere refrescar los datos.

Tabla 3.18. *Scripts del proceso de carga.*

Orden	Archivo	Tipo	Contenido
1	01_DDL_Creacion_Estructura.sql	DDL	Base de datos, esquemas stg, oltp y dw, y todas las tablas.

2	02_Logica_Procesos_ETL.sql	Procedimientos y vistas	stg.usp_CargarOLTP, dw.usp_ETL_CargarDataMart y las tres vistas analíticas.
3	03_DML_Ejecucion_Cargas.sql	DML	Limpieza de *staging*, BULK INSERT, datos base de odontólogos, ejecución de procedimientos y verificación.

Secuencia de ejecución. Los *scripts* se ejecutan en orden numérico. El Script 3 vacía las tablas de *staging*, carga los CSV, inserta los tres odontólogos base (solo si la tabla está vacía), ejecuta stg.usp_CargarOLTP y luego dw.usp_ETL_CargarDataMart, y finaliza con una consulta de verificación que cuenta los registros de oltp.Pacientes, oltp.Citas, dw.Dim_Paciente y dw.Fact_Atenciones.

Actualización de datos. Los procedimientos son incrementales: en cada ejecución insertan únicamente los registros que no existen en el destino, comparando por las claves de negocio (IdPaciente, IdCita, IdOdontologo, IdTratamiento y SK_Tiempo). Para incorporar nuevos datos basta con reemplazar o actualizar los archivos CSV y volver a ejecutar el Script 3. La verificación final permite comprobar que el número de citas del OLTP coincide con el de la tabla de hechos.

Consideraciones de ejecución.

- Las rutas de los archivos en BULK INSERT son absolutas (carpeta 05_Datasets del proyecto) y deben ajustarse al equipo donde se ejecute; además, la cuenta de servicio de SQL Server debe tener permiso de lectura sobre ellas.
- La carga de oltp.Tratamientos no verifica existencia previa; si se desea una recarga completa desde cero, se recomienda volver a ejecutar el Script 1 antes del Script 3.
- La asignación de odontólogo y tratamiento a cada cita es simulada (sección 3.13.2), por lo que los análisis por especialidad y tratamiento deben interpretarse como una demostración del modelo.
- Al cargar el catálogo desde el CSV de CPMS, la duración de cada tratamiento (DuracionMeses) se fija en 1 mes; solo el catálogo de respaldo incluye duraciones distintas.
- Tiempo_Espera_Min se calcula contra la fecha de la cita sin hora (tipo DATE, equivalente a las 00:00). En citas programadas el mismo día, el valor puede resultar negativo, por lo que conviene filtrarlo o interpretarlo con cuidado en el análisis.

3.14.1 Script 1: Estructura de la base de datos (DDL)

Código 3.1. *01_DDL_Creacion_Estructura.sql*

```
/* ======================================================================
   SCRIPT 1: ESTRUCTURA DE BASE DE DATOS (DDL)
   ====================================================================== */
USE master;
GO


IF DB_ID('DentalCenterDB') IS NULL
    CREATE DATABASE DentalCenterDB;
GO


USE DentalCenterDB;
GO
```

```
-- 1. ESQUEMAS
IF SCHEMA_ID('stg')  IS NULL EXEC('CREATE SCHEMA stg');
IF SCHEMA_ID('oltp') IS NULL EXEC('CREATE SCHEMA oltp');
IF SCHEMA_ID('dw')   IS NULL EXEC('CREATE SCHEMA dw');
GO


-- 2. TABLAS STAGING (Capa de aterrizaje cruda)
IF OBJECT_ID('stg.Raw_NoShow', 'U') IS NOT NULL DROP TABLE stg.Raw_NoShow;
CREATE TABLE stg.Raw_NoShow (
    PatientId           NVARCHAR(50)  NULL,
    AppointmentID   NVARCHAR(50)  NULL,
    Gender              NVARCHAR(10)  NULL,
    ScheduledDay        NVARCHAR(50)  NULL,
    AppointmentDay  NVARCHAR(50)  NULL,
    Age                 NVARCHAR(10)  NULL,
    Neighbourhood   NVARCHAR(100) NULL,
    Scholarship         NVARCHAR(5)   NULL,
    Hipertension        NVARCHAR(5)   NULL,
    Diabetes            NVARCHAR(5)   NULL,
    Alcoholism          NVARCHAR(5)   NULL,
    Handcap             NVARCHAR(5)   NULL,
    SMS_received        NVARCHAR(5)   NULL,
    NoShow              NVARCHAR(10)  NULL
);


IF OBJECT_ID('stg.Raw_CPMS', 'U') IS NOT NULL DROP TABLE stg.Raw_CPMS;
CREATE TABLE stg.Raw_CPMS (
    Codigo      NVARCHAR(50)   NULL,
    Descripcion  NVARCHAR(1000) NULL,
    Tarifa      NVARCHAR(50)   NULL
);
GO


-- 3. TABLAS OLTP (Sistema Transaccional)
IF OBJECT_ID('oltp.Citas', 'U') IS NOT NULL DROP TABLE oltp.Citas;
IF OBJECT_ID('oltp.Pacientes', 'U') IS NOT NULL DROP TABLE oltp.Pacientes;
IF OBJECT_ID('oltp.Odontologos', 'U') IS NOT NULL DROP TABLE oltp.Odontologos;
IF OBJECT_ID('oltp.Tratamientos', 'U') IS NOT NULL DROP TABLE oltp.Tratamientos;
GO


CREATE TABLE oltp.Pacientes (
    IdPaciente  BIGINT          NOT NULL PRIMARY KEY CLUSTERED,
    Genero      CHAR(1)         NOT NULL,
    Edad        SMALLINT        NOT NULL,
    Barrio      NVARCHAR(100) NOT NULL,
    Beca        BIT             NOT NULL DEFAULT 0,
    Hipertension  BIT           NOT NULL DEFAULT 0,
    Diabetes    BIT             NOT NULL DEFAULT 0,
    Alcoholismo   BIT           NOT NULL DEFAULT 0,
    Discapacidad  TINYINT       NOT NULL DEFAULT 0
);


CREATE TABLE oltp.Odontologos (
    IdOdontologo INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    Nombres     NVARCHAR(100) NOT NULL,
    Apellidos   NVARCHAR(100) NOT NULL,
    Especialidad NVARCHAR(100) NOT NULL,
    Activo      BIT             NOT NULL DEFAULT 1
);


CREATE TABLE oltp.Tratamientos (
    IdTratamiento INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    CodigoCPMS  VARCHAR(50)     NOT NULL,
    Descripcion   NVARCHAR(500)  NOT NULL,
    DuracionMeses INT           NOT NULL DEFAULT 1, -- Nuevo campo operativo
    Costo       DECIMAL(10,2)  NOT NULL
);


CREATE TABLE oltp.Citas (
    IdCita              INT             NOT NULL PRIMARY KEY CLUSTERED,
    IdPaciente          BIGINT          NOT NULL FOREIGN KEY REFERENCES oltp.Pacientes(IdPaciente),
    IdOdontologo        INT             NOT NULL FOREIGN KEY REFERENCES oltp.Odontologos(IdOdontologo),
    IdTratamiento       INT             NOT NULL,
    FechaProgramacion DATETIME2(0)  NOT NULL,
    FechaCita           DATE            NOT NULL,
    SMSRecibido         BIT             NOT NULL DEFAULT 0,
    NoShow              VARCHAR(3)      NOT NULL,
    CostoAplicado       DECIMAL(10,2) NOT NULL
);
GO


-- 4. TABLAS DATA MART (Modelo Dimensional Kimball)
IF OBJECT_ID('dw.Fact_Atenciones', 'U') IS NOT NULL DROP TABLE dw.Fact_Atenciones;
IF OBJECT_ID('dw.Dim_Paciente', 'U') IS NOT NULL DROP TABLE dw.Dim_Paciente;
IF OBJECT_ID('dw.Dim_Medico', 'U') IS NOT NULL DROP TABLE dw.Dim_Medico;
```

```
IF OBJECT_ID('dw.Dim_Tratamiento', 'U') IS NOT NULL DROP TABLE dw.Dim_Tratamiento;
IF OBJECT_ID('dw.Dim_Tiempo', 'U') IS NOT NULL DROP TABLE dw.Dim_Tiempo;
IF OBJECT_ID('dw.Resultados_Prediccion_IA', 'U') IS NOT NULL DROP TABLE dw.Resultados_Prediccion_IA;
GO


CREATE TABLE dw.Dim_Paciente (
    SK_Paciente  INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdPaciente   BIGINT         NOT NULL UNIQUE,
    Genero      CHAR(1)         NOT NULL,
    Edad        SMALLINT        NOT NULL,
    Barrio      NVARCHAR(100) NOT NULL
);


CREATE TABLE dw.Dim_Medico (
    SK_Medico   INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdOdontologo   INT          NOT NULL UNIQUE,
    NombreCompleto NVARCHAR(200) NOT NULL,
    Especialidad   NVARCHAR(100) NOT NULL
);


CREATE TABLE dw.Dim_Tratamiento (
    SK_Tratamiento INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdTratamiento  INT          NOT NULL,
    Descripcion NVARCHAR(500) NOT NULL,
    Duracion_Meses INT          NOT NULL, -- Nuevo campo
    Costo_Total DECIMAL(10,2) NOT NULL  -- Renombrado
);


CREATE TABLE dw.Dim_Tiempo (
    SK_Tiempo  INT      NOT NULL PRIMARY KEY CLUSTERED,
    Fecha       DATE            NOT NULL,
    Anio        SMALLINT        NOT NULL,
    Mes         TINYINT         NOT NULL,
    NombreMes  VARCHAR(12) NOT NULL,
    Trimestre  TINYINT  NOT NULL,       -- Nuevo campo
    Dia_Semana VARCHAR(15) NOT NULL        -- Nuevo campo
);


CREATE TABLE dw.Fact_Atenciones (
    ID_Hecho            INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdCita              INT             NOT NULL UNIQUE, -- Necesario para el flujo ETL (no duplicar)
    SK_Paciente         INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Paciente(SK_Paciente),
    SK_Medico           INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Medico(SK_Medico),
    SK_Tratamiento      INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Tratamiento(SK_Tratamiento),
    SK_Tiempo           INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Tiempo(SK_Tiempo),

    -- Métricas / Medidas
    Estado_Cita         VARCHAR(20)   NOT NULL,
    Tiempo_Espera_Min INT           NOT NULL,
    Monto_Pagado        DECIMAL(10,2) NOT NULL,

    -- Variables Calculadas para Análisis y Machine Learning
    Es_Atendido         INT             NOT NULL,
    Es_Ausencia         INT             NOT NULL
);


CREATE TABLE dw.Resultados_Prediccion_IA (
    IdCita              INT             NOT NULL PRIMARY KEY CLUSTERED,
    Probabilidad      DECIMAL(5,4)  NOT NULL,
    Riesgo              VARCHAR(20)   NOT NULL,
    Prediccion_Binary INT           NOT NULL,
    FechaEvaluacion   DATETIME          DEFAULT GETDATE()
);
GO
```

3.14.2 Script 2: Lógica de procesamiento (procedimientos almacenados y vistas)

Código 3.2. *02_Logica_Procesos_ETL.sql*

```
/* ====================================================================
   SCRIPT 2: LÓGICA DE PROCESAMIENTO (STORED PROCEDURES Y VISTAS)
   ==================================================================== */
USE DentalCenterDB;
GO


-- 1. PROCEDIMIENTO: CARGA OLTP
CREATE OR ALTER PROCEDURE stg.usp_CargarOLTP
AS
BEGIN
    SET NOCOUNT ON;

    -- Tratamientos
    INSERT INTO oltp.Tratamientos (CodigoCPMS, Descripcion, Costo, DuracionMeses)
```

```
    SELECT Codigo, Descripcion, ISNULL(TRY_CAST(REPLACE(Tarifa, ',', '.') AS DECIMAL(10,2)), 45.00), 1
    FROM stg.Raw_CPMS WHERE Codigo IS NOT NULL;


    IF NOT EXISTS (SELECT 1 FROM oltp.Tratamientos)
    BEGIN
        INSERT INTO oltp.Tratamientos (CodigoCPMS, Descripcion, Costo, DuracionMeses) VALUES
        ('CPMS-01', 'Consulta Odontológica General', 30.00, 1),
        ('CPMS-02', 'Profilaxis y Destartraje', 50.00, 1),
        ('CPMS-03', 'Curación con Resina Fotocurable', 70.00, 1),
        ('CPMS-04', 'Exodoncia Simple', 60.00, 1),
        ('CPMS-05', 'Endodoncia Unirradicular', 150.00, 2),
        ('CPMS-06', 'Ortodoncia - Control Mensual', 80.00, 12);
    END;


    -- Pacientes
    WITH PacientesUnicos AS (
        SELECT
                TRY_CAST(PatientId AS BIGINT) AS IdPaciente,
                UPPER(LEFT(Gender, 1)) AS Genero,
                TRY_CAST(Age AS SMALLINT) AS Edad,
                Neighbourhood AS Barrio,
                TRY_CAST(Scholarship AS BIT) AS Beca,
                TRY_CAST(Hipertension AS BIT) AS Hipertension,
                TRY_CAST(Diabetes AS BIT) AS Diabetes,
                TRY_CAST(Alcoholism AS BIT) AS Alcoholismo,
                TRY_CAST(Handcap AS TINYINT) AS Discapacidad,
                ROW_NUMBER() OVER (PARTITION BY TRY_CAST(PatientId AS BIGINT) ORDER BY TRY_CAST(AppointmentID AS
INT) DESC) AS FilaNum
        FROM stg.Raw_NoShow
        WHERE TRY_CAST(PatientId AS BIGINT) IS NOT NULL AND TRY_CAST(Age AS SMALLINT) BETWEEN 0 AND 120
    )
    INSERT INTO oltp.Pacientes (IdPaciente, Genero, Edad, Barrio, Beca, Hipertension, Diabetes, Alcoholismo,
Discapacidad)
    SELECT IdPaciente, Genero, Edad, Barrio, ISNULL(Beca, 0), ISNULL(Hipertension, 0), ISNULL(Diabetes, 0),
ISNULL(Alcoholismo, 0), ISNULL(Discapacidad, 0)
    FROM PacientesUnicos
    WHERE FilaNum = 1 AND IdPaciente NOT IN (SELECT IdPaciente FROM oltp.Pacientes);


    -- Citas
    WITH CitasUnicas AS (
        SELECT
                TRY_CAST(AppointmentID AS INT) AS IdCita,
                TRY_CAST(PatientId AS BIGINT) AS IdPaciente,
                (ABS(CHECKSUM(AppointmentID)) % 3) + 1 AS IdOdontologo,
                (ABS(CHECKSUM(AppointmentID, 7)) % (SELECT ISNULL(NULLIF(COUNT(*), 0), 1) FROM oltp.Tratamientos))
+ 1 AS IdTratamiento,
                TRY_CAST(LEFT(ScheduledDay, 19) AS DATETIME2) AS FechaProgramacion,
                TRY_CAST(LEFT(AppointmentDay, 10) AS DATE) AS FechaCita,
                CASE WHEN SMS_received = '1' THEN 1 ELSE 0 END AS SMSRecibido,
                NoShow,
                ROW_NUMBER() OVER (PARTITION BY TRY_CAST(AppointmentID AS INT) ORDER BY ScheduledDay DESC) AS
FilaNum
        FROM stg.Raw_NoShow
        WHERE TRY_CAST(AppointmentID AS INT) IS NOT NULL AND TRY_CAST(PatientId AS BIGINT) IS NOT NULL
    )
    INSERT INTO oltp.Citas (IdCita, IdPaciente, IdOdontologo, IdTratamiento, FechaProgramacion, FechaCita,
SMSRecibido, NoShow, CostoAplicado)
    SELECT c.IdCita, c.IdPaciente, c.IdOdontologo, c.IdTratamiento, c.FechaProgramacion, c.FechaCita,
c.SMSRecibido, c.NoShow, ISNULL(t.Costo, 50.00)
    FROM CitasUnicas c
    LEFT JOIN oltp.Tratamientos t ON t.IdTratamiento = c.IdTratamiento
    WHERE c.FilaNum = 1 AND c.IdCita NOT IN (SELECT IdCita FROM oltp.Citas) AND c.IdPaciente IN (SELECT IdPaciente
FROM oltp.Pacientes);
END;
GO


-- 2. PROCEDIMIENTO: CARGA DATA MART
CREATE OR ALTER PROCEDURE dw.usp_ETL_CargarDataMart
AS
BEGIN
    SET NOCOUNT ON;
    SET LANGUAGE Spanish; -- Para extraer días/meses en español

    INSERT INTO dw.Dim_Paciente (IdPaciente, Genero, Edad, Barrio)
    SELECT IdPaciente, Genero, Edad, Barrio FROM oltp.Pacientes WHERE IdPaciente NOT IN (SELECT IdPaciente FROM
dw.Dim_Paciente);

    INSERT INTO dw.Dim_Medico (IdOdontologo, NombreCompleto, Especialidad)
    SELECT IdOdontologo, Nombres + ' ' + Apellidos, Especialidad FROM oltp.Odontologos WHERE IdOdontologo NOT IN
(SELECT IdOdontologo FROM dw.Dim_Medico);


    -- Dim_Tratamiento actualizada
    INSERT INTO dw.Dim_Tratamiento (IdTratamiento, Descripcion, Duracion_Meses, Costo_Total)
    SELECT IdTratamiento, Descripcion, DuracionMeses, Costo
    FROM oltp.Tratamientos
    WHERE IdTratamiento NOT IN (SELECT IdTratamiento FROM dw.Dim_Tratamiento);


    -- Dim_Tiempo actualizada
```

```
    INSERT INTO dw.Dim_Tiempo (SK_Tiempo, Fecha, Anio, Mes, NombreMes, Trimestre, Dia_Semana)
    SELECT DISTINCT
        CAST(CONVERT(VARCHAR(8), FechaCita, 112) AS INT),
        FechaCita,
        YEAR(FechaCita),
        MONTH(FechaCita),
        DATENAME(MONTH, FechaCita),
        DATEPART(QUARTER, FechaCita),
        DATENAME(WEEKDAY, FechaCita)
    FROM oltp.Citas
    WHERE CAST(CONVERT(VARCHAR(8), FechaCita, 112) AS INT) NOT IN (SELECT SK_Tiempo FROM dw.Dim_Tiempo);


    -- Fact_Atenciones actualizada
    INSERT INTO dw.Fact_Atenciones (
        IdCita, SK_Paciente, SK_Medico, SK_Tratamiento, SK_Tiempo,
        Estado_Cita, Tiempo_Espera_Min, Monto_Pagado, Es_Atendido, Es_Ausencia
    )
    SELECT
        c.IdCita,
        dp.SK_Paciente,
        dm.SK_Medico,
        ISNULL(dt.SK_Tratamiento, 1),
        CAST(CONVERT(VARCHAR(8), c.FechaCita, 112) AS INT) AS SK_Tiempo,
        CASE WHEN c.NoShow = 'Yes' THEN 'Ausencia/No-Show' ELSE 'Atendido' END AS Estado_Cita,
        DATEDIFF(MINUTE, c.FechaProgramacion, CAST(c.FechaCita AS DATETIME2)) AS Tiempo_Espera_Min,
        c.CostoAplicado AS Monto_Pagado,
        CASE WHEN c.NoShow = 'Yes' THEN 0 ELSE 1 END AS Es_Atendido,
        CASE WHEN c.NoShow = 'Yes' THEN 1 ELSE 0 END AS Es_Ausencia
    FROM oltp.Citas c
    JOIN dw.Dim_Paciente dp ON c.IdPaciente = dp.IdPaciente
    JOIN dw.Dim_Medico dm ON c.IdOdontologo = dm.IdOdontologo
    LEFT JOIN dw.Dim_Tratamiento dt ON c.IdTratamiento = dt.IdTratamiento
    WHERE c.IdCita NOT IN (SELECT IdCita FROM dw.Fact_Atenciones);
END;
GO


-- 3. VISTAS ANALÍTICAS ACTUALIZADAS
CREATE OR ALTER VIEW dw.vw_KPI_TasaAbandono AS
SELECT
    t.Anio, t.Mes, t.NombreMes, p.Barrio,
    COUNT(*) AS TotalCitas,
    SUM(f.Es_Ausencia) AS CitasAbandonadas,
    CAST(SUM(f.Es_Ausencia) * 100.0 / NULLIF(COUNT(*), 0) AS DECIMAL(5,2)) AS PorcentajeAbandono
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON t.SK_Tiempo = f.SK_Tiempo
JOIN dw.Dim_Paciente p ON p.SK_Paciente = f.SK_Paciente
GROUP BY t.Anio, t.Mes, t.NombreMes, p.Barrio;
GO


CREATE OR ALTER VIEW dw.vw_KPI_IngresosEnRiesgo AS
SELECT
    t.Anio, t.NombreMes, m.Especialidad,
    SUM(f.Monto_Pagado) AS IngresoTotalEstimado,
    SUM(CASE WHEN f.Es_Ausencia = 1 THEN f.Monto_Pagado ELSE 0 END) AS IngresosEnRiesgoPerdidos
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON t.SK_Tiempo = f.SK_Tiempo
JOIN dw.Dim_Medico m ON m.SK_Medico = f.SK_Medico
GROUP BY t.Anio, t.NombreMes, m.Especialidad;
GO


CREATE OR ALTER VIEW dw.vw_Dataset_ML AS
SELECT
    f.ID_Hecho,
    p.Edad,
    f.Tiempo_Espera_Min,
    dt.Duracion_Meses,
    f.Monto_Pagado,
    f.Es_Ausencia AS Target_Abandono
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Paciente p ON p.SK_Paciente = f.SK_Paciente
JOIN dw.Dim_Tratamiento dt ON dt.SK_Tratamiento = f.SK_Tratamiento;
GO
```

3.14.3 Script 3: Ejecución del ETL y carga de datos (DML)

Código 3.3. *03_DML_Ejecucion_Cargas.sql*

```
/* ====================================================================
   SCRIPT 3: EJECUCIÓN ETL Y CARGA DE DATOS (DML)
   ==================================================================== */
USE DentalCenterDB;
GO


-- 1. LIMPIEZA DE TABLAS TEMPORALES (Staging)
TRUNCATE TABLE stg.Raw_NoShow;
```

```
TRUNCATE TABLE stg.Raw_CPMS;
GO


-- 2. CARGA DE ARCHIVOS CSV CRUDOS
-- (Recuerda modificar la ruta a una pública como C:\Datasets\ si tienes problemas de permisos)
BULK INSERT stg.Raw_NoShow
FROM 'C:\Users\MANFRED\Desktop\Proyecto_GADI_Clinica\05_Datasets\KaggleV2-May-2016.csv'
WITH (FORMAT = 'CSV', FIRSTROW = 2, FIELDTERMINATOR = ',', ROWTERMINATOR = '0x0a');


BULK INSERT stg.Raw_CPMS
FROM 'C:\Users\MANFRED\Desktop\Proyecto_GADI_Clinica\05_Datasets\cpms_odontologia.csv'
WITH (FORMAT = 'CSV', FIRSTROW = 2, FIELDTERMINATOR = ',', ROWTERMINATOR = '0x0a');
GO


-- 3. INSERCIÓN DE DATOS ESTÁTICOS INICIALES (Personal base)
IF NOT EXISTS (SELECT 1 FROM oltp.Odontologos)
BEGIN
    INSERT INTO oltp.Odontologos (Nombres, Apellidos, Especialidad) VALUES
    ('Carlos', 'Mendoza', 'Odontología General'),
    ('Lucía', 'Paredes', 'Endodoncia'),
    ('Jorge', 'Salas', 'Ortodoncia');
END;
GO


-- 4. EJECUCIÓN DE PROCEDIMIENTOS ALMACENADOS ETL
PRINT 'Iniciando carga hacia OLTP...';
EXEC stg.usp_CargarOLTP;
PRINT 'Carga OLTP finalizada.';


PRINT 'Iniciando carga hacia Data Mart...';
EXEC dw.usp_ETL_CargarDataMart;
PRINT 'Carga Data Mart finalizada.';
GO


-- 5. VERIFICACIÓN FINAL (Validar que las tablas tienen datos)
SELECT 'OLTP Pacientes' AS Tabla, COUNT(*) AS TotalRegistros FROM oltp.Pacientes
UNION ALL
SELECT 'OLTP Citas', COUNT(*) FROM oltp.Citas
UNION ALL
SELECT 'DW Dim_Paciente', COUNT(*) FROM dw.Dim_Paciente
UNION ALL
SELECT 'DW Fact_Atenciones', COUNT(*) FROM dw.Fact_Atenciones;
GO
```

3.15 Implementación de OLAP.

El procesamiento analítico en línea (OLAP, *Online Analytical Processing*) permite explorar los datos del Data Mart desde múltiples perspectivas —tiempo, paciente, odontólogo y tratamiento— y con distintos niveles de detalle, sin necesidad de reconstruir las consultas desde cero. En esta sección se describe cómo se implementó la capa OLAP sobre el esquema estrella `dw` de `DentalCenterDB`, de modo que la gerencia de la clínica pueda responder preguntas como dónde, cuándo y en qué especialidades se concentran las ausencias y los ingresos en riesgo.

3.15.1 Enfoque de implementación

Las soluciones OLAP se clasifican según la forma de almacenar los datos: **MOLAP** (cubo multidimensional precalculado), **ROLAP** (las agregaciones se calculan sobre tablas relacionales) y **HOLAP** (combinación de ambos). Dado que el Data Mart ya está modelado como esquema estrella en SQL Server y que su volumen es moderado (del orden de cien mil citas), se adoptó un enfoque **ROLAP**, complementado con un **modelo semántico en Power BI** para la exploración visual. Las razones son las siguientes:

- **Aprovecha el modelo existente.** El esquema estrella Fact_Atenciones + cuatro dimensiones actúa directamente como el cubo, sin duplicar datos en una estructura adicional.
- **No requiere infraestructura adicional.** Las agregaciones se calculan con T-SQL estándar (GROUP BY, ROLLUP, CUBE, PIVOT) y los resultados se actualizan automáticamente cada vez que se ejecuta el ETL.
- **Integra el análisis visual.** Power BI consume el mismo modelo dimensional y permite hacer

drill-down, filtros y segmentaciones de forma interactiva.

Tabla 3.19. *Capas de la implementación OLAP.*

Capa	Componente	Función
Almacenamiento	Esquema dw (Fact_Atenciones y dimensiones)	Almacena los hechos y sus dimensiones; es la base del cubo.
Acceso al cubo	Vista dw.vw_Cubo_Atenciones	Presenta el esquema estrella aplanado, con todas las dimensiones y medidas en una sola estructura.
Consulta OLAP	T-SQL con ROLLUP, CUBE y PIVOT	Ejecuta las operaciones OLAP: *roll-up*, *drill-down*, *slice*, *dice* y *pivot*.
Presentación	Modelo semántico y reportes en Power BI	Medidas DAX, jerarquías y visualizaciones interactivas para los usuarios de negocio.

3.15.2 Definición del cubo

El cubo de atenciones tiene como tabla de hechos dw.Fact_Atenciones (una fila por cita) y cuatro dimensiones. Cada celda del cubo corresponde a la intersección de un valor de cada dimensión —por ejemplo, una especialidad, un barrio y un mes— y contiene las medidas calculadas para ese conjunto de citas.

Figura 3.4. *Cubo OLAP de atenciones con sus dimensiones, jerarquías y medidas.*

Tabla 3.20. *Dimensiones y jerarquías del cubo.*

Dimensión	Jerarquía (niveles)	Atributos adicionales
Tiempo	Año → Trimestre → Mes → Fecha	Dia_Semana, para analizar patrones por día.
Paciente	Barrio → Paciente	Genero y Edad, para segmentar.
Médico	Especialidad → Odontólogo	—
Tratamiento	Tratamiento (descripción)	Duracion_Meses y Costo_Total.

Tabla 3.21. *Medidas del cubo.*

Medida	Cálculo en SQL	Comportamiento
Total de citas	COUNT(*)	Aditiva (conteo).
Citas atendidas	SUM(Es_Atendido)	Aditiva.
Ausencias	SUM(Es_Ausencia)	Aditiva.
% de ausencia	SUM(Es_Ausencia) * 100.0 / COUNT(*)	Calculada; no se suma, se recalcula en cada nivel.

Ingreso estimado	SUM(Monto_Pagado)	Aditiva.
Ingresos en riesgo	SUM(Ingreso_En_Riesgo)	Aditiva; monto de las citas con ausencia.
Espera promedio (min)	AVG(Tiempo_Espera_Min)	No aditiva; se promedia.

3.15.3 Vista de acceso al cubo

Para que las consultas OLAP no repitan en cada ocasión los cuatro *joins* del esquema estrella, se creó la vista dw.vw_Cubo_Atenciones, que reúne en una sola estructura los atributos de todas las dimensiones y las medidas a nivel de cita. La columna Ingreso_En_Riesgo equivale al monto de la cita cuando esta terminó en ausencia, y es la base de la medida de ingresos en riesgo. Las vistas vw_KPI_TasaAbandono y vw_KPI_IngresosEnRiesgo del Script 2 pueden entenderse como cortes ya agregados de este mismo cubo.

Código 3.4. *Vista de acceso al cubo OLAP (dw.vw_Cubo_Atenciones).*

```
CREATE OR ALTER VIEW dw.vw_Cubo_Atenciones AS
SELECT
    f.ID_Hecho, f.IdCita,
    t.Fecha, t.Anio, t.Trimestre, t.Mes, t.NombreMes, t.Dia_Semana,
    p.Barrio, p.Genero, p.Edad,
    m.Especialidad, m.NombreCompleto AS Medico,
    tr.Descripcion AS Tratamiento, tr.Duracion_Meses,
    f.Estado_Cita, f.Tiempo_Espera_Min, f.Monto_Pagado,
    f.Es_Atendido, f.Es_Ausencia,
    CASE WHEN f.Es_Ausencia = 1 THEN f.Monto_Pagado ELSE 0 END AS Ingreso_En_Riesgo
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo      t  ON t.SK_Tiempo       = f.SK_Tiempo
JOIN dw.Dim_Paciente    p  ON p.SK_Paciente     = f.SK_Paciente
JOIN dw.Dim_Medico      m  ON m.SK_Medico       = f.SK_Medico
JOIN dw.Dim_Tratamiento tr ON tr.SK_Tratamiento = f.SK_Tratamiento;
GO
```

Como control de calidad, el número de citas de la vista debe coincidir con el de la tabla de hechos; si ambos valores son iguales, ninguna cita quedó fuera del cubo por falta de una dimensión:

```
SELECT (SELECT COUNT(*) FROM dw.Fact_Atenciones)   AS CitasEnHechos,
       (SELECT COUNT(*) FROM dw.vw_Cubo_Atenciones) AS CitasEnCubo;
```

3.15.4 Operaciones OLAP

Las operaciones OLAP clásicas se implementaron con consultas T-SQL sobre la vista del cubo. La tabla siguiente resume cada operación, su finalidad y la instrucción utilizada.

Tabla 3.22. *Operaciones OLAP implementadas.*

Operación	Qué hace	Implementación en T-SQL
Roll-up	Agrega los datos hacia un nivel superior de la jerarquía (de mes a trimestre y a año).	GROUP BY ROLLUP (Anio, Trimestre, Mes)
Drill-down	Baja a un nivel de mayor detalle (de mes a fecha).	Filtro por año y mes con GROUP BY Fecha.
Slice	Fija un único valor de una dimensión.	WHERE Especialidad = N'Ortodoncia'

Dice	Filtra varias dimensiones a la vez y obtiene un subcubo.	WHERE con IN y BETWEEN sobre varias columnas.
Pivot	Rota los ejes: valores de una dimensión pasan a ser columnas.	Operador PIVOT sobre Dia_Semana.
Cubo completo	Calcula todas las combinaciones de agregación posibles.	GROUP BY CUBE (Especialidad, Trimestre)

Roll-up: de mes a trimestre y a año

ROLLUP produce, en una sola consulta, el detalle por mes, el subtotal por trimestre, el subtotal por año y el total general. La columna NivelAgregacion (GROUPING_ID) indica el nivel de cada fila: 0 para el detalle y valores mayores para los subtotales.

Código 3.5. *Operación roll-up.*

```
USE DentalCenterDB;
GO

SELECT
    CASE WHEN GROUPING(t.Anio) = 1 THEN 'TOTAL HISTÓRICO' ELSE CAST(t.Anio AS VARCHAR) END AS Anio,
    CASE WHEN GROUPING(t.Trimestre) = 1 THEN 'Subtotal Año' ELSE 'Trimestre ' + CAST(t.Trimestre AS VARCHAR) END AS
Trimestre,
    CASE WHEN GROUPING(t.NombreMes) = 1 THEN 'Subtotal Trimestre' ELSE t.NombreMes END AS Mes,
    COUNT(f.ID_Hecho) AS Total_Citas_Programadas,
    SUM(f.Es_Ausencia) AS Total_Abandonos,
    SUM(f.Monto_Pagado) AS Ingresos_Proyectados
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON f.SK_Tiempo = t.SK_Tiempo
GROUP BY ROLLUP (t.Anio, t.Trimestre, t.NombreMes);
```

Resultados | Mensajes

	Anio	Trimestre	Mes	Total_Citas_Programadas	Total_Abandonos	Ingresos_Proyectados
1	2016	Trimestre 2	Abril	3235	633	145575.00
2	2016	Trimestre 2	Junio	26448	4882	1190160.00
3	2016	Trimestre 2	Mayo	80838	16804	3637710.00
4	2016	Trimestre 2	Subtotal Trimestre	110521	22319	4973445.00
5	2016	Subtotal Año	Subtotal Trimestre	110521	22319	4973445.00
6	TOTAL HISTÓRICO	Subtotal Año	Subtotal Trimestre	110521	22319	4973445.00

Drill-down: de mes a fecha

Partiendo de un mes de interés, se desciende al nivel de fecha para identificar los días con mayor ausencia. Los valores de año y mes son parámetros de ejemplo y pueden modificarse.

Código 3.6. *Operación drill-down.*

```
CREATE OR ALTER VIEW dw.vw_Cubo_Atenciones AS
SELECT
    f.ID_Hecho,
    t.Fecha,
    t.Anio,
    t.Mes,
    t.Trimestre,
    t.NombreMes,
    t.Dia_Semana,
    p.Barrio,
    m.Especialidad,
    tr.Descripcion AS Tratamiento,
    f.Tiempo_Espera_Min,
    f.Monto_Pagado,
    f.Es_Atendido,
    f.Es_Ausencia
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON f.SK_Tiempo = t.SK_Tiempo
JOIN dw.Dim_Paciente p ON f.SK_Paciente = p.SK_Paciente
JOIN dw.Dim_Medico m ON f.SK_Medico = m.SK_Medico
JOIN dw.Dim_Tratamiento tr ON f.SK_Tratamiento = tr.SK_Tratamiento;
```

```
GO
```

Slice: una sola especialidad

El *slice* fija una dimensión en un valor concreto y mantiene el resto del cubo. En este caso se analiza la evolución mensual de una única especialidad.

Código 3.7. *Operación slice.*

```
SELECT
    Anio,
    Mes,
    NombreMes,
    COUNT(*) AS TotalCitas,
    SUM(Es_Ausencia) AS Ausencias,
    -- Calculamos el ingreso en riesgo multiplicando la ausencia (1 o 0) por el monto
    SUM(Es_Ausencia * Monto_Pagado) AS IngresosEnRiesgo
FROM dw.vw_Cubo_Atenciones
WHERE Especialidad = N'Ortodoncia'
GROUP BY Anio, Mes, NombreMes
ORDER BY Anio, Mes;
```

	Anio	Mes	NombreMes	TotalCitas	Ausencias	IngresosEnRiesgo
1	2016	4	Abril	1030	200	9000.00
2	2016	5	Mayo	27024	5683	255735.00
3	2016	6	Junio	8827	1647	74115.00

Dice: subcubo por varias dimensiones

El *dice* restringe varias dimensiones simultáneamente: especialidad, género y rango de edad. La cláusula `HAVING` descarta grupos con muy pocas citas, cuyos porcentajes no serían representativos.

Código 3.8. *Operación dice.*

```
CREATE OR ALTER VIEW dw.vw_Cubo_Atenciones AS
SELECT
    f.ID_Hecho,
    t.Fecha,
    t.Anio,
    t.Mes,
    t.Trimestre,
    t.NombreMes,
    t.Dia_Semana,
    p.Barrio,
    p.Genero,       -- AGREGADO PARA EL DICE
    p.Edad,         -- AGREGADO PARA EL DICE
    m.Especialidad,
    tr.Descripcion AS Tratamiento,
    f.Tiempo_Espera_Min,
    f.Monto_Pagado,
    f.Es_Atendido,
    f.Es_Ausencia
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON f.SK_Tiempo = t.SK_Tiempo
JOIN dw.Dim_Paciente p ON f.SK_Paciente = p.SK_Paciente
JOIN dw.Dim_Medico m ON f.SK_Medico = m.SK_Medico
JOIN dw.Dim_Tratamiento tr ON f.SK_Tratamiento = tr.SK_Tratamiento;
GO
```

Pivot: ausencias por especialidad y día de la semana

El *pivot* gira el eje de los días de la semana para mostrarlos como columnas y compararlos lado a lado entre especialidades. Los nombres de los días coinciden con los almacenados en `Dim_Tiempo`, que se generan en español durante el ETL.

Código 3.9. *Operación pivot.*

```
SELECT Especialidad,
       [Lunes], [Martes], [Miercoles], [Jueves], [Viernes], [Sabado], [Domingo]
FROM (
    SELECT Especialidad, Dia_Semana, Es_Ausencia
    FROM dw.vw_Cubo_Atenciones
) AS Origen
PIVOT (
    SUM(Es_Ausencia)
```

```
    FOR Dia_Semana IN ([Lunes], [Martes], [Miercoles], [Jueves], [Viernes], [Sabado], [Domingo])
) AS TablaPivote
ORDER BY Especialidad;
```

	Especialidad	Lunes	Martes	Miercoles	Jueves	Viernes	Sabado	Domingo
1	Endodoncia	1548	1699	NULL	1144	1332	NULL	NULL
2	Odontología General	1548	1700	NULL	1079	1379	NULL	NULL
3	Ortodoncia	1594	1753	NULL	1115	1326	NULL	NULL

Cubo completo: todas las combinaciones

`CUBE` calcula las agregaciones de todas las combinaciones de las columnas indicadas: el detalle por especialidad y trimestre, los totales por especialidad, los totales por trimestre y el total general.

Código 3.10. *Agregación con CUBE.*

```
SELECT
    Especialidad,
    Trimestre,
    COUNT(*) AS TotalCitas,
    -- Reemplazamos Ingreso_En_Riesgo por la fórmula matemática
    SUM(Es_Ausencia * Monto_Pagado) AS IngresosEnRiesgo,
    GROUPING_ID(Especialidad, Trimestre) AS Nivel
FROM dw.vw_Cubo_Atenciones
GROUP BY CUBE (Especialidad, Trimestre)
ORDER BY Nivel, Especialidad, Trimestre;
```

	Especialidad	Trimestre	TotalCitas	IngresosEnRiesgo	Nivel
1	Endodoncia	2	36793	333765.00	0
2	Odontología General	2	36847	331740.00	0
3	Ortodoncia	2	36881	338850.00	0
4	Endodoncia	NULL	36793	333765.00	1
5	Odontología General	NULL	36847	331740.00	1
6	Ortodoncia	NULL	36881	338850.00	1
7	NULL	2	110521	1004355.00	2
8	NULL	NULL	110521	1004355.00	3

3.15.5 Optimización del rendimiento

Al ser un cubo ROLAP, cada consulta recalcula las agregaciones sobre la tabla de hechos. Para acelerar este tipo de consultas analíticas, que leen pocas columnas sobre muchas filas, se propone un índice *columnstore* no agrupado sobre las columnas que intervienen en los cálculos.

Código 3.11. *Índice columnstore sobre la tabla de hechos.*

```
CREATE NONCLUSTERED COLUMNSTORE INDEX NCCI_Fact_Atenciones
ON dw.Fact_Atenciones (
    SK_Paciente, SK_Medico, SK_Tratamiento, SK_Tiempo,
    Estado_Cita, Tiempo_Espera_Min, Monto_Pagado, Es_Atendido, Es_Ausencia
);
```

Dado que el Script 1 elimina y vuelve a crear las tablas del Data Mart, este índice debe crearse después de la carga inicial, y conviene recrearlo cuando se reconstruya la estructura.

3.15.6 Modelo semántico en Power BI

Para la exploración visual, Power BI se conecta a las tablas del esquema `dw` y reproduce el cubo mediante un modelo semántico: las relaciones del esquema estrella, las jerarquías de cada dimensión y las medidas calculadas en DAX.

Tabla 3.23. *Relaciones del modelo semántico.*

Tabla (lado 1)	Tabla (lado N)	Columna y cardinalidad
Dim_Paciente	Fact_Atenciones	SK_Paciente; uno a muchos.
Dim_Medico	Fact_Atenciones	SK_Medico; uno a muchos.
Dim_Tratamiento	Fact_Atenciones	SK_Tratamiento; uno a muchos.
Dim_Tiempo	Fact_Atenciones	SK_Tiempo; uno a muchos.
Resultados_Prediccion_IA	Fact_Atenciones	IdCita; uno a uno, para cruzar el riesgo predicho con las dimensiones.

En el modelo, Dim_Tiempo se marca como tabla de fechas (columna Fecha) y se define la jerarquía de calendario Año → Trimestre → Mes → Fecha. El nombre del mes se ordena por la columna Mes, y el día de la semana por una columna numérica auxiliar, de modo que las visualizaciones respeten el orden cronológico en lugar del alfabético.

Tabla 3.24. *Medidas DAX del modelo.*

Medida	Expresión DAX	Descripción
Total Citas	`COUNTROWS(Fact_Atenciones)`	Número de citas.
Citas Atendidas	`SUM(Fact_Atenciones[Es_Atendido])`	Citas a las que el paciente asistió.
Ausencias	`SUM(Fact_Atenciones[Es_Ausencia])`	Citas a las que el paciente no asistió.
% Ausencia	`DIVIDE([Ausencias], [Total Citas])`	Tasa de abandono.
Ingreso Estimado	`SUM(Fact_Atenciones[Monto_Pagado])`	Ingreso total de las citas.
Ingresos en Riesgo	`CALCULATE(SUM(Fact_Atenciones[Monto_Pagado]), Fact_Atenciones[Es_Ausencia] = 1)`	Monto de las citas con ausencia.
Espera Promedio (min)	`AVERAGE(Fact_Atenciones[Tiempo_Espera_Min])`	Tiempo de espera promedio.

Con este modelo, el usuario puede hacer *drill-down* sobre la jerarquía de tiempo, segmentar por barrio, especialidad o tratamiento, y combinar los indicadores históricos con la probabilidad de ausencia calculada por el modelo de inteligencia artificial, que alimenta además el simulador financiero (*What-If*) del tablero.

[Insertar aquí la captura del modelo de relaciones de Power BI]

[Insertar aquí la captura de una matriz o tablero de Power BI con drill-down por año, trimestre y mes]

3.15.7 Preguntas de negocio que responde el cubo

La siguiente tabla relaciona preguntas de gestión de la clínica con la operación OLAP que las resuelve.

Tabla 3.25. *Preguntas de negocio y operación OLAP asociada.*

Pregunta de negocio	Operación	Dimensiones involucradas
¿Cómo evoluciona la tasa de ausencia de mes a mes, por trimestre y por año?	Roll-up	Tiempo
¿Qué días concretos de un mes concentran más ausencias?	Drill-down	Tiempo
¿Cuántos ingresos se pierden en una especialidad determinada?	Slice	Médico, Tiempo
¿En qué barrios es más alta la ausencia de mujeres jóvenes atendidas en endodoncia y ortodoncia?	Dice	Médico, Paciente
¿Qué especialidad tiene más ausencias los lunes frente a los viernes?	Pivot	Médico, Tiempo
¿Cuál es el total general, por especialidad y por trimestre, de ingresos en riesgo?	Cube	Médico, Tiempo

3.16 Campos calculados y KPI.
3.17 Diseño de dashboards y reportes.
3.18 Módulo de Machine Learning.

Para abordar la retención de pacientes, el problema se modeló como una tarea de aprendizaje supervisado de clasificación binaria. El objetivo fue predecir si un paciente completaría su tratamiento (Clase 0) o lo abandonaría (Clase 1), utilizando el historial clínico y transaccional consolidado en el Data Mart.

Selección y Preparación de Datos

Se extrajo la sábana de datos consolidada cruzando la tabla de hechos *Fact_Atenciones* con las dimensiones de Paciente y Tratamiento. Durante el Análisis Exploratorio de Datos (EDA), se evaluaron variables como el tiempo promedio de espera, las ausencias acumuladas, la edad del paciente y el porcentaje del monto pagado respecto al costo total del tratamiento. La variable objetivo, *Target_Abandono*, se definió empíricamente: si la proporción de ausencias de un paciente supera el 25% del total de sus citas programadas, se etiquetó como abandono (Clase 1).

Comparación de Algoritmos

El conjunto de datos se dividió en entrenamiento (80%) y validación (20%), aplicando estratificación para mantener la proporción de la clase minoritaria (abandonos). Se entrenaron y evaluaron dos algoritmos supervisados:

- Regresión Logística: Seleccionada como modelo base (baseline) por su interpretabilidad matemática y simplicidad computacional.
- Random Forest: Seleccionado por su capacidad intrínseca para manejar variables con distribuciones no normales y capturar interacciones complejas no lineales entre predictores,

común en el comportamiento humano.

Justificación y Selección del Modelo

La evaluación no se limitó a la exactitud global (Accuracy), sino que se priorizó el Recall (Sensibilidad). En el contexto del centro dental, el costo de oportunidad de perder un paciente sin intentar retenerlo (Falso Negativo) es significativamente mayor que el esfuerzo operativo de realizar una llamada de seguimiento a un paciente que finalmente sí iba a continuar (Falso Positivo).

Tras evaluar las métricas en el conjunto de prueba, Random Forest demostró un desempeño superior, especialmente en la métrica F1-score (que equilibra Precision y Recall). Adicionalmente, este algoritmo permitió extraer la importancia de las variables (Feature Importance), confirmando cuantitativamente que factores como el "*Costo_Tratamiento*" y el "*Prom_Tiempo_Espera*" son los determinantes principales del abandono, alineándose con estudios previos en clínicas odontológicas (Meza Rincón, 2025).

Integración y Scoring Predictivo

El modelo Random Forest entrenado se utilizó para calificar (scoring) a todos los pacientes activos. Las predicciones probabilísticas (de 0.0 a 1.0) se categorizaron en tres niveles de alerta: Riesgo Alto (> 0.65), Riesgo Medio (0.35 - 0.64) y Riesgo Bajo (< 0.35). Estos resultados se inyectaron directamente en la tabla *Resultados_Prediccion_IA* del Data Mart, permitiendo que el dashboard de Power BI consuma esta clasificación para habilitar el simulador de retornos económicos y la toma de decisiones gerenciales.

3.19 Integración BI + IA.

3.20 Resultados y recomendaciones.

Referencias Bibliográficas

[1] E. E. Arosemena Doss, “Indicadores claves de desempeño y su aplicación en la gerencia estratégica de las empresas de salud,” *Odontología Vital*, vol. 2, no. 37, pp. 50–66, 2022. [En línea]. Disponible en: https://www.scielo.sa.cr/pdf/odov/n37/1659-0775-odov-37-50.pdf

[2] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[3] S. Chaudhuri and U. Dayal, “An overview of data warehousing and OLAP technology,” *ACM SIGMOD Record*, vol. 26, no. 1, pp. 65–74, 1997, doi: 10.1145/248603.248616.

[4] J. Curto Díaz and J. Conesa Caralt, *Introducción al business intelligence*. Barcelona, España: Editorial UOC, 2010.

[5] J. Hernández Orallo, M. J. Ramírez Quintana, and C. Ferri Ramírez, *Introducción a la minería de datos*. Madrid, España: Pearson Educación, 2004.

[6] M. D. Hernández Ramírez, “Procedimiento para el desarrollo de un sistema de inteligencia de negocios en la gestión de ensayos clínicos en el Centro de Inmunología Molecular,” *Revista Cubana de Información en Ciencias de la Salud*, vol. 22, no. 4, pp. 349–361, 2011. [En línea]. Disponible en:

https://acimed.sld.cu/index.php/acimed/article/download/208/183/1603

[7] R. S. Kaplan and D. P. Norton, *El cuadro de mando integral*, 2.ª ed. Barcelona, España: Gestión 2000, 2000.

[8] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Hoboken, NJ, USA: Wiley, 2013.

[9] A. J. Meza Rincón, "Factores vinculados al abandono del tratamiento dental en una clínica odontológica docente, Lima 2024," tesis de licenciatura, Universidad Privada Norbert Wiener, Lima, Perú, 2025. [En línea]. Disponible en: https://hdl.handle.net/20.500.13053/13269

[10] E. Prada Madrid, "Los insumos invisibles de decisión: Datos, información y conocimiento," *Anales de Documentación*, vol. 11, pp. 183–196, 2008. [En línea]. Disponible en: https://revistas.um.es/analesdoc/article/view/24881

[11] G. R. Rivadera, "La metodología de Kimball para el diseño de almacenes de datos (Data warehouses)," *Cuadernos de Ingeniería*, no. 5, pp. 56–71, 2010. [En línea]. Disponible en: https://revistas.ucasal.edu.ar/index.php/CI/article/view/169

[12] H. M. Rodríguez Rey, A. León Quintela, and M. L. Duque de Estrada Bertot, "Principales causas relacionadas con el abandono del tratamiento ortodóncico por escolares y adultos jóvenes según tipos de aparatos utilizados," *MEDISAN*, vol. 21, no. 3, pp. 321–329, 2017. [En línea]. Disponible en: https://medisan.sld.cu/index.php/san/article/download/1334/pdf

[13] C. I. Valenzuela-Núñez, F. H. Troncoso-Espinosa, and G. O. Latorre-Núñez, "Predicción del ausentismo en citas médicas mediante Machine Learning," *Universidad, Ciencia y Tecnología*, vol. 27, no. 120, pp. 19–30, 2023, doi: 10.47460/uct.v27i120.728.