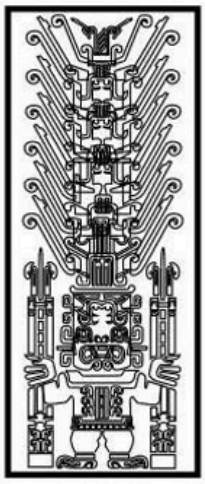
“Año de la Esperanza y el Fortalecimiento de la Democracia”



Universidad Nacional
**Federico Villarreal**

FACULTAD DE INGENIERÍA ELECTRÓNICA E INFORMÁTICA - FIEI
ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA


**ESTUDIANTES:**

- Borromeo Quispe Allimson
- Huere Marchan Manfred Hober
- Lozano Villalobos Alex
- Pacheco Anton Fátima
- Pauca Muñoz Fabrizzio


**CURSO:** Gestión y Análisis de Datos e Información

**PROFESOR:** Ivan Crispin Sanchez

**FECHA DE ENTREGA:** lunes 13 de octubre de 2026

2026

# Sistema Inteligente de Gestión, Predicción y Fidelización de Pacientes para un Centro Dental

Informe final — Introducción y Capítulos I y II · Gestión y Análisis de Datos e Información · FIEI-UNFV 2026 ··

## Introducción

### Presentación del proyecto

El proyecto "Sistema Inteligente de Gestión, Predicción y Fidelización de Pacientes para un Centro Dental" integra gestión de datos, inteligencia de negocios (BI) y aprendizaje automático en una sola solución. Parte de una base transaccional (OLTP) en SQL Server con pacientes, citas, tratamientos, pagos y médicos. Mediante un proceso ETL, esa información alimenta un DataMart dimensional, sobre el cual se construyen indicadores, análisis OLAP, un dashboard en Power BI y un modelo que estima el riesgo de abandono de cada paciente.

El objetivo general es apoyar las decisiones del centro dental con información histórica integrada y con predicciones que permitan actuar antes de que el paciente abandone su tratamiento.

### Problema identificado

Muchos tratamientos odontológicos (ortodoncia, endodoncia, rehabilitación) requieren varias citas a lo largo de semanas o meses. Cuando el paciente deja de asistir, el tratamiento queda incompleto: el paciente no logra el resultado clínico previsto y el centro deja de percibir los ingresos pendientes de ese tratamiento.

En el escenario analizado, el centro detecta estos casos tarde, cuando el paciente ya lleva semanas sin venir. La información de citas, asistencia, tiempos de espera y pagos vive en registros operativos que no se analizan en conjunto, y no existe un criterio objetivo para decidir a qué paciente contactar primero. El problema de decisión es: **¿qué pacientes en tratamiento tienen mayor riesgo de abandonarlo y qué acción de fidelización conviene aplicar a cada uno?**

### Importancia de la solución

- **Clínica:** favorece la continuidad de los tratamientos y, con ella, el resultado esperado para el paciente.
- **Económica:** permite priorizar las llamadas y campañas según el riesgo de abandono y el monto pendiente de cada tratamiento, y estimar el retorno de esas acciones con un simulador What-If.
- **De gestión:** reemplaza reportes aislados por indicadores consolidados con trazabilidad desde la base transaccional hasta el dashboard.
- **Académica:** demuestra la integración de DataMart, ETL, OLAP, KPI, BI y Machine Learning que exige el proyecto final del curso.

### Alcance general

El proyecto incluye: (1) una base transaccional en SQL Server con registros históricos simulados del centro; (2) un DataMart en esquema estrella; (3) el proceso ETL; (4) indicadores, consultas OLAP y KPI; (5) un módulo de Machine Learning en Python que compara Regresión Logística y Random Forest para clasificar el riesgo de abandono en Alto, Medio y Bajo; y (6) un dashboard en Power BI de tres páginas (ejecutiva, predictiva y simulador What-If).

Queda fuera del alcance la historia clínica detallada, la facturación electrónica, el envío real de mensajes a pacientes y cualquier diagnóstico odontológico. Los datos son simulados y no corresponden a pacientes reales.

# Capítulo I: Generalidades

## 1.1 Descripción dc la organización

El caso de estudio es **Clínica Dental Sonrisa Integral**, un centro odontológico privado de atención ambulatoria ubicado en Lima, Perú. Se trata de un caso simulado: el nombre y los datos descriptivos son ficticios, y se construyeron para representar la operación típica de un centro dental de tamaño mediano.

El centro ofrece odontología general, ortodoncia, endodoncia, rehabilitación oral y odontopediatría, y atiende con cita previa a pacientes particulares. Parte de sus ingresos proviene de tratamientos de varias sesiones que el paciente paga en cuotas, por lo que la asistencia continua del paciente influye directamente en lo que el centro llega a cobrar.

Sus procesos principales son el agendamiento de citas, la atención clínica, el cobro de las cuotas y el seguimiento del paciente.

## 1.2 Historia, misión, visión y valores

**Historia.** El centro fue fundado por un grupo de cirujanos dentistas con dos consultorios y una sola especialidad. Con los años incorporó ortodoncia, endodoncia, rehabilitación oral y odontopediatría, y hoy opera con seis consultorios. Al crecer el número de pacientes y de tratamientos de larga duración, el control de citas y pagos en registros separados dejó de ser suficiente para gestionar el negocio.

**Misión.** Brindar atención odontológica integral, segura y cercana, acompañando a cada paciente hasta completar su tratamiento.

**Visión.** Ser un centro dental de referencia en Lima por la continuidad y la calidad de sus tratamientos, apoyándose en información confiable para decidir.

**Valores.**

- Empatía con el paciente
- Responsabilidad clínica
- Transparencia en costos y plazos

- Confidencialidad de los datos del paciente
- Mejora continua

### 1.3 Organización y organigrama

La Dirección General coordina dos áreas: la Dirección Clínica, que reúne a los odontólogos y especialistas, y Atención al Paciente y Administración, donde se aplica el proyecto.

**El proyecto se aplica en Atención al Paciente y Administración**

Resaltada: el área donde se aplica el proyecto




organigrama · 2 áreas, 6 unidades

El organigrama muestra solo las unidades que participan en el proceso de citas y tratamientos.

## 1.4 Área involucrada

El proyecto interviene en el área de **Atención al Paciente y Administración**, que concentra el agendamiento de citas, la recepción, el cobro de cuotas y el seguimiento posterior a la atención. Los usuarios de la solución son la Dirección General y la Jefatura de Atención al Paciente, que deciden a qué pacientes contactar y qué campañas de fidelización realizar.

Los datos que esta área genera son la materia prima del DataMart y del modelo predictivo:

| Dato | Dónde se registra | Uso en el proyecto |
|---|---|---|
| Citas y asistencia | Agenda de recepción | Asistencias, ausencias y días desde la última cita |
| Tiempo de espera | Recepción (hora de llegada y hora de ingreso al consultorio) | Minutos de espera por atención |
| Pagos | Caja | Monto cobrado y porcentaje del tratamiento pagado |
| Estado del tratamiento | Odontólogo tratante | Completado, Abandonado o En curso (variable objetivo del modelo) |

## 1.5 Descripción del proceso

El proceso analizado es la **gestión de citas y el seguimiento de tratamientos**. Va desde que el paciente acepta un plan de tratamiento hasta que lo completa o deja de asistir:

1. **Registro y plan de tratamiento.** El odontólogo define el tratamiento, su costo total y el número estimado de citas, y recepción registra al paciente.
2. **Agendamiento.** Recepción programa las citas en la agenda del consultorio.
3. **Recepción y espera.** El paciente llega, registra su ingreso y espera hasta ser llamado.
4. **Atención clínica.** El odontólogo realiza el procedimiento y anota la evolución.
5. **Cobro.** El paciente paga en caja la cuota que corresponde a la sesión.
6. **Siguiente cita.** Se programa la próxima sesión, hasta completar el tratamiento.
7. **Seguimiento.** Si el paciente falta, recepción intenta contactarlo.

Cada paso deja datos que alimentan el análisis: asistencia o ausencia, minutos de espera y monto cobrado. De ese conjunto sale la tabla de hechos del DataMart, con una fila por atención.

## 1.6 Diagrama AS-IS

En el proceso actual, el centro agenda, atiende y cobra sin una vista consolidada del paciente. Cuando alguien falta, la reacción depende de qué recepción revise la agenda y decida a quién llamar.



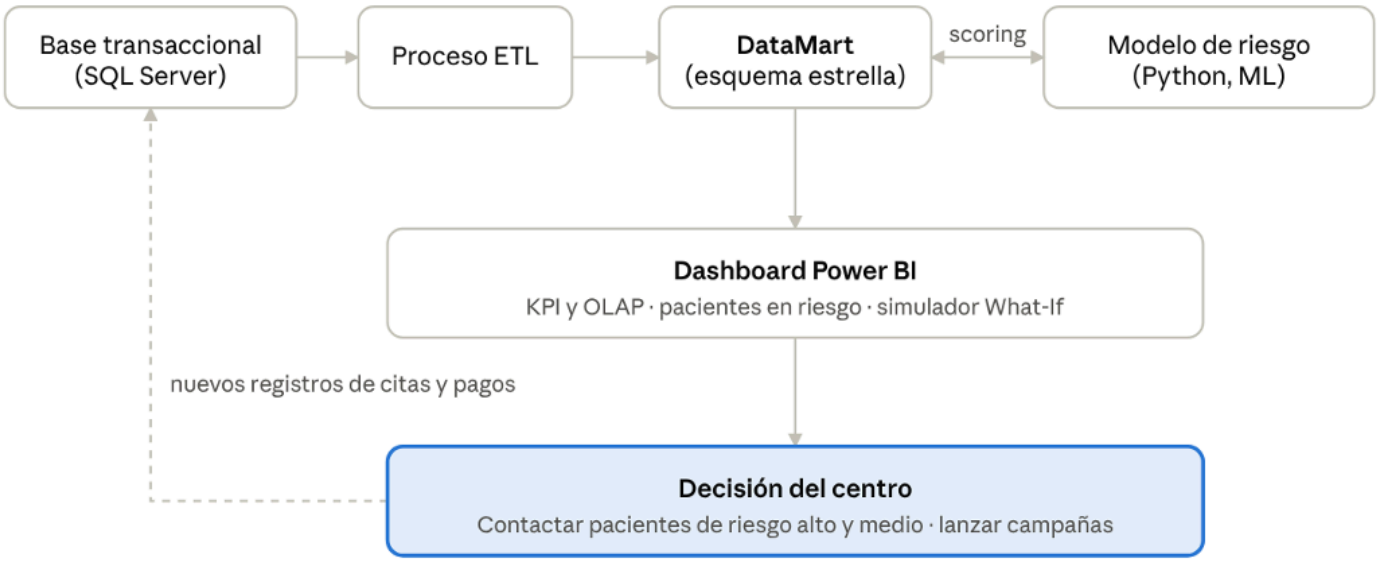

proceso AS-IS · 6 pasos, 1 decisión

La ruta de la inasistencia no tiene alertas ni prioridades, y por eso puede terminar en un tratamiento abandonado.

## 1.7 Propuesta TO-BE

La propuesta conecta la operación con el análisis: los registros de citas, esperas y pagos se integran en un DataMart, el modelo calcula el riesgo de abandono de cada paciente en tratamiento y el dashboard lo pone a disposición de quien decide.

**Con el sistema, el centro actúa antes de que el paciente abandone**




proceso TO-BE · 6 componentes

El modelo devuelve al DataMart la probabilidad y el nivel de riesgo (Alto, Medio, Bajo), que Power BI muestra junto con los KPI. Con esa lista, el centro puede contactar primero a los pacientes de mayor riesgo y estimar con el simulador What-If el efecto de recuperar una parte de ellos. Los nuevos registros de citas y pagos vuelven a alimentar el ciclo.

# Capítulo II: Proyecto o tarea académica (marco teórico)

## 2.1 Inteligencia de negocios

La inteligencia de negocios (BI, por sus siglas en inglés) es el conjunto de estrategias, procesos y herramientas que transforman los datos de una organización en información útil para decidir (Curto Díaz & Conesa Caralt, 2010). Hernández Ramírez (2011) lo describe como un conjunto de conceptos y métodos para mejorar el proceso de decisión, normalmente construido sobre un almacén de datos. Sus componentes habituales son las fuentes de datos, el proceso ETL, el almacén de datos, el análisis multidimensional (OLAP) y los cuadros de mando que presentan los resultados al usuario de negocio.

Una solución de BI responde sobre todo a qué pasó y por qué pasó. Este proyecto la complementa con Machine Learning para estimar qué puede pasar, de modo que el análisis descriptivo y el predictivo conviven en un mismo dashboard.

## 2.2 Data Warehouse y DataMart

Un Data Warehouse (almacén de datos) es una colección de datos integrada e histórica, construida para apoyar el análisis y la toma de decisiones (Rivadera, 2010; Chaudhuri & Dayal, 1997). Un DataMart es un repositorio similar, pero limitado a un área o proceso del negocio, y esa delimitación es su principal diferencia con el almacén completo (Rivadera, 2010).

Los datos llegan al almacén mediante un proceso de extracción, transformación y carga (ETL) que los limpia y los homogeniza antes de cargarlos (Chaudhuri & Dayal, 1997). La tabla resume en qué se diferencia del sistema transaccional del que provienen.

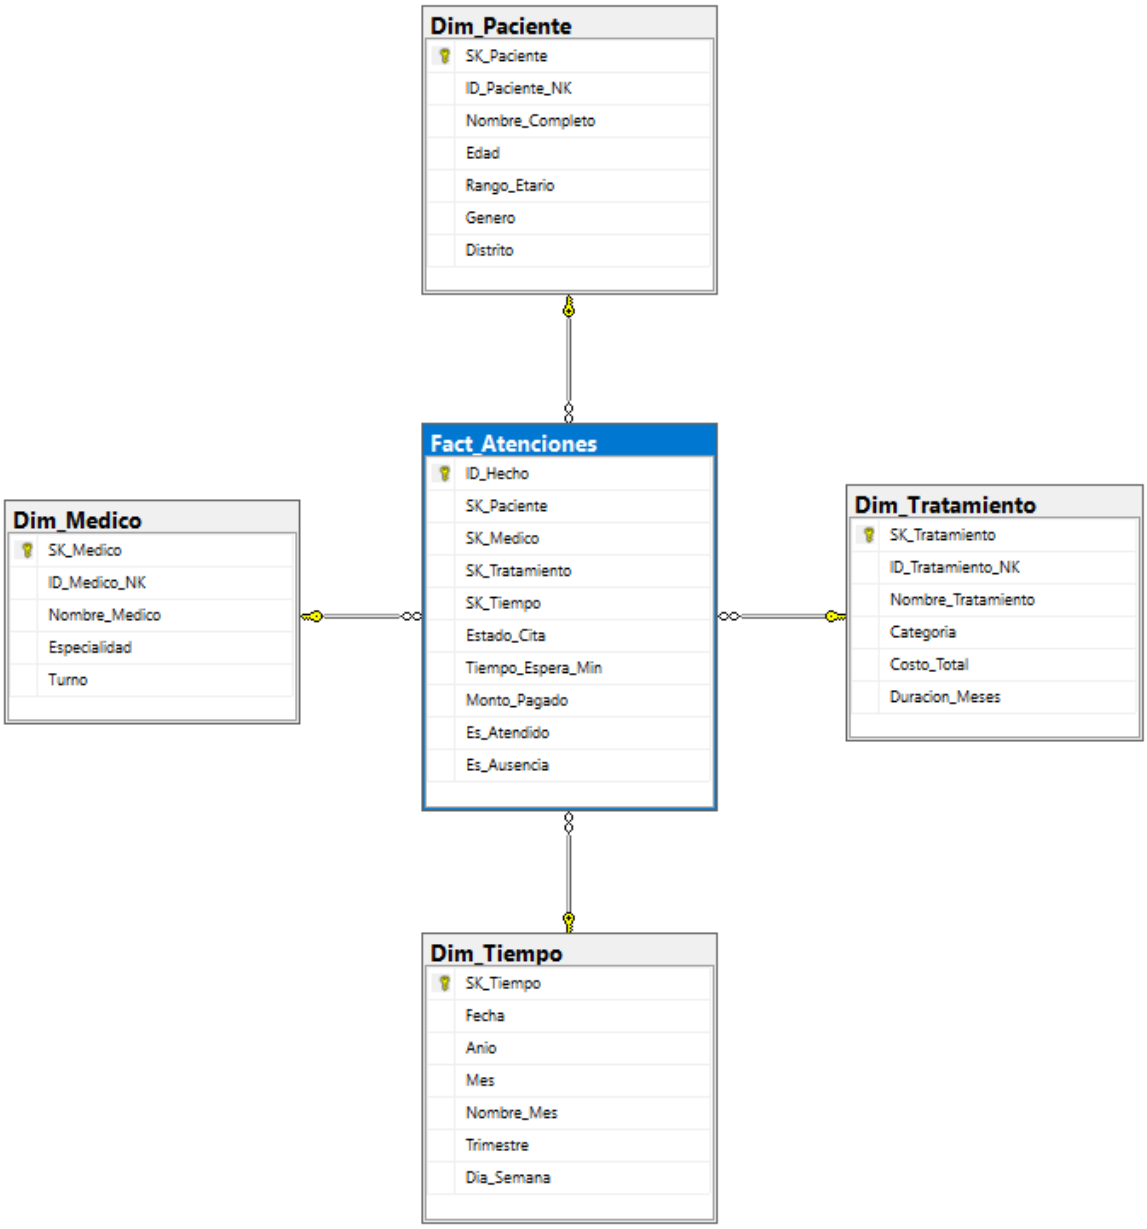
| Característica | Base transaccional (OLTP) | DataMart (OLAP) |
|---|---|---|
| Propósito | Registrar la operación diaria | Analizar para decidir |
| Datos | Actuales, detallados | Históricos, integrados |
| Estructura | Normalizada, muchas tablas | Dimensional, hechos y dimensiones |
| En el proyecto | Pacientes, citas, tratamientos, pagos | Atenciones, indicadores y riesgo de abandono |

## 2.3 Modelos dimensionales

El modelado dimensional organiza los datos en tablas de hechos, que guardan las medidas de un evento del negocio, y tablas de dimensiones, que aportan el contexto para analizarlas: quién, qué, cuándo (Kimball & Ross, 2013). Cuando una tabla de hechos queda al centro y las dimensiones a su alrededor, el modelo se conoce como esquema estrella. Si las dimensiones se normalizan en varias tablas, se obtiene un esquema copo de nieve.

Kimball y Ross (2013) proponen diseñar el modelo con cuatro decisiones, en este orden: el proceso de negocio, la granularidad, las dimensiones y los hechos. Para este proyecto, el proceso es la atención al

paciente y la granularidad es una fila por atención. El diseño preliminar se muestra a continuación y se detalla en el Capítulo III.




esquema estrella preliminar · 1 hecho, 4 dimensiones

Las medidas viven en la tabla de hechos; las dimensiones permiten filtrarlas y agruparlas.

## 2.4 Datos, información y conocimiento

La inteligencia de negocios se apoya en distinguir tres niveles: los datos, la información y el conocimiento, y en cómo cada uno contribuye a decidir mejor dentro de una organización (Prada Madrid, 2008). La tabla los define con un ejemplo del centro dental.

| Nivel | Qué es | Ejemplo en el centro dental |
|---|---|---|
| Dato | Registro aislado, sin contexto | 35 |
| Información | Dato con contexto y significado | La espera promedio en ortodoncia fue de 35 minutos en marzo |
| Conocimiento | Comprensión que permite actuar | Los pacientes con esperas largas y pagos atrasados tienden a abandonar, por lo que conviene contactarlos primero |

En el proyecto, el ETL convierte registros en datos limpios, el DataMart y los KPI los vuelven información, y el modelo predictivo junto con las recomendaciones busca producir conocimiento accionable. El patrón del ejemplo es una hipótesis que el modelo debe confirmar con los datos.

## 2.5 Dimensiones, medidas, jerarquías y granularidad

Estos cuatro conceptos son la base del diseño de un DataMart (Kimball & Ross, 2013). La tabla los define y los ilustra con el caso del centro dental.

| Concepto | Definición | Ejemplo en el proyecto |
|---|---|---|
| Dimensión | Tabla con los atributos que describen el contexto de un hecho | Paciente, tratamiento, tiempo, médico |
| Medida | Valor numérico que se agrega o se compara | Monto cobrado, minutos de espera, asistencias, ausencias |
| Jerarquía | Niveles de una dimensión, de lo general a lo detallado | Día, mes, trimestre, año |
| Granularidad | Nivel de detalle de cada fila de la tabla de hechos | Una fila por atención del paciente |

La granularidad se fija antes que las dimensiones y las medidas, porque de ella depende qué preguntas puede responder el modelo. Con una fila por atención, el DataMart permite agregar hacia arriba (por mes o por médico) sin perder el detalle de cada cita.

## 2.6 Cubos OLAP

Un cubo OLAP organiza las medidas según varias dimensiones a la vez, por ejemplo el monto cobrado por mes, por tratamiento y por médico (Chaudhuri & Dayal, 1997). Sobre ese cubo se aplican operaciones que permiten explorar los datos sin escribir una consulta distinta para cada pregunta.

| Operación | Qué hace | Ejemplo en el centro dental |
|---|---|---|
| Roll-up | Agrega a un nivel superior de la jerarquía | Pasar de ingresos por mes a ingresos por trimestre |
| Drill-down | Baja a un nivel más detallado | Pasar de ingresos por tratamiento a ingresos por médico |
| Slice | Fija un valor de una dimensión | Ver solo los pacientes de ortodoncia |
| Dice | Selecciona un subcubo con varias dimensiones | Ortodoncia y endodoncia durante un trimestre |
| Pivot | Rota los ejes del análisis | Cambiar tratamientos por filas y meses por columnas |

En este proyecto, el análisis OLAP se implementa con consultas agregadas en T-SQL sobre el DataMart y con las jerarquías y filtros del modelo de Power BI.

## 2.7 Indicadores de gestión y KPI

Un indicador clave de desempeño (KPI) es una medida ligada a los factores críticos de éxito de una organización, que permite saber si se cumplen sus objetivos y decidir a tiempo (Arosemena Doss, 2022). El cuadro de mando integral propone observarlos desde cuatro perspectivas: financiera, clientes, procesos internos y aprendizaje y crecimiento (Kaplan & Norton, 2000). Para consultorios dentales y de salud privados, Arosemena Doss (2022) sugiere indicadores como la tasa de inasistencia de pacientes y la tasa de aceptación de tratamientos.

La tabla muestra los KPI de referencia para este proyecto. Su definición final, con metas y fuentes, se presenta en el Capítulo III.

| KPI | Fórmula | Perspectiva | Pregunta de negocio |
|---|---|---|---|
| Tasa de inasistencia | Citas con falta ÷ citas programadas | Procesos internos | ¿Cuántas citas se pierden? |
| Tasa de abandono | Tratamientos abandonados ÷ (completados + abandonados) | Clientes | ¿Cuántos pacientes no terminan su tratamiento? |
| Porcentaje cobrado | Monto cobrado ÷ costo total del tratamiento | Financiera | ¿Cuánto del ingreso previsto se ha cobrado? |
| Tiempo medio de espera | Minutos de espera ÷ número de atenciones | Clientes | ¿Cuánto espera el paciente? |

## 2.8 Machine Learning e Inteligencia Artificial

La inteligencia artificial reúne técnicas que permiten a un sistema realizar tareas que normalmente requieren inteligencia humana. El aprendizaje automático (Machine Learning) es la parte de la IA en la que el modelo aprende patrones a partir de los datos,en lugar de seguir reglas escritas a mano (Hernández Orallo et al., 2004).

**Aprendizaje supervisado y no supervisado.** En el aprendizaje supervisado, cada registro de entrenamiento incluye la respuesta correcta (la variable objetivo) y el modelo aprende a predecirla. En el no supervisado no existe esa respuesta y el modelo busca estructura, como grupos de registros parecidos (Hernández Orallo et al., 2004).

**El problema del proyecto.** Es un problema de clasificación supervisada. La variable objetivo indica si el tratamiento terminó abandonado o completado, dato que se conoce en los tratamientos ya cerrados. El modelo se entrena con ese historial y luego se aplica a los pacientes que siguen en tratamiento, cuyo desenlace aún no se conoce.

**Regresión logística.** Estima la probabilidad de abandono a partir de las variables de entrada mediante la función logística:

$$P(\text{abandono} = 1 \mid x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k)}}$$

Cada coeficiente indica cómo cambia esa probabilidad cuando varía una variable, lo que facilita la interpretación.

**Random Forest.** Es un conjunto de muchos árboles de decisión, entrenados con muestras aleatorias de los datos y de las variables, cuya clase final se decide por votación (Breiman, 2001). Suele captar relaciones no lineales y permite medir qué variables pesan más en la predicción.

**Evaluación.** Los dos modelos se comparan sobre un conjunto de prueba que no se usó para entrenar, con las métricas de la tabla, y no por apreciación visual.

| Métrica | Qué mide | Por qué importa en este caso |
|---|---|---|
| Accuracy | Proporción de aciertos sobre el total | Da una vista general, pero engaña si pocos pacientes abandonan |
| Precisión | De los pacientes marcados en riesgo, cuántos abandonan de verdad | Evita gastar llamadas en pacientes que no lo necesitan |
| Recall | De los pacientes que abandonan, cuántos detecta el modelo | Evita perder pacientes sin haberlos contactado |
| F1-score | Media armónica de precision y recall | Resume ambos valores para comparar modelos |
| Matriz de confusión | Conteo de verdaderos y falsos positivos y negativos | Muestra qué tipo de error comete cada modelo |

**Variables de entrada.** El modelo usa variables como los días desde la última cita, el tiempo de espera, el porcentaje del tratamiento pagado y las faltas acumuladas. Un estudio en una clínica odontológica docente de Lima, con 160 pacientes, encontró que el factor económico (30 %), la calidad del servicio (29,4 %) y el tiempo de espera (28,1 %) fueron los más vinculados al abandono (Meza Rincón, 2025). Eso respalda incluir el pago y la espera entre las variables. En un estudio sobre ortodoncia en escolares y adultos jóvenes de Santiago de Cuba, haber faltado a seis o más citas se asoció con el abandono del tratamiento (Rodríguez Rey et al., 2017), lo que respalda incluir las faltas acumuladas.

**Fuga de información.** Las variables se calculan solo con información anterior a una fecha de corte, y la etiqueta se define con lo que ocurre después. Así se evita la fuga de información (data leakage), que ocurre cuando una variable ya contiene la respuesta y produce métricas poco realistas. Además, la separación entre entrenamiento y prueba se hace por paciente, sin repetir a un mismo paciente en ambos conjuntos.

**Antecedente.** Valenzuela-Núñez et al. (2023) predijeron el ausentismo a citas médicas en un hospital regional de Chile con cinco algoritmos supervisados, entre ellos la regresión logística, y dividieron los datos de forma temporal entre entrenamiento y prueba. El mejor modelo fue una máquina de vectores de soporte, con un AUC de 85,1 %. Su enfoque respalda comparar varios algoritmos con métricas y separar los datos por fecha.

**Segmentación.** Los algoritmos de clustering agrupan pacientes con comportamientos parecidos sin necesitar etiquetas. Pueden servir como complemento para describir perfiles, pero no reemplazan al clasificador: sus grupos no tienen un nivel de riesgo asociado y no se evalúan con las métricas anteriores.

# Capítulo III: Desarrollo de la solución

## 3.1 Análisis de requerimientos.

El desarrollo del Sistema Inteligente de Gestión, Predicción y Fidelización de Pacientes se fundamenta en requerimientos estructurados en cuatro dimensiones clave para garantizar la alineación entre las necesidades clínicas, operativas y tecnológicas.

Requerimientos de Negocio

- Identificar de manera proactiva a los pacientes en tratamiento odontológico que presentan un alto riesgo de abandono antes de su finalización clínica.
- Priorizar las gestiones del área de Atención al Paciente y Administración (llamadas, recordatorios, campañas) basándose en un criterio objetivo de riesgo y el monto financiero pendiente de cada tratamiento.
- Estimar el impacto y retorno financiero de las acciones de fidelización mediante un simulador de escenarios (What-If) que cuantifique los ingresos recuperables.
- Reemplazar la revisión manual de agendas operativas por una vista consolidada que permita una toma de decisiones informada por parte de la Dirección General y la Jefatura de Atención al Paciente.

Requerimientos de Información y Analítica

- Disponer de indicadores clave de desempeño (KPI) históricos y actuales, tales como la tasa de inasistencia, tasa de abandono, porcentaje cobrado y tiempo medio de espera.
- Habilitar el análisis multidimensional (OLAP) de las atenciones filtrado por dimensiones descriptivas: tiempo (año, trimestre, mes, día de la semana), paciente (demografía, barrio), médico (especialidad) y tratamiento (costo, duración).
- Mantener la trazabilidad total de la información, permitiendo navegar desde las métricas agregadas del dashboard hasta el nivel atómico de cada cita médica.

Requerimientos Predictivos (Machine Learning)

- Implementar un modelo de clasificación supervisada capaz de calcular la probabilidad probabilística de que un paciente abandone el tratamiento (Target_Abandono).
- Desplegar un algoritmo (Random Forest) que maneje relaciones no lineales, soporte distribuciones no normales y permita extraer cuantitativamente la importancia de las variables (Feature Importance).
- Categorizar los resultados predictivos en niveles de alerta accionables (Riesgo Alto, Medio, Bajo) para facilitar la lectura por parte del usuario final.
- Evaluar el rendimiento del modelo priorizando la métrica de Sensibilidad (Recall) para minimizar los falsos negativos, dado el alto costo de oportunidad de perder un paciente sin intentar retenerlo.

Requerimientos Técnicos y de Arquitectura

- Construir la solución centralizada sobre un motor de base de datos SQL Server, dividida lógicamente en un esquema de aterrizaje (stg), un sistema transaccional normalizado (oltp) y un modelo dimensional en esquema estrella (dw).
- Desarrollar un proceso ETL (Extracción, Transformación y Carga) automatizado mediante T-SQL que ingeste datos crudos desde archivos CSV, transforme tipos de datos, elimine duplicados mediante funciones de ventana y garantice la integridad referencial.
- Automatizar el intercambio de datos con el entorno de Inteligencia Artificial en Python, permitiendo consultar las vistas analíticas (ej. dm.vw_Dataset_ML) y exportar las clasificaciones directamente a la tabla Resultados_Prediccion_IA en el Data Mart.
- Desplegar la capa de visualización en Power BI combinando indicadores descriptivos (KPI) con la

salida del modelo predictivo en un entorno interactivo.

## 3.2 Preguntas de negocio.

| N.º | Pregunta de negocio | Finalidad del análisis |
|---|---|---|
| 1 | ¿Cómo evoluciona la cantidad de citas atendidas y ausentes a lo largo del tiempo? | Identificar tendencias y variaciones en la asistencia de los pacientes. |
| 2 | ¿En qué meses, trimestres y días de la semana se concentra la mayor cantidad de inasistencias? | Identificar patrones temporales que permitan mejorar la programación de citas. |
| 3 | ¿Qué barrios presentan las mayores tasas de inasistencia de pacientes? | Identificar zonas geográficas donde se concentra el problema. |
| 4 | ¿Qué especialidades odontológicas y profesionales registran la mayor cantidad de citas ausentes? | Evaluar el comportamiento de la asistencia según la especialidad y el odontólogo. |
| 5 | ¿Qué tratamientos presentan mayores niveles de inasistencia y qué relación existe con su duración y costo? | Identificar tratamientos que requieren mayor seguimiento. |
| 6 | ¿Qué características demográficas de los pacientes se relacionan con una mayor frecuencia de inasistencias? | Analizar patrones según edad, género y barrio de residencia. |
| 7 | ¿Qué pacientes presentan mayor probabilidad de abandonar sus tratamientos según el modelo predictivo? | Identificar y priorizar pacientes con riesgo Alto, Medio y Bajo. |
| 8 | ¿Qué variables tienen mayor influencia en la predicción del abandono de los pacientes? | Identificar los factores más relevantes mediante la importancia de variables del modelo Random Forest. |
| 9 | ¿Cuál es el monto económico estimado asociado a las citas ausentes y cómo se distribuye según el tiempo, tratamiento y especialidad? | Cuantificar el impacto económico potencial de las inasistencias. |
| 10 | ¿Cuánto podría recuperar económicamente la clínica si logra fidelizar a un porcentaje determinado de pacientes en riesgo? | Evaluar diferentes escenarios de recuperación mediante el simulador What-If. |

3.3Indicadores y perspectivas de análisis.

3.4 Modelo conceptual.

El modelo conceptual describe, sin entrar en detalles técnicos de implementación, cómo funciona el centro dental y qué elementos del negocio es necesario registrar. La operación gira en torno a un hecho central: el **paciente** solicita una **cita** para ser atendido por un **odontólogo**, quien le aplica un **tratamiento** del catálogo de procedimientos de la clínica.

El flujo general de la clínica es el siguiente: (1) el paciente se registra con sus datos demográficos (género, edad y barrio de residencia); (2) se programa una cita, indicando la fecha de programación y la fecha en que será atendido; (3) opcionalmente se le envía un mensaje de texto (SMS) recordatorio; (4) el día de la cita el paciente asiste o no asiste (inasistencia o *no-show*); y (5) a la cita se le asocia el costo del tratamiento aplicado, que representa el ingreso que la clínica obtiene o deja de percibir.

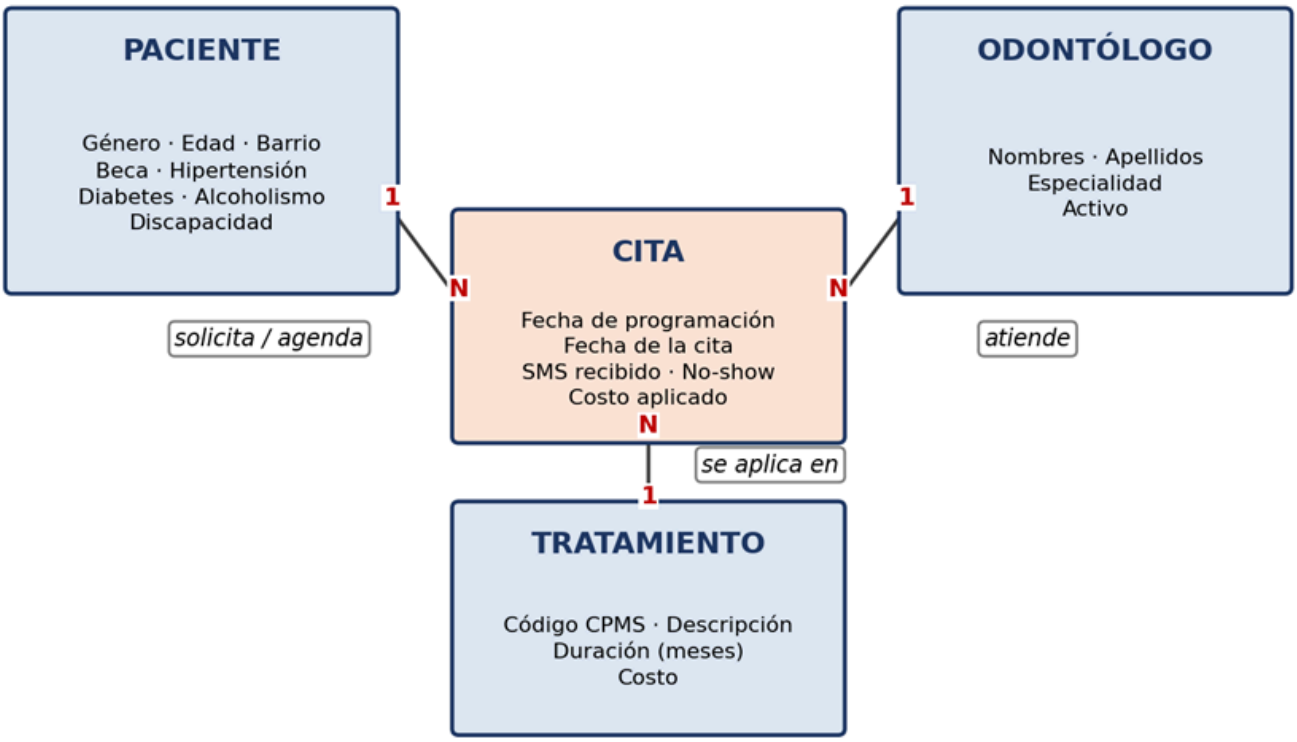



**Figura 3.1.** *Modelo conceptual del centro dental: entidades y relaciones principales.*

**Tabla 3.1.** *Entidades del modelo conceptual.*

| Entidad | Descripción | Atributos principales |
|---|---|---|
| Paciente | Persona que solicita atención odontológica en la clínica. | Género, edad y barrio de residencia. |
| Odontólogo | Profesional de la salud que atiende las citas. | Nombres, apellidos, especialidad y estado activo. |
| Tratamiento | Procedimiento odontológico del catálogo CPMS, con su costo y duración estimada. | Código CPMS, descripción, duración en meses y costo. |
| Cita | Evento que vincula a un paciente, un odontólogo y un tratamiento en una fecha determinada. | Fecha de programación, fecha de la cita, SMS recibido, inasistencia (*no-show*) y costo aplicado. |

Las relaciones entre las entidades son las siguientes:

- Un paciente puede tener **muchas citas**; cada cita pertenece a un único paciente (1:N).
- Un odontólogo atiende **muchas citas**; cada cita es atendida por un único odontólogo (1:N).
- Un tratamiento se aplica en **muchas citas**; cada cita tiene asociado un único tratamiento (1:N).

De este modo, la entidad **Cita** es la entidad transaccional que conecta a las demás y sobre la cual se medirá posteriormente el comportamiento de los pacientes.

## 3.5 Análisis de la base OLTP.

La base transaccional (OLTP) soporta la operación diaria de la clínica. Se implementó en SQL Server dentro de la base de datos **DentalCenterDB**, en el esquema oltp, y está compuesta por cuatro tablas: Pacientes, Odontologos, Tratamientos y Citas. Antes de llegar a ellas, los datos crudos de los archivos CSV aterrizan en el esquema stg (*staging*), cuyas tablas **Raw_NoShow** y **Raw_CPMS** definen todas sus columnas como texto (NVARCHAR) y aceptan valores nulos, de modo que la carga masiva no falle por problemas de formato; la validación y conversión de tipos se realiza posteriormente en el proceso ETL. Este esquema incluye además la tabla **Rechazos_Ingesta**, donde el ETL registra los datos descartados y el motivo del rechazo. Aunque Raw_NoShow conserva todas las columnas del archivo de origen (incluidos los indicadores de beca, hipertensión, diabetes, alcoholismo y discapacidad), el modelo transaccional incorpora únicamente los atributos demográficos del paciente: género, edad y barrio.

Las características de diseño más relevantes del esquema transaccional son:

- **Llaves primarias.** Pacientes e IdCita conservan el identificador del sistema origen (BIGINT e INT, respectivamente); Odontologos usa IDENTITY(1,1); y Tratamientos usa un INT sin autoincremento, asignado por el ETL mediante ROW_NUMBER() ordenado por el código CPMS.
- **Tipos de datos ajustados al dominio.** El indicador de SMS y el estado activo del odontólogo se modelan como BIT; los costos como DECIMAL(10,2); y la fecha de programación como DATETIME2(0) (precisión de segundos), diferenciándose de la fecha de la cita, que es de tipo DATE.
- **Integridad y valores por defecto.** Todas las columnas son NOT NULL; Activo (DEFAULT 1), SMSRecibido (DEFAULT 0) y DuracionMeses (DEFAULT 1) tienen valor por defecto, lo que evita registros incompletos. Las tres relaciones de la tabla Citas están declaradas como llaves foráneas (sección 3.6).

- **Normalización.** Cada entidad del negocio tiene su propia tabla y los datos del paciente, del odontólogo y del tratamiento no se repiten en cada cita, sino que se referencian mediante llaves foráneas.

**Tabla 3.2.** *Estructura de la tabla oltp.Pacientes.*

| Columna | Tipo | Restricción | Descripción |
|---|---|---|---|
| IdPaciente | BIGINT | PK | Identificador del paciente (PatientId del origen). |
| Genero | CHAR(1) | NOT NULL | Género (M/F). |
| Edad | SMALLINT | NOT NULL | Edad en años. |
| Barrio | NVARCHAR(100) | NOT NULL | Barrio de residencia. |

**Tabla 3.3.** *Estructura de la tabla oltp.Odontologos.*

| Columna | Tipo | Restricción | Descripción |
|---|---|---|---|
| IdOdontologo | INT | PK, IDENTITY | Identificador del odontólogo. |
| Nombres | NVARCHAR(100) | NOT NULL | Nombres del profesional. |
| Apellidos | NVARCHAR(100) | NOT NULL | Apellidos del profesional. |
| Especialidad | NVARCHAR(100) | NOT NULL | Especialidad (general, endodoncia, ortodoncia). |
| Activo | BIT | DEFAULT 1 | Indica si el profesional está activo. |

**Tabla 3.4.** *Estructura de la tabla oltp.Tratamientos.*

| Columna | Tipo | Restricción | Descripción |
|---|---|---|---|
| IdTratamiento | INT | PK | Identificador del tratamiento, asignado por el ETL (ROW_NUMBER sobre el código CPMS). |
| CodigoCPMS | VARCHAR(50) | NOT NULL | Código del procedimiento según el catálogo CPMS. |
| Descripcion | NVARCHAR(500) | NOT NULL | Descripción del procedimiento. |
| DuracionMeses | INT | NOT NULL, DEFAULT 1 | Duración estimada del tratamiento en meses (campo operativo). |
| Costo | DECIMAL(10,2) | NOT NULL | Tarifa del procedimiento. |

**Tabla 3.5.** *Estructura de la tabla oltp.Citas.*

| Columna | Tipo | Restricción | Descripción |
|---|---|---|---|
| IdCita | INT | PK | Identificador de la cita (AppointmentID del origen). |
| IdPaciente | BIGINT | FK, NOT NULL | Paciente que solicita la cita. |
| IdOdontologo | INT | FK, NOT NULL | Odontólogo que atiende la cita. |
| IdTratamiento | INT | FK, NOT NULL | Tratamiento asociado a la cita. |
| FechaProgramacion | DATETIME2(0) | NOT NULL | Fecha y hora en que se registró la cita. |
| FechaCita | DATE | NOT NULL | Fecha en que debe realizarse la atención. |
| SMSRecibido | BIT | NOT NULL, DEFAULT 0 | Indica si el paciente recibió recordatorio por SMS. |
| NoShow | VARCHAR(3) | NOT NULL | Resultado de asistencia: Yes (no asistió) / No (asistió). |
| CostoAplicado | DECIMAL(10,2) | NOT NULL | Costo del tratamiento aplicado a la cita. |

## 3.6 Relaciones identificadas.

En el esquema transaccional, la tabla oltp.Citas actúa como tabla hija de las otras tres entidades. Las relaciones se establecen a través de llaves foráneas, de forma que ninguna cita puede existir sin un paciente y un odontólogo válidos.

**Tabla 3.6.** *Relaciones del esquema OLTP.*

| Tabla hija (N) | Tabla padre (1) | Tipo | Detalle |
|---|---|---|---|
| oltp.Citas.IdPaciente | oltp.Pacientes.IdPaciente | FK declarada | Un paciente tiene muchas citas; cada cita pertenece a un solo paciente. |
| oltp.Citas.IdOdontologo | oltp.Odontologos.IdOdontologo | FK declarada | Un odontólogo atiende muchas citas; cada cita es atendida por un solo odontólogo. |
| oltp.Citas.IdTratamiento | oltp.Tratamientos.IdTratamiento | FK declarada | Un tratamiento se aplica en muchas citas; cada cita tiene un único tratamiento del catálogo. |

Las tres relaciones están declaradas como llaves foráneas, de modo que el motor garantiza que ninguna cita exista sin un paciente, un odontólogo y un tratamiento válidos. La integridad referencial se refuerza además en el proceso de carga: el procedimiento stg.usp_CargarOLTP solo inserta citas cuyo IdPaciente ya existe en oltp.Pacientes y asigna únicamente identificadores de tratamiento del catálogo (con el identificador 1 como valor de respaldo). El orden de eliminación de tablas en el script DDL (primero Citas y luego las tablas padre) respeta estas dependencias.

En el Data Mart se identifican relaciones análogas: la tabla de hechos dm.Fact_Atenciones referencia a cada dimensión mediante llaves foráneas sobre las llaves subrogadas (SK_Paciente, SK_Medico, SK_Tratamiento y SK_Tiempo), tal como se detalla en las secciones 3.9 a 3.12.

## 3.7 Nivel de granularidad.

La granularidad define qué representa exactamente cada registro de la tabla de hechos. En este proyecto se establece que **cada registro corresponde a una cita médica**, es decir, a una atención odontológica programada para un paciente, con un odontólogo y un tratamiento en una fecha determinada, independientemente de que el paciente haya asistido o no.

Esta definición se garantiza en el modelo mediante tres mecanismos: (a) IdCita es la llave primaria de oltp.Citas; (b) IdCita tiene una restricción UNIQUE en dm.Fact_Atenciones; y (c) el proceso ETL elimina duplicados por AppointmentID antes de cargar la cita (sección 3.13).

**Tabla 3.7.** *Granularidad por capa de datos.*

| Capa / tabla | Un registro representa | Observación |
|---|---|---|
| stg.Raw_NoShow | Una fila del archivo CSV | Puede contener duplicados y valores inválidos. |

| | | |
|---|---|---|
| oltp.Pacientes | Un paciente | Se conserva un único registro por IdPaciente. |
| oltp.Citas | Una cita | Un paciente puede tener varias citas. |
| dm.Fact_Atenciones | Una cita médica | Grano atómico del Data Mart; no se agrega información. |

Definir el grano al nivel de cita permite analizar la información con el máximo detalle y agregarla después por cualquiera de las dimensiones: por mes o año, por barrio, por especialidad del odontólogo o por tratamiento. Con ello se responden preguntas como: ¿cuál es la tasa de inasistencia por barrio y mes?, ¿cuántos ingresos se pierden por especialidad? o ¿cuánto tiempo de espera precede a una ausencia?

## 3.8 Modelo conceptual ampliado.

El modelo conceptual ampliado extiende la base operativa con las capas necesarias para la analítica de negocio y la inteligencia artificial. Los datos fluyen desde los archivos CSV hasta el área de *staging*, se depuran y almacenan en el OLTP, se transforman al modelo dimensional del Data Mart y, desde allí, alimentan tanto los indicadores de gestión como el modelo predictivo de inasistencia. Los resultados de la predicción regresan al Data Mart y son consumidos por Power BI.

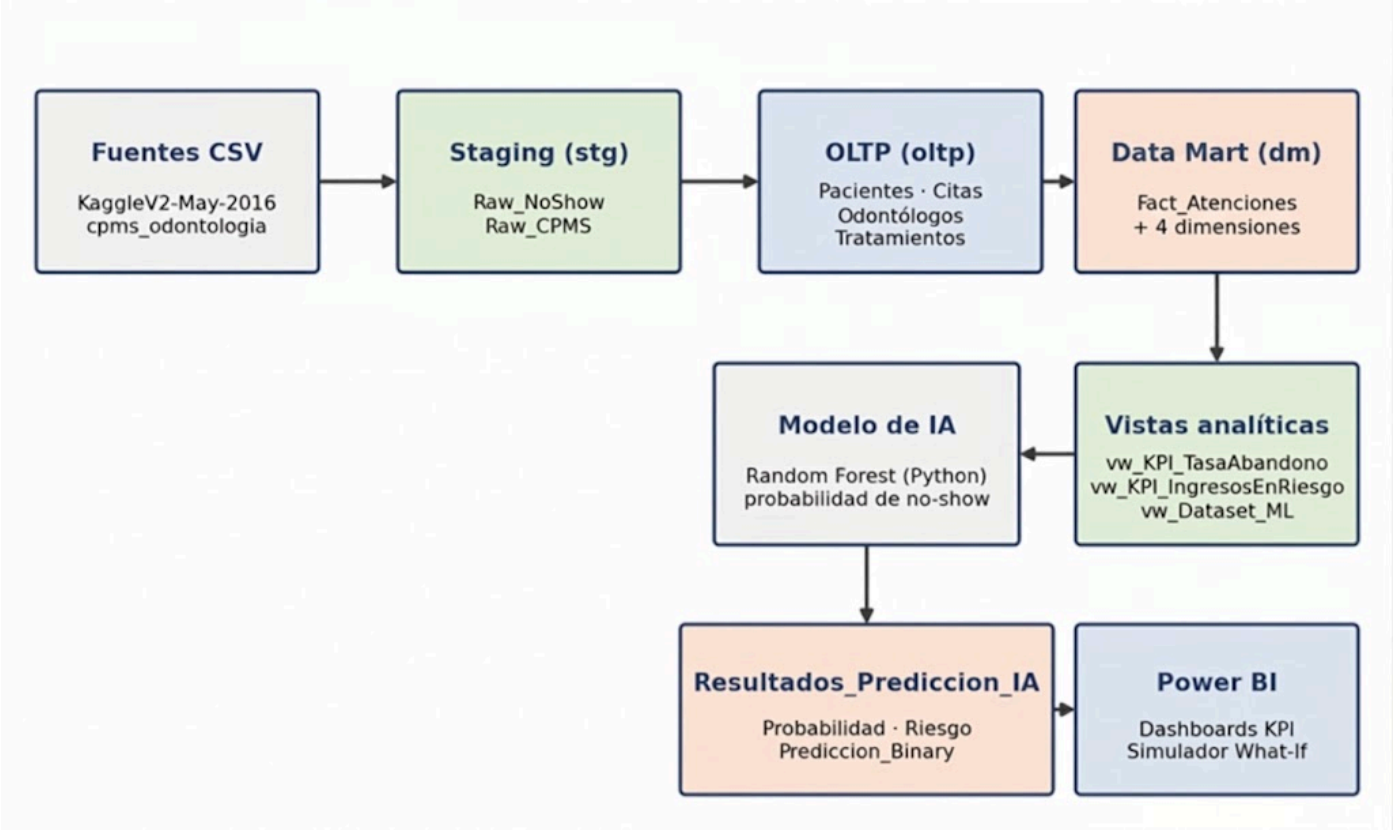



**Figura 3.2.** *Modelo conceptual ampliado: de la operación diaria a la analítica y la IA.*

Para esta preparación analítica, la base incorpora los siguientes componentes:

- **Data Mart dimensional (`dm`)**, con una tabla de hechos y cuatro dimensiones, optimizado para consultas analíticas. La dimensión de tiempo incluye el trimestre y el día de la semana, que permiten estudiar patrones estacionales de ausencia, y la dimensión de paciente incluye un rango etario.
- **Variables calculadas en la tabla de hechos** (Estado_Cita, Tiempo_Espera_Dias, Es_Atendido y Es_Ausencia), que dejan la información lista para el análisis y para el aprendizaje automático.
- **Vistas analíticas**, que encapsulan el indicador clave de abandono y el conjunto de datos de entrenamiento para el modelo predictivo.
- **Tabla de resultados de IA (`dm.Resultados_Prediccion_IA`)**, donde se almacena, por cada cita evaluada, la probabilidad de inasistencia, el nivel de riesgo (por ejemplo, Alto, Medio o Bajo), la predicción binaria y la fecha de evaluación.

**Tabla 3.8.** *Vistas analíticas del Data Mart.*

| Vista | Nivel de análisis | Medidas / campos |
|---|---|---|
| dm.vw_KPI_TasaAbandono | Año, mes y barrio | Anio, Mes, NombreMes, Barrio, TotalCitas, CitasAbandonadas (suma de Es_Ausencia) y PorcentajeAbandono. |
| dm.vw_Dataset_ML | Una fila por cita | IdCita, SK_Paciente, Edad, Genero, SMSRecibido, Tiempo_Espera_Dias, Costo_Tratamiento_Sugerido, Mes_Cita, DiaSemana_Cita y Target_Inasistencia (variable objetivo). |

La vista **dm.vw_Dataset_ML** entrega al modelo predictivo las variables explicativas (edad y género del paciente, SMS recibido, tiempo de espera en días, costo de catálogo del tratamiento, mes y día de la semana de la cita) junto con la variable objetivo (Target_Inasistencia), que indica si la cita terminó en ausencia. Cada fila corresponde a una cita e incluye IdCita y SK_Paciente, que permiten registrar la predicción en dm.Resultados_Prediccion_IA y relacionarla con la tabla de hechos sin pasos intermedios. Se utiliza el costo de catálogo (Costo_Tratamiento_Sugerido, tomado de Dim_Tratamiento.Costo_Total) en lugar de Monto_Pagado, porque este último vale cero en las citas con ausencia y revelaría la variable objetivo. Los indicadores de salud del archivo de origen no forman parte del OLTP ni del Data Mart. Con las predicciones almacenadas, la clínica puede priorizar recordatorios y acciones de fidelización sobre las citas y pacientes con mayor riesgo de ausencia y estimar el retorno económico de recuperarlos.

## 3.9 Modelo lógico del DataMart.

El Data Mart sigue el enfoque dimensional de Kimball bajo un **esquema estrella**: una tabla de hechos central (**dm.Fact_Atenciones**) rodeada por cuatro tablas de dimensiones (Dim_Paciente, Dim_Medico, **Dim_Tratamiento** y **Dim_Tiempo**). Todas las tablas analíticas residen en el esquema dm, separadas lógicamente de la capa de aterrizaje (stg) y de la base transaccional (oltp).

Las decisiones principales del diseño lógico se resumen a continuación:

• **Llaves subrogadas.** Cada dimensión tiene una llave primaria artificial de tipo INT IDENTITY(1,1) (SK_Paciente, SK_Medico, SK_Tratamiento) que aísla al Data Mart de los cambios en los identificadores del sistema origen y optimiza los *joins*. La tabla de hechos tiene su propia llave autoincremental, ID_Hecho.

• **Claves de negocio conservadas.** El identificador original (IdPaciente, IdOdontologo, IdTratamiento) se mantiene en la dimensión y se protege con una restricción UNIQUE, evitando duplicados.

• **Clave inteligente de tiempo.** Dim_Tiempo usa como llave SK_Tiempo un entero con formato AAAAMMDD (por ejemplo, 20160429), legible y ordenable.

• **Integridad referencial.** La tabla de hechos declara llaves foráneas hacia las cuatro dimensiones, de modo que no pueden existir atenciones sin sus descriptores.

• **Dimensiones no versionadas.** Las dimensiones se cargan de forma incremental, insertando solo los miembros nuevos; cada miembro conserva los valores con que fue cargado por primera vez.

**Tabla 3.9.** *Llaves del modelo lógico del Data Mart.*

| Tabla | Llave primaria | Llave de negocio | Llaves foráneas |
|---|---|---|---|
| dm.Dim_Paciente | SK_Paciente | IdPaciente (UNIQUE) | — |
| dm.Dim_Medico | SK_Medico | IdOdontologo (UNIQUE) | — |
| dm.Dim_Tratamiento | SK_Tratamiento | IdTratamiento (UNIQUE) | — |
| dm.Dim_Tiempo | SK_Tiempo | Fecha | — |
| dm.Fact_Atenciones | ID_Hecho | IdCita (UNIQUE) | SK_Paciente, SK_Medico, SK_Tratamiento, SK_Tiempo |
| dm.Resultados_Prediccion_IA | ID_Prediccion | — | Ninguna declarada; relación lógica con Fact_Atenciones por IdCita (y SK_Paciente) |

## 3.10 Tablas de dimensiones.

Las dimensiones contienen los atributos descriptivos que permiten filtrar, agrupar y etiquetar las medidas de la tabla de hechos. A continuación se describe cada una.

### 3.10.1 Dim_Tiempo

Describe la fecha de la cita y permite analizar la información por año, trimestre, mes y día de la semana. Se alimenta con las fechas distintas de oltp.Citas.FechaCita. La fecha de programación no tiene dimensión propia: se utiliza para calcular la medida Tiempo_Espera_Dias en la tabla de hechos. Jerarquía: Año → Trimestre → Mes → Fecha.

**Tabla 3.10.** *Estructura de dm.Dim_Tiempo.*

| Columna | Tipo | Descripción |
|---|---|---|
| SK_Tiempo | INT (PK) | Llave de la dimensión con formato AAAAMMDD. |
| Fecha | DATE | Fecha calendario de la cita. |
| Anio | SMALLINT | Año. |
| Mes | TINYINT | Número de mes (1–12). |
| NombreMes | VARCHAR(12) | Nombre del mes en español. |
| Trimestre | TINYINT | Trimestre del año (1–4). |
| Dia_Semana | VARCHAR(15) | Nombre del día de la semana en español. |

### 3.10.2 Dim_Paciente

Contiene los atributos demográficos del paciente utilizados para segmentar el análisis, en especial el barrio, la edad, el rango etario y el género. Se alimenta desde oltp.Pacientes; el rango etario se calcula durante el ETL en cinco tramos: 0-17 años, 18-29 años, 30-44 años, 45-59 años y 60 años a más.

***Tabla 3.11.*** *Estructura de dm.Dim_Paciente.*

| Columna | Tipo | Descripción |
|---|---|---|
| SK_Paciente | INT (PK, IDENTITY) | Llave subrogada del paciente. |
| IdPaciente | BIGINT (UNIQUE) | Clave de negocio proveniente del OLTP. |
| Genero | CHAR(1) | Género del paciente. |
| Edad | SMALLINT | Edad del paciente. |
| Rango_Etario | VARCHAR(20) | Tramo de edad calculado en el ETL (0-17 años, 18-29 años, 30-44 años, 45-59 años, 60 años a más). |
| Barrio | NVARCHAR(100) | Barrio de residencia. |

### 3.10.3 Dim_Medico

Describe al odontólogo que atiende la cita y permite analizar el desempeño por profesional y especialidad. Se alimenta desde oltp.Odontologos, concatenando nombres y apellidos en un único campo.

***Tabla 3.12.*** *Estructura de dm.Dim_Medico.*

| Columna | Tipo | Descripción |
|---|---|---|
| SK_Medico | INT (PK, IDENTITY) | Llave subrogada del odontólogo. |
| IdOdontologo | INT (UNIQUE) | Clave de negocio proveniente del OLTP. |
| NombreCompleto | NVARCHAR(200) | Nombres y apellidos concatenados. |
| Especialidad | NVARCHAR(100) | Especialidad odontológica. |

### 3.10.4 Dim_Tratamiento

Describe el procedimiento odontológico aplicado, tomado del catálogo CPMS, junto con su duración estimada y su costo. Se alimenta desde oltp.Tratamientos.

***Tabla 3.13.*** *Estructura de dm.Dim_Tratamiento.*

| Columna | Tipo | Descripción |
|---|---|---|
| SK_Tratamiento | INT (PK, IDENTITY) | Llave subrogada del tratamiento. |
| IdTratamiento | INT (UNIQUE) | Clave de negocio proveniente del OLTP. |
| Descripcion | NVARCHAR(500) | Descripción del procedimiento. |
| Duracion_Meses | INT | Duración estimada del tratamiento, en meses. |
| Costo_Total | DECIMAL(10,2) | Costo del tratamiento según el catálogo (proviene de Tratamientos.Costo). |

**3.11 Tabla de hechos**.
La tabla dm.Fact_Atenciones es el centro del modelo dimensional. Su grano es **una fila por cita médica** (sección 3.7) y almacena las medidas numéricas del proceso de atención, las variables calculadas para análisis y aprendizaje automático, y las llaves hacia las cuatro dimensiones.

***Tabla 3.14.*** *Estructura de dm.Fact_Atenciones.*

| Columna | Tipo | Rol | Descripción |
|---|---|---|---|
| ID_Hecho | INT | PK (IDENTITY) | Llave subrogada del hecho. |
| IdCita | INT | Dimensión degenerada (UNIQUE) | Identificador de la cita en el OLTP; garantiza una fila por cita y evita duplicados en el ETL. |
| SK_Paciente | INT | FK | Paciente atendido (Dim_Paciente). |
| SK_Medico | INT | FK | Odontólogo que atiende (Dim_Medico). |
| SK_Tratamiento | INT | FK | Tratamiento aplicado (Dim_Tratamiento). |
| SK_Tiempo | INT | FK | Fecha de la cita (Dim_Tiempo). |
| Estado_Cita | VARCHAR(20) | Atributo | 'Atendido' o 'Ausencia/No-Show'. |
| Tiempo_Espera_Dias | INT | Medida | Días entre la fecha de programación y la fecha de la cita. |
| SMSRecibido | BIT | Indicador | 1 si el paciente recibió el recordatorio por SMS; 0 en caso contrario. |
| Monto_Pagado | DECIMAL(10, 2) | Medida | Monto cobrado: costo aplicado de la cita si el paciente asistió; 0 si no asistió. |
| Es_Atendido | INT | Indicador | 1 si el paciente asistió; 0 en caso contrario. |

Las medidas se comportan de la siguiente manera: Monto_Pagado es **aditiva** y se puede sumar por cualquier dimensión, pero representa el ingreso efectivamente percibido (vale 0 en las ausencias), por lo que el ingreso que se deja de percibir se calcula con el costo del tratamiento (Dim_Tratamiento.Costo_Total) de las citas con Es_Ausencia = 1; Es_Atendido y Es_Ausencia son **aditivas** como conteos de citas atendidas y ausentes (SUM), y Es_Ausencia dividida entre el total de citas produce la tasa de abandono; Tiempo_Espera_Dias **no se suma**, sino que se analiza mediante promedio, mínimo y máximo. A modo de ejemplo, la tasa de ausencia por especialidad se obtiene con la siguiente consulta:

```
SELECT m.Especialidad,
    COUNT(*) AS TotalCitas,
    SUM(f.Es_Ausencia) AS Ausencias,
    CAST(SUM(f.Es_Ausencia) * 100.0 / COUNT(*) AS DECIMAL(5,2)) AS PorcentajeAusencia
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Medico m ON m.SK_Medico = f.SK_Medico
GROUP BY m.Especialidad
ORDER BY PorcentajeAusencia DESC;
```

Complementariamente, la tabla dm.Resultados_Prediccion_IA almacena la salida del modelo predictivo por cita: IdCita, SK_Paciente, Probabilidad_Inasistencia, Nivel_Riesgo, Prediccion_Binary y Fecha_Evaluacion. Tiene su propia llave subrogada (ID_Prediccion) y se relaciona de forma lógica, sin llave foránea declarada, con la tabla de hechos mediante IdCita, lo que permite cruzar el riesgo estimado con cualquier dimensión.

## 3.12 Modelo dimensional.

El modelo dimensional resultante es un esquema estrella: la tabla de hechos Fact_Atenciones ocupa el centro y se conecta con las dimensiones Paciente, Médico, Tratamiento y Tiempo mediante relaciones uno a muchos (1:N) sobre las llaves subrogadas. La figura siguiente presenta el esquema con sus llaves y tipos de datos.

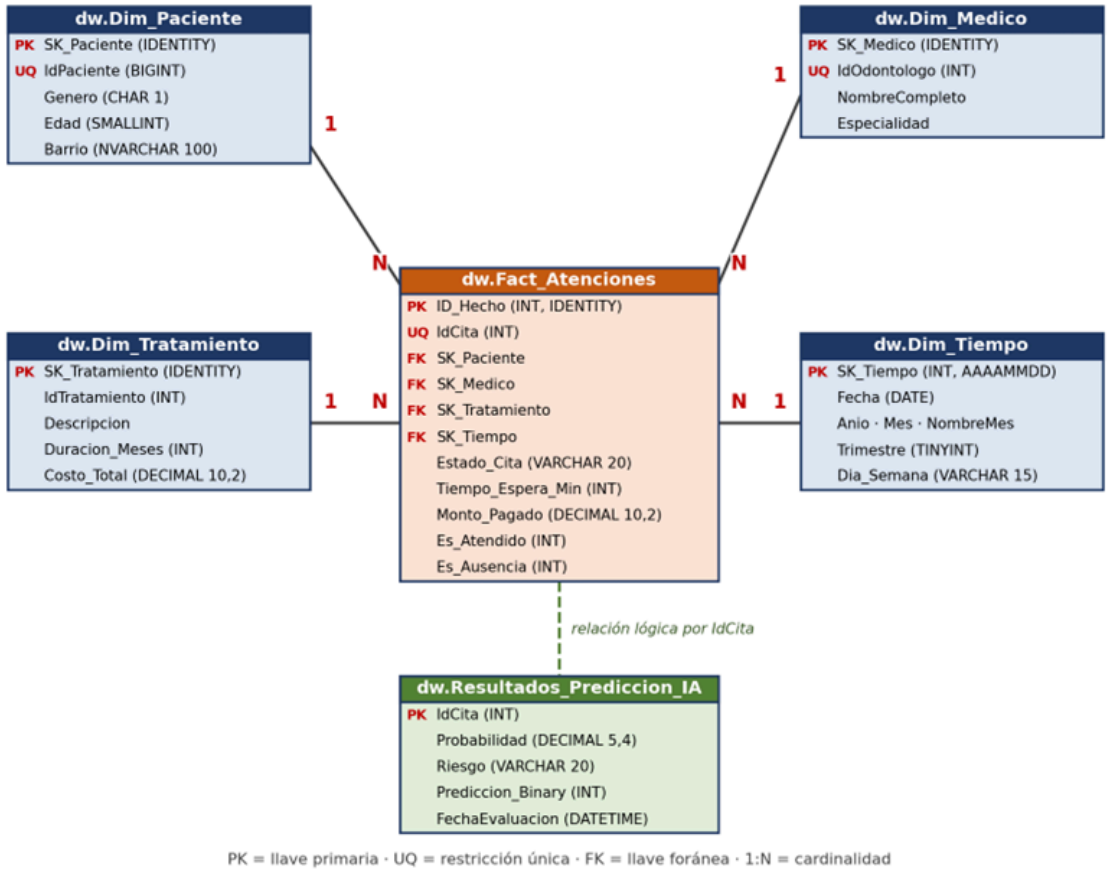



**Figura 3.3.** *Esquema estrella del Data Mart (diagrama de referencia).*

En el esquema estrella, cada dimensión se vincula directamente con la tabla de hechos, sin dimensiones intermedias, lo que simplifica las consultas y favorece el rendimiento de las agregaciones. La tabla `Resultados_Prediccion_IA` se muestra con una relación lógica por IdCita, ya que su función es registrar la salida del modelo de IA sobre las citas existentes en la tabla de hechos.

## 3.13 Proceso ETL.

El proceso ETL (extracción, transformación y carga) traslada los datos desde los archivos CSV hasta el Data Mart en dos etapas encadenadas: de los archivos crudos al OLTP, y del OLTP al modelo dimensional. Está implementado con *scripts* de T-SQL y dos procedimientos almacenados: stg.usp_CargarOLTP y dm.usp_ETL_CargarDataMart.

### 3.13.1 Extracción de los archivos CSV

La extracción se realiza con la instrucción BULK INSERT, que carga cada archivo directamente en su tabla de *staging*, omitiendo la fila de encabezado (FIRSTROW = 2), con separador de campos coma y codificación UTF-8 (CODEPAGE = 65001). Antes de cada carga, las tablas stg.Raw_NoShow y stg.Raw_CPMS se vacían con TRUNCATE TABLE, de manera que siempre reflejen el contenido del archivo más reciente; la tabla de control stg.Rechazos_Ingesta se vacía al inicio de cada ejecución de stg.usp_CargarOLTP.

**Tabla 3.15.** *Fuentes de datos del proceso ETL.*

| Archivo | Tabla de staging | Contenido |
|---|---|---|
| KaggleV2-May-2016.csv | stg.Raw_NoShow | Citas médicas y datos del paciente (dataset público *Medical Appointment No Shows*): identificadores, género, fechas, edad, barrio, indicadores de salud, SMS e inasistencia. |
| cpms_odontologia.csv | stg.Raw_CPMS | Catálogo de procedimientos odontológicos: código, descripción y tarifa. |

### 3.13.2 Transformación y limpieza

La transformación se realiza en stg.usp_CargarOLTP y convierte el texto crudo en datos tipados y validados. Se utiliza TRY_CAST, que devuelve NULL en lugar de producir un error cuando un valor no se puede convertir, lo que permite descartar o corregir registros inválidos sin interrumpir el proceso.

Antes de cargar los datos al OLTP, el procedimiento valida los registros de stg.Raw_NoShow y guarda los descartados en la tabla stg.Rechazos_Ingesta, donde cada rechazo conserva el PatientId, el AppointmentID, el motivo y la fecha de registro (FechaRegistro, con valor por defecto GETDATE()).

***Tabla 3.16a.*** *Reglas de validación y registro de rechazos.*

| Campo de origen | Campo de destino | Regla aplicada |
|---|---|---|
| PatientId | Pacientes.IdPaciente | Conversión a BIGINT; se descartan nulos y valores no numéricos, que se registran en stg.Rechazos_Ingesta. |
| Gender | Pacientes.Genero | UPPER(LEFT(Gender, 1)): primera letra en mayúscula. |
| Age | Pacientes.Edad | Conversión a SMALLINT; solo se aceptan edades entre 0 y 100. |
| Neighbourhood | Pacientes.Barrio | Copia directa. |
| Scholarship, Hipertension, Diabetes, Alcoholism, Handcap | (no se transfieren) | Permanecen únicamente en stg.Raw_NoShow; no se cargan al OLTP ni al Data Mart. |
| AppointmentID | Citas.IdCita | Conversión a INT. |
| PatientId | Citas.IdPaciente | Conversión a BIGINT; solo se cargan citas de pacientes aceptados en oltp.Pacientes. |
| ScheduledDay | Citas.FechaProgramacion | Se toman los primeros 19 caracteres y se convierte a DATETIME2. |
| AppointmentDay | Citas.FechaCita | Se toman los primeros 10 caracteres y se convierte a DATE; se excluyen las citas con fecha anterior a la de programación. |
| SMS_received | Citas.SMSRecibido | 1 si el valor es "1"; en caso contrario 0. |

| | | |
|---|---|---|
| NoShow | Citas.NoShow | Se conserva el texto Yes/No; en el Data Mart se traduce a Estado_Cita, Es_Atendido y Es_Ausencia. |
| Codigo, Descripcion, Tarifa | Tratamientos.CodigoCPMS, Descripcion, Costo | Se reemplaza la coma decimal por punto y se convierte a DECIMAL(10,2); si la tarifa es inválida se asigna 45.00. IdTratamiento se genera con ROW_NUMBER() ordenado por código y DuracionMeses se fija en 1. |
| (calculado) | Citas.IdOdontologo, Citas.IdTratamiento | Asignación determinística a partir de CHECKSUM(AppointmentID), ya que el origen no registra odontólogo ni tratamiento. |
| (calculado) | Citas.CostoAplicado | Costo del tratamiento asignado; 45.00 si no se encuentra. |

Dado que el dataset de origen no incluye información sobre el odontólogo ni sobre el tratamiento de cada cita, el ETL los asigna de forma determinística: el identificador del odontólogo se obtiene como (ABS(CHECKSUM(AppointmentID)) % 3) + 1 y el del tratamiento como (ABS(CHECKSUM(AppointmentID, 7)) % N) + 1, donde N es el número de tratamientos del catálogo. Al ser determinística, la asignación es reproducible en cada ejecución. Los tres odontólogos corresponden a personal base insertado en el Script 3 (Odontología General, Endodoncia y Ortodoncia). La carga de tratamientos es idempotente: solo se ejecuta si oltp.Tratamientos está vacía y, si el catálogo CPMS llega vacío, el procedimiento carga un catálogo mínimo de seis tratamientos odontológicos (CPMS-01 a CPMS-06), con duraciones de 1 a 12 meses (por ejemplo, 12 meses para el control mensual de ortodoncia).

### 3.13.3 Deduplicación

El archivo de origen contiene una fila por cita, de modo que un mismo paciente aparece repetido tantas veces como tenga citas. Para cargar entidades únicas, el ETL utiliza la función de ventana ROW_NUMBER() y conserva solo la primera fila de cada grupo (FilaNum = 1).

**Tabla 3.17.** *Reglas de deduplicación.*

| Entidad | Criterio de partición y orden | Resultado |
|---|---|---|
| Paciente | PARTITION BY PatientId ORDER BY AppointmentID DESC | Un registro por paciente, con los datos de su cita más reciente. |
| Cita | PARTITION BY AppointmentID ORDER BY ScheduledDay DESC | Un registro por cita, aun si el identificador se repite en el archivo. |

La carga de citas es incremental: solo se insertan las citas cuyo IdCita aún no existe en oltp.Citas (NOT IN) y cuyo paciente fue aceptado en oltp.Pacientes, preservando la integridad referencial. En cambio, la carga de pacientes se ejecuta únicamente cuando oltp.Pacientes está vacía (condición NOT EXISTS sobre la tabla completa), por lo que está concebida para la carga inicial. Las citas de pacientes descartados por edad inválida no ingresan al modelo.

### 3.13.4 Carga al Data Mart

El procedimiento dm.usp_ETL_CargarDataMart realiza la carga dimensional en el siguiente orden: primero las dimensiones (Dim_Paciente, Dim_Medico, Dim_Tratamiento y Dim_Tiempo) y finalmente la tabla de hechos. Este orden es necesario porque la tabla de hechos requiere las llaves subrogadas de las dimensiones para resolver sus llaves foráneas. Todas las cargas son incrementales: solo se insertan los miembros o citas que aún no existen en el destino.

- **Dim_Paciente:** además de copiar los atributos del OLTP, se calcula Rango_Etario con una expresión CASE sobre la edad (0-17, 18-29, 30-44, 45-59 y 60 años a más).
- **Dim_Medico:** el nombre completo se construye concatenando Nombres y Apellidos.
- **Dim_Tiempo:** a partir de las fechas distintas de las citas se genera la llave AAAAMMDD mediante CONVERT(VARCHAR(8), FechaCita, 112), y se derivan el nombre del mes (DATENAME(MONTH, ...)), el trimestre (DATEPART(QUARTER, ...)) y el día de la semana (DATENAME(WEEKDAY, ...)); el procedimiento ejecuta SET LANGUAGE Spanish para que los nombres salgan en español.
- **Fact_Atenciones:** se relaciona cada cita con las llaves subrogadas de sus dimensiones; Tiempo_Espera_Dias se calcula con DATEDIFF(DAY, ...) entre la fecha de programación (sin hora) y la fecha de la cita; SMSRecibido se copia de la cita; el resultado Yes/No se traduce a Estado_Cita ('Atendido' o 'Ausencia/No-Show') y a los indicadores Es_Atendido y Es_Ausencia; y Monto_Pagado toma el valor de CostoAplicado cuando el paciente asistió y 0 cuando no asistió.

## 3.14 Carga y actualización de datos.

La implementación completa se organiza en tres *scripts* de T-SQL que separan la responsabilidad de crear la estructura, definir la lógica de procesamiento y ejecutar las cargas. Esta separación facilita el mantenimiento: la estructura y la lógica se definen una sola vez, y solo el tercer *script* se vuelve a ejecutar cuando se requiere refrescar los datos.

**Tabla 3.18.** *Scripts del proceso de carga.*

| Orden | Archivo | Tipo | Contenido |
|---|---|---|---|
| 1 | 01_DDL_Creacion_Estructura.sql | DDL | Eliminación y creación de la base de datos DentalCenterDB, esquemas stg, oltp y dm, y todas las tablas (staging, OLTP, Data Mart y resultados de IA). |
| 2 | 02_Logica_Procesos_ETL.sql | Procedimientos y vistas | stg.usp_CargarOLTP, dm.usp_ETL_CargarDataMart y las dos vistas analíticas (vw_KPI_TasaAbandono y vw_Dataset_ML). |
| 3 | 03_DML_Ejecucion_Cargas.sql | DML | Limpieza de *staging*, BULK INSERT, datos base de odontólogos, ejecución de procedimientos y verificación. |

**Secuencia de ejecución.** Los *scripts* se ejecutan en orden numérico. El Script 1 cierra las conexiones abiertas (SINGLE_USER WITH ROLLBACK IMMEDIATE), elimina la base de datos DentalCenterDB si existe y la vuelve a crear, por lo que borra todos los datos previos. El Script 3 vacía las tablas de *staging*, carga los CSV, inserta los tres odontólogos base (solo si la tabla está vacía), ejecuta stg.usp_CargarOLTP y luego dm.usp_ETL_CargarDataMart, y finaliza con una consulta de verificación que cuenta los registros de stg.Rechazos_Ingesta, oltp.Tratamientos, oltp.Pacientes, oltp.Citas, dm.Dim_Paciente y dm.Fact_Atenciones.

**Actualización de datos.** Los procedimientos insertan únicamente los registros que no existen en el destino, comparando por las claves de negocio (IdCita, IdOdontologo, IdTratamiento, IdPaciente y SK_Tiempo). Las tablas oltp.Pacientes y oltp.Tratamientos solo se cargan cuando están vacías, de modo que, si los nuevos archivos incluyen pacientes o tratamientos nuevos, se recomienda una recarga completa ejecutando de nuevo los Scripts 1, 2 y 3. La verificación final permite comprobar que el número de citas del OLTP coincide con el de la tabla de hechos y revisar cuántos registros fueron rechazados.

**Consideraciones de ejecución.**

- Las rutas de los archivos en BULK INSERT son absolutas (carpeta 05_Datasets del proyecto) y deben ajustarse al equipo donde se ejecute; además, la cuenta de servicio de SQL Server debe tener permiso de lectura sobre ellas.
- La recarga completa desde cero se realiza volviendo a ejecutar el Script 1, que elimina la base de datos con todos sus datos antes de recrearla; no debe ejecutarse si se desea conservar la información existente.
- La asignación de odontólogo y tratamiento a cada cita es simulada (sección 3.13.2), por lo que los análisis por especialidad y tratamiento deben interpretarse como una demostración del modelo.
- Al cargar el catálogo desde el CSV de CPMS, la duración de cada tratamiento (DuracionMeses) se fija en 1 mes; solo el catálogo de respaldo incluye duraciones distintas.
- Las citas con fecha de atención anterior a la de programación se excluyen durante el ETL, por lo que Tiempo_Espera_Dias nunca es negativo; las citas programadas para el mismo día tienen un tiempo de espera de 0 días.

### 3.14.1 Script 1: Estructura de la base de datos (DDL)

**Código 3.1.** *01_DDL_Creacion_Estructura.sql*

```
/* ====================================================================
   SCRIPT 1: ESTRUCTURA DE BASE DE DATOS (DDL)
   ==================================================================== */
USE master;
GO


IF DB_ID('DentalCenterDB') IS NULL
    CREATE DATABASE DentalCenterDB;
GO


USE DentalCenterDB;
GO


-- 1. ESQUEMAS
IF SCHEMA_ID('stg')  IS NULL EXEC('CREATE SCHEMA stg');
IF SCHEMA_ID('oltp') IS NULL EXEC('CREATE SCHEMA oltp');
IF SCHEMA_ID('dw')   IS NULL EXEC('CREATE SCHEMA dw');
GO


-- 2. TABLAS STAGING (Capa de aterrizaje cruda)
IF OBJECT_ID('stg.Raw_NoShow', 'U') IS NOT NULL DROP TABLE stg.Raw_NoShow;
CREATE TABLE stg.Raw_NoShow (
    PatientId           NVARCHAR(50)  NULL,
    AppointmentID   NVARCHAR(50)  NULL,
    Gender              NVARCHAR(10)  NULL,
    ScheduledDay        NVARCHAR(50)  NULL,
    AppointmentDay  NVARCHAR(50)  NULL,
    Age                 NVARCHAR(10)  NULL,
    Neighbourhood   NVARCHAR(100) NULL,
    Scholarship         NVARCHAR(5)   NULL,
    Hipertension        NVARCHAR(5)   NULL,
    Diabetes            NVARCHAR(5)   NULL,
    Alcoholism          NVARCHAR(5)   NULL,
    Handcap             NVARCHAR(5)   NULL,
    SMS_received        NVARCHAR(5)   NULL,
    NoShow              NVARCHAR(10)  NULL
);


IF OBJECT_ID('stg.Raw_CPMS', 'U') IS NOT NULL DROP TABLE stg.Raw_CPMS;
CREATE TABLE stg.Raw_CPMS (
    Codigo      NVARCHAR(50)   NULL,
    Descripcion  NVARCHAR(1000) NULL,
    Tarifa      NVARCHAR(50)   NULL
);
GO


-- 3. TABLAS OLTP (Sistema Transaccional)
IF OBJECT_ID('oltp.Citas', 'U') IS NOT NULL DROP TABLE oltp.Citas;
IF OBJECT_ID('oltp.Pacientes', 'U') IS NOT NULL DROP TABLE oltp.Pacientes;
IF OBJECT_ID('oltp.Odontologos', 'U') IS NOT NULL DROP TABLE oltp.Odontologos;
IF OBJECT_ID('oltp.Tratamientos', 'U') IS NOT NULL DROP TABLE oltp.Tratamientos;
GO


CREATE TABLE oltp.Pacientes (
    IdPaciente  BIGINT          NOT NULL PRIMARY KEY CLUSTERED,
    Genero      CHAR(1)         NOT NULL,
    Edad        SMALLINT        NOT NULL,
    Barrio      NVARCHAR(100) NOT NULL,
    Beca        BIT             NOT NULL DEFAULT 0,
    Hipertension  BIT           NOT NULL DEFAULT 0,
    Diabetes    BIT             NOT NULL DEFAULT 0,
    Alcoholismo   BIT           NOT NULL DEFAULT 0,
    Discapacidad  TINYINT       NOT NULL DEFAULT 0
);


CREATE TABLE oltp.Odontologos (
    IdOdontologo INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    Nombres     NVARCHAR(100) NOT NULL,
    Apellidos   NVARCHAR(100) NOT NULL,
    Especialidad NVARCHAR(100) NOT NULL,
    Activo      BIT             NOT NULL DEFAULT 1
);


CREATE TABLE oltp.Tratamientos (
    IdTratamiento INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    CodigoCPMS  VARCHAR(50)     NOT NULL,
    Descripcion   NVARCHAR(500)  NOT NULL,
    DuracionMeses INT           NOT NULL DEFAULT 1, -- Nuevo campo operativo
    Costo       DECIMAL(10,2)  NOT NULL
);
```

```
CREATE TABLE oltp.Citas (
    IdCita              INT             NOT NULL PRIMARY KEY CLUSTERED,
    IdPaciente          BIGINT          NOT NULL FOREIGN KEY REFERENCES oltp.Pacientes(IdPaciente),
    IdOdontologo        INT             NOT NULL FOREIGN KEY REFERENCES oltp.Odontologos(IdOdontologo),
    IdTratamiento       INT             NOT NULL,
    FechaProgramacion DATETIME2(0)  NOT NULL,
    FechaCita           DATE            NOT NULL,
    SMSRecibido         BIT             NOT NULL DEFAULT 0,
    NoShow              VARCHAR(3)      NOT NULL,
    CostoAplicado       DECIMAL(10,2) NOT NULL
);
GO


-- 4. TABLAS DATA MART (Modelo Dimensional Kimball)
IF OBJECT_ID('dw.Fact_Atenciones', 'U') IS NOT NULL DROP TABLE dw.Fact_Atenciones;
IF OBJECT_ID('dw.Dim_Paciente', 'U') IS NOT NULL DROP TABLE dw.Dim_Paciente;
IF OBJECT_ID('dw.Dim_Medico', 'U') IS NOT NULL DROP TABLE dw.Dim_Medico;
IF OBJECT_ID('dw.Dim_Tratamiento', 'U') IS NOT NULL DROP TABLE dw.Dim_Tratamiento;
IF OBJECT_ID('dw.Dim_Tiempo', 'U') IS NOT NULL DROP TABLE dw.Dim_Tiempo;
IF OBJECT_ID('dw.Resultados_Prediccion_IA', 'U') IS NOT NULL DROP TABLE dw.Resultados_Prediccion_IA;
GO


CREATE TABLE dw.Dim_Paciente (
    SK_Paciente  INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdPaciente   BIGINT         NOT NULL UNIQUE,
    Genero      CHAR(1)         NOT NULL,
    Edad        SMALLINT        NOT NULL,
    Barrio      NVARCHAR(100) NOT NULL
);


CREATE TABLE dw.Dim_Medico (
    SK_Medico   INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdOdontologo   INT          NOT NULL UNIQUE,
    NombreCompleto NVARCHAR(200) NOT NULL,
    Especialidad   NVARCHAR(100) NOT NULL
);


CREATE TABLE dw.Dim_Tratamiento (
    SK_Tratamiento INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdTratamiento  INT          NOT NULL,
    Descripcion NVARCHAR(500) NOT NULL,
    Duracion_Meses INT          NOT NULL, -- Nuevo campo
    Costo_Total DECIMAL(10,2) NOT NULL  -- Renombrado
);


CREATE TABLE dw.Dim_Tiempo (
    SK_Tiempo  INT      NOT NULL PRIMARY KEY CLUSTERED,
    Fecha       DATE            NOT NULL,
    Anio        SMALLINT        NOT NULL,
    Mes         TINYINT         NOT NULL,
    NombreMes  VARCHAR(12) NOT NULL,
    Trimestre  TINYINT  NOT NULL,       -- Nuevo campo
    Dia_Semana VARCHAR(15) NOT NULL        -- Nuevo campo
);


CREATE TABLE dw.Fact_Atenciones (
    ID_Hecho            INT IDENTITY(1,1) NOT NULL PRIMARY KEY CLUSTERED,
    IdCita              INT             NOT NULL UNIQUE, -- Necesario para el flujo ETL (no duplicar)
    SK_Paciente         INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Paciente(SK_Paciente),
    SK_Medico           INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Medico(SK_Medico),
    SK_Tratamiento      INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Tratamiento(SK_Tratamiento),
    SK_Tiempo           INT             NOT NULL FOREIGN KEY REFERENCES dw.Dim_Tiempo(SK_Tiempo),

    -- Métricas / Medidas
    Estado_Cita         VARCHAR(20)   NOT NULL,
    Tiempo_Espera_Min INT          NOT NULL,
    Monto_Pagado        DECIMAL(10,2) NOT NULL,

    -- Variables Calculadas para Análisis y Machine Learning
    Es_Atendido         INT             NOT NULL,
    Es_Ausencia         INT             NOT NULL
);


CREATE TABLE dw.Resultados_Prediccion_IA (
    IdCita              INT             NOT NULL PRIMARY KEY CLUSTERED,
    Probabilidad      DECIMAL(5,4)  NOT NULL,
    Riesgo              VARCHAR(20)   NOT NULL,
    Prediccion_Binary INT          NOT NULL,
    FechaEvaluacion   DATETIME          DEFAULT GETDATE()
);
GO
```

### 3.14.2 Script 2: Lógica de procesamiento (procedimientos almacenados y vistas)

**Código 3.2.** *02_Logica_Procesos_ETL.sql*

```
/* ====================================================================
   SCRIPT 2: LÓGICA DE PROCESAMIENTO (STORED PROCEDURES Y VISTAS)
   ==================================================================== */
USE DentalCenterDB;
GO


-- 1. PROCEDIMIENTO: CARGA OLTP
CREATE OR ALTER PROCEDURE stg.usp_CargarOLTP
AS
BEGIN
    SET NOCOUNT ON;

    -- Tratamientos
    INSERT INTO oltp.Tratamientos (CodigoCPMS, Descripcion, Costo, DuracionMeses)
    SELECT Codigo, Descripcion, ISNULL(TRY_CAST(REPLACE(Tarifa, ',', '.') AS DECIMAL(10,2)), 45.00), 1
    FROM stg.Raw_CPMS WHERE Codigo IS NOT NULL;


    IF NOT EXISTS (SELECT 1 FROM oltp.Tratamientos)
    BEGIN
        INSERT INTO oltp.Tratamientos (CodigoCPMS, Descripcion, Costo, DuracionMeses) VALUES
        ('CPMS-01', 'Consulta Odontológica General', 30.00, 1),
        ('CPMS-02', 'Profilaxis y Destartraje', 50.00, 1),
        ('CPMS-03', 'Curación con Resina Fotocurable', 70.00, 1),
        ('CPMS-04', 'Exodoncia Simple', 60.00, 1),
        ('CPMS-05', 'Endodoncia Unirradicular', 150.00, 2),
        ('CPMS-06', 'Ortodoncia - Control Mensual', 80.00, 12);
    END;

    -- Pacientes
    WITH PacientesUnicos AS (
        SELECT
                TRY_CAST(PatientId AS BIGINT) AS IdPaciente,
                UPPER(LEFT(Gender, 1)) AS Genero,
                TRY_CAST(Age AS SMALLINT) AS Edad,
                Neighbourhood AS Barrio,
                TRY_CAST(Scholarship AS BIT) AS Beca,
                TRY_CAST(Hipertension AS BIT) AS Hipertension,
                TRY_CAST(Diabetes AS BIT) AS Diabetes,
                TRY_CAST(Alcoholism AS BIT) AS Alcoholismo,
                TRY_CAST(Handcap AS TINYINT) AS Discapacidad,
                ROW_NUMBER() OVER (PARTITION BY TRY_CAST(PatientId AS BIGINT) ORDER BY TRY_CAST(AppointmentID AS
INT) DESC) AS FilaNum
        FROM stg.Raw_NoShow
        WHERE TRY_CAST(PatientId AS BIGINT) IS NOT NULL AND TRY_CAST(Age AS SMALLINT) BETWEEN 0 AND 120
    )
    INSERT INTO oltp.Pacientes (IdPaciente, Genero, Edad, Barrio, Beca, Hipertension, Diabetes, Alcoholismo,
Discapacidad)
    SELECT IdPaciente, Genero, Edad, Barrio, ISNULL(Beca, 0), ISNULL(Hipertension, 0), ISNULL(Diabetes, 0),
ISNULL(Alcoholismo, 0), ISNULL(Discapacidad, 0)
    FROM PacientesUnicos
    WHERE FilaNum = 1 AND IdPaciente NOT IN (SELECT IdPaciente FROM oltp.Pacientes);


    -- Citas
    WITH CitasUnicas AS (
        SELECT
                TRY_CAST(AppointmentID AS INT) AS IdCita,
                TRY_CAST(PatientId AS BIGINT) AS IdPaciente,
                (ABS(CHECKSUM(AppointmentID)) % 3) + 1 AS IdOdontologo,
                (ABS(CHECKSUM(AppointmentID, 7)) % (SELECT ISNULL(NULLIF(COUNT(*), 0), 1) FROM oltp.Tratamientos))
+ 1 AS IdTratamiento,
                TRY_CAST(LEFT(ScheduledDay, 19) AS DATETIME2) AS FechaProgramacion,
                TRY_CAST(LEFT(AppointmentDay, 10) AS DATE) AS FechaCita,
                CASE WHEN SMS_received = '1' THEN 1 ELSE 0 END AS SMSRecibido,
                NoShow,
                ROW_NUMBER() OVER (PARTITION BY TRY_CAST(AppointmentID AS INT) ORDER BY ScheduledDay DESC) AS
FilaNum
        FROM stg.Raw_NoShow
        WHERE TRY_CAST(AppointmentID AS INT) IS NOT NULL AND TRY_CAST(PatientId AS BIGINT) IS NOT NULL
    )
    INSERT INTO oltp.Citas (IdCita, IdPaciente, IdOdontologo, IdTratamiento, FechaProgramacion, FechaCita,
SMSRecibido, NoShow, CostoAplicado)
    SELECT c.IdCita, c.IdPaciente, c.IdOdontologo, c.IdTratamiento, c.FechaProgramacion, c.FechaCita,
c.SMSRecibido, c.NoShow, ISNULL(t.Costo, 50.00)
    FROM CitasUnicas c
    LEFT JOIN oltp.Tratamientos t ON t.IdTratamiento = c.IdTratamiento
    WHERE c.FilaNum = 1 AND c.IdCita NOT IN (SELECT IdCita FROM oltp.Citas) AND c.IdPaciente IN (SELECT IdPaciente
FROM oltp.Pacientes);
END;
GO


-- 2. PROCEDIMIENTO: CARGA DATA MART
CREATE OR ALTER PROCEDURE dw.usp_ETL_CargarDataMart
AS
BEGIN
    SET NOCOUNT ON;
```

```
    SET LANGUAGE Spanish; -- Para extraer días/meses en español

    INSERT INTO dw.Dim_Paciente (IdPaciente, Genero, Edad, Barrio)
    SELECT IdPaciente, Genero, Edad, Barrio FROM oltp.Pacientes WHERE IdPaciente NOT IN (SELECT IdPaciente FROM
dw.Dim_Paciente);

    INSERT INTO dw.Dim_Medico (IdOdontologo, NombreCompleto, Especialidad)
    SELECT IdOdontologo, Nombres + ' ' + Apellidos, Especialidad FROM oltp.Odontologos WHERE IdOdontologo NOT IN
(SELECT IdOdontologo FROM dw.Dim_Medico);


    -- Dim_Tratamiento actualizada
    INSERT INTO dw.Dim_Tratamiento (IdTratamiento, Descripcion, Duracion_Meses, Costo_Total)
    SELECT IdTratamiento, Descripcion, DuracionMeses, Costo
    FROM oltp.Tratamientos
    WHERE IdTratamiento NOT IN (SELECT IdTratamiento FROM dw.Dim_Tratamiento);


    -- Dim_Tiempo actualizada
    INSERT INTO dw.Dim_Tiempo (SK_Tiempo, Fecha, Anio, Mes, NombreMes, Trimestre, Dia_Semana)
    SELECT DISTINCT
        CAST(CONVERT(VARCHAR(8), FechaCita, 112) AS INT),
        FechaCita,
        YEAR(FechaCita),
        MONTH(FechaCita),
        DATENAME(MONTH, FechaCita),
        DATEPART(QUARTER, FechaCita),
        DATENAME(WEEKDAY, FechaCita)
    FROM oltp.Citas
    WHERE CAST(CONVERT(VARCHAR(8), FechaCita, 112) AS INT) NOT IN (SELECT SK_Tiempo FROM dw.Dim_Tiempo);


    -- Fact_Atenciones actualizada
    INSERT INTO dw.Fact_Atenciones (
        IdCita, SK_Paciente, SK_Medico, SK_Tratamiento, SK_Tiempo,
        Estado_Cita, Tiempo_Espera_Min, Monto_Pagado, Es_Atendido, Es_Ausencia
    )
    SELECT
        c.IdCita,
        dp.SK_Paciente,
        dm.SK_Medico,
        ISNULL(dt.SK_Tratamiento, 1),
        CAST(CONVERT(VARCHAR(8), c.FechaCita, 112) AS INT) AS SK_Tiempo,
        CASE WHEN c.NoShow = 'Yes' THEN 'Ausencia/No-Show' ELSE 'Atendido' END AS Estado_Cita,
        DATEDIFF(MINUTE, c.FechaProgramacion, CAST(c.FechaCita AS DATETIME2)) AS Tiempo_Espera_Min,
        c.CostoAplicado AS Monto_Pagado,
        CASE WHEN c.NoShow = 'Yes' THEN 0 ELSE 1 END AS Es_Atendido,
        CASE WHEN c.NoShow = 'Yes' THEN 1 ELSE 0 END AS Es_Ausencia
    FROM oltp.Citas c
    JOIN dw.Dim_Paciente dp ON c.IdPaciente = dp.IdPaciente
    JOIN dw.Dim_Medico dm ON c.IdOdontologo = dm.IdOdontologo
    LEFT JOIN dw.Dim_Tratamiento dt ON c.IdTratamiento = dt.IdTratamiento
    WHERE c.IdCita NOT IN (SELECT IdCita FROM dw.Fact_Atenciones);
END;
GO


-- 3. VISTAS ANALÍTICAS ACTUALIZADAS
CREATE OR ALTER VIEW dw.vw_KPI_TasaAbandono AS
SELECT
    t.Anio, t.Mes, t.NombreMes, p.Barrio,
    COUNT(*) AS TotalCitas,
    SUM(f.Es_Ausencia) AS CitasAbandonadas,
    CAST(SUM(f.Es_Ausencia) * 100.0 / NULLIF(COUNT(*), 0) AS DECIMAL(5,2)) AS PorcentajeAbandono
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON t.SK_Tiempo = f.SK_Tiempo
JOIN dw.Dim_Paciente p ON p.SK_Paciente = f.SK_Paciente
GROUP BY t.Anio, t.Mes, t.NombreMes, p.Barrio;
GO


CREATE OR ALTER VIEW dw.vw_KPI_IngresosEnRiesgo AS
SELECT
    t.Anio, t.NombreMes, m.Especialidad,
    SUM(f.Monto_Pagado) AS IngresoTotalEstimado,
    SUM(CASE WHEN f.Es_Ausencia = 1 THEN f.Monto_Pagado ELSE 0 END) AS IngresosEnRiesgoPerdidos
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON t.SK_Tiempo = f.SK_Tiempo
JOIN dw.Dim_Medico m ON m.SK_Medico = f.SK_Medico
GROUP BY t.Anio, t.NombreMes, m.Especialidad;
GO


CREATE OR ALTER VIEW dw.vw_Dataset_ML AS
SELECT
    f.ID_Hecho,
    p.Edad,
    f.Tiempo_Espera_Min,
    dt.Duracion_Meses,
    f.Monto_Pagado,
    f.Es_Ausencia AS Target_Abandono
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Paciente p ON p.SK_Paciente = f.SK_Paciente
JOIN dw.Dim_Tratamiento dt ON dt.SK_Tratamiento = f.SK_Tratamiento;
```

```
GO
```

### 3.14.3 Script 3: Ejecución del ETL y carga de datos (DML)

**Código 3.3.** *03_DML_Ejecucion_Cargas.sql*

```
/* ====================================================================
   SCRIPT 3: EJECUCIÓN ETL Y CARGA DE DATOS (DML)
   ==================================================================== */
USE DentalCenterDB;
GO


-- 1. LIMPIEZA DE TABLAS TEMPORALES (Staging)
TRUNCATE TABLE stg.Raw_NoShow;
TRUNCATE TABLE stg.Raw_CPMS;
GO


-- 2. CARGA DE ARCHIVOS CSV CRUDOS
-- (Recuerda modificar la ruta a una pública como C:\Datasets\ si tienes problemas de permisos)
BULK INSERT stg.Raw_NoShow
FROM 'C:\Users\MANFRED\Desktop\Proyecto_GADI_Clinica\05_Datasets\KaggleV2-May-2016.csv'
WITH (FORMAT = 'CSV', FIRSTROW = 2, FIELDTERMINATOR = ',', ROWTERMINATOR = '0x0a');


BULK INSERT stg.Raw_CPMS
FROM 'C:\Users\MANFRED\Desktop\Proyecto_GADI_Clinica\05_Datasets\cpms_odontologia.csv'
WITH (FORMAT = 'CSV', FIRSTROW = 2, FIELDTERMINATOR = ',', ROWTERMINATOR = '0x0a');
GO


-- 3. INSERCIÓN DE DATOS ESTÁTICOS INICIALES (Personal base)
IF NOT EXISTS (SELECT 1 FROM oltp.Odontologos)
BEGIN
    INSERT INTO oltp.Odontologos (Nombres, Apellidos, Especialidad) VALUES
    ('Carlos', 'Mendoza', 'Odontología General'),
    ('Lucía', 'Paredes', 'Endodoncia'),
    ('Jorge', 'Salas', 'Ortodoncia');
END;
GO


-- 4. EJECUCIÓN DE PROCEDIMIENTOS ALMACENADOS ETL
PRINT 'Iniciando carga hacia OLTP...';
EXEC stg.usp_CargarOLTP;
PRINT 'Carga OLTP finalizada.';


PRINT 'Iniciando carga hacia Data Mart...';
EXEC dw.usp_ETL_CargarDataMart;
PRINT 'Carga Data Mart finalizada.';
GO


-- 5. VERIFICACIÓN FINAL (Validar que las tablas tienen datos)
SELECT 'OLTP Pacientes' AS Tabla, COUNT(*) AS TotalRegistros FROM oltp.Pacientes
UNION ALL
SELECT 'OLTP Citas', COUNT(*) FROM oltp.Citas
UNION ALL
SELECT 'DW Dim_Paciente', COUNT(*) FROM dw.Dim_Paciente
UNION ALL
SELECT 'DW Fact_Atenciones', COUNT(*) FROM dw.Fact_Atenciones;
GO
```

## 3.15 Implementación de OLAP.

El procesamiento analítico en línea (OLAP, *Online Analytical Processing*) permite explorar los datos del Data Mart desde múltiples perspectivas —tiempo, paciente, odontólogo y tratamiento— y con distintos niveles de detalle, sin necesidad de reconstruir las consultas desde cero. En esta sección se describe cómo se implementó la capa OLAP sobre el esquema estrella dm de DentalCenterDB, de modo que la gerencia de la clínica pueda responder preguntas como dónde, cuándo y en qué especialidades se concentran las ausencias y los ingresos en riesgo.

### 3.15.1 Enfoque de implementación

Las soluciones OLAP se clasifican según la forma de almacenar los datos: **MOLAP** (cubo multidimensional precalculado), **ROLAP** (las agregaciones se calculan sobre tablas relacionales) y **HOLAP** (combinación de ambos). Dado que el Data Mart ya está modelado como esquema estrella en SQL Server y que su volumen es moderado (del orden de cien mil citas), se adoptó un enfoque **ROLAP**, complementado con un **modelo semántico en Power BI** para la exploración visual. Las razones son las siguientes:

- **Aprovecha el modelo existente.** El esquema estrella Fact_Atenciones + cuatro dimensiones actúa directamente como el cubo, sin duplicar datos en una estructura adicional.
- **No requiere infraestructura adicional.** Las agregaciones se calculan con T-SQL estándar (GROUP BY, ROLLUP, CUBE, PIVOT) y los resultados se actualizan automáticamente cada vez que se ejecuta el ETL.
- **Integra el análisis visual.** Power BI consume el mismo modelo dimensional y permite hacer *drill-down*, filtros y segmentaciones de forma interactiva.

**Tabla 3.19.** *Capas de la implementación OLAP.*

| Capa | Componente | Función |
|---|---|---|
| Almacenamiento | Esquema dm (Fact_Atenciones y dimensiones) | Almacena los hechos y sus dimensiones; es la base del cubo. |
| Acceso al cubo | Vista dm.vw_Cubo_Atenciones | Presenta el esquema estrella aplanado, con todas las dimensiones y medidas en una sola estructura. Se crea después del Script 3. |
| Consulta OLAP | T-SQL con ROLLUP, CUBE y PIVOT | Ejecuta las operaciones OLAP: *roll-up*, *drill-down*, *slice*, *dice* y *pivot*. |
| Presentación | Modelo semántico y reportes en Power BI | Medidas DAX, jerarquías y visualizaciones interactivas para los usuarios de negocio. |

### 3.15.2 Definición del cubo

El cubo de atenciones tiene como tabla de hechos dm.Fact_Atenciones (una fila por cita) y cuatro dimensiones. Cada celda del cubo corresponde a la intersección de un valor de cada dimensión —por ejemplo, una especialidad, un barrio y un mes— y contiene las medidas calculadas para ese conjunto de citas.

**Figura 3.4.** *Cubo OLAP de atenciones con sus dimensiones, jerarquías y medidas.*

**Tabla 3.20.** *Dimensiones y jerarquías del cubo.*

| Dimensión | Jerarquía (niveles) | Atributos adicionales |
|---|---|---|
| Tiempo | Año → Trimestre → Mes → Fecha | Dia_Semana, para analizar patrones por día. |
| Paciente | Barrio → Paciente | Genero, Edad y Rango_Etario, para segmentar. |
| Médico | Especialidad → Odontólogo | — |
| Tratamiento | Tratamiento (descripción) | Duracion_Meses y Costo_Total. |

**Tabla 3.21.** *Medidas del cubo.*

| Medida | Cálculo en SQL | Comportamiento |
|---|---|---|
| Total de citas | COUNT(*) | Aditiva (conteo). |
| Citas atendidas | SUM(Es_Atendido) | Aditiva. |
| Ausencias | SUM(Es_Ausencia) | Aditiva. |
| % de ausencia | SUM(Es_Ausencia) * 100.0 / COUNT(*) | Calculada; no se suma, se recalcula en cada nivel. |
| Ingreso cobrado | SUM(Monto_Pagado) | Aditiva; vale 0 en las citas con ausencia. |
| Ingresos en riesgo | SUM(Ingreso_En_Riesgo) | Aditiva; costo del tratamiento (Costo_Total) de las citas con ausencia. |
| Espera promedio (días) | AVG(Tiempo_Espera_Dias) | No aditiva; se promedia. |

### 3.15.3 Vista de acceso al cubo

Para que las consultas OLAP no repitan en cada ocasión los cuatro *joins* del esquema estrella, se creó la vista dm.vw_Cubo_Atenciones, que reúne en una sola estructura los atributos de todas las dimensiones y las medidas a nivel de cita. Como Monto_Pagado vale 0 cuando el paciente no asiste, la columna Ingreso_En_Riesgo se calcula con el costo del tratamiento (Costo_Total) de las citas con ausencia, y es la base de la medida de ingresos en riesgo. La vista dm.vw_KPI_TasaAbandono del Script 2 puede entenderse como un corte ya agregado de este mismo cubo.

**Código 3.4.** *Vista de acceso al cubo OLAP (dw.vw_Cubo_Atenciones).*

```
CREATE OR ALTER VIEW dw.vw_Cubo_Atenciones AS
SELECT
    f.ID_Hecho, f.IdCita,
    t.Fecha, t.Anio, t.Trimestre, t.Mes, t.NombreMes, t.Dia_Semana,
    p.Barrio, p.Genero, p.Edad,
    m.Especialidad, m.NombreCompleto AS Medico,
    tr.Descripcion AS Tratamiento, tr.Duracion_Meses,
    f.Estado_Cita, f.Tiempo_Espera_Min, f.Monto_Pagado,
    f.Es_Atendido, f.Es_Ausencia,
    CASE WHEN f.Es_Ausencia = 1 THEN f.Monto_Pagado ELSE 0 END AS Ingreso_En_Riesgo
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo      t  ON t.SK_Tiempo       = f.SK_Tiempo
JOIN dw.Dim_Paciente    p  ON p.SK_Paciente     = f.SK_Paciente
JOIN dw.Dim_Medico      m  ON m.SK_Medico       = f.SK_Medico
JOIN dw.Dim_Tratamiento tr ON tr.SK_Tratamiento = f.SK_Tratamiento;
GO
```

Como control de calidad, el número de citas de la vista debe coincidir con el de la tabla de hechos; si ambos valores son iguales, ninguna cita quedó fuera del cubo por falta de una dimensión:

```
SELECT (SELECT COUNT(*) FROM dw.Fact_Atenciones)   AS CitasEnHechos,
       (SELECT COUNT(*) FROM dw.vw_Cubo_Atenciones) AS CitasEnCubo;
```

### 3.15.4 Operaciones OLAP

Las operaciones OLAP clásicas se implementaron con consultas T-SQL sobre la vista del cubo. La tabla siguiente resume cada operación, su finalidad y la instrucción utilizada.

**Tabla 3.22.** *Operaciones OLAP implementadas.*

| Operación | Qué hace | Implementación en T-SQL |
|---|---|---|
| Roll-up | Agrega los datos hacia un nivel superior de la jerarquía (de mes a trimestre y a año). | GROUP BY ROLLUP (Anio, Trimestre, Mes) |
| Drill-down | Baja a un nivel de mayor detalle (de mes a fecha). | Filtro por año y mes con GROUP BY Fecha. |
| Slice | Fija un único valor de una dimensión. | WHERE Especialidad = N'Ortodoncia' |
| Dice | Filtra varias dimensiones a la vez y obtiene un subcubo. | WHERE con IN y BETWEEN sobre varias columnas. |
| Pivot | Rota los ejes: valores de una dimensión pasan a ser columnas. | Operador PIVOT sobre Dia_Semana. |
| Cubo completo | Calcula todas las combinaciones de agregación posibles. | GROUP BY CUBE (Especialidad, Trimestre) |

#### Roll-up: de mes a trimestre y a año

ROLLUP produce, en una sola consulta, el detalle por mes, el subtotal por trimestre, el subtotal por año y el total general. La columna NivelAgregacion (GROUPING_ID) indica el nivel de cada fila: 0 para el detalle y valores mayores para los subtotales.

**Código 3.5.** *Operación roll-up.*

```
USE DentalCenterDB;
GO

SELECT
    CASE WHEN GROUPING(t.Anio) = 1 THEN 'TOTAL HISTÓRICO' ELSE CAST(t.Anio AS VARCHAR) END AS Anio,
    CASE WHEN GROUPING(t.Trimestre) = 1 THEN 'Subtotal Año' ELSE 'Trimestre ' + CAST(t.Trimestre AS VARCHAR) END AS
Trimestre,
    CASE WHEN GROUPING(t.NombreMes) = 1 THEN 'Subtotal Trimestre' ELSE t.NombreMes END AS Mes,
    COUNT(f.ID_Hecho) AS Total_Citas_Programadas,
    SUM(f.Es_Ausencia) AS Total_Abandonos,
    SUM(f.Monto_Pagado) AS Ingresos_Proyectados
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON f.SK_Tiempo = t.SK_Tiempo
GROUP BY ROLLUP (t.Anio, t.Trimestre, t.NombreMes);
```

Resultados | Mensajes

| | Anio | Trimestre | Mes | Total_Citas_Programadas | Total_Abandonos | Ingresos_Proyectados |
|---|---|---|---|---|---|---|
| 1 | 2016 | Trimestre 2 | Abril | 3235 | 633 | 145575.00 |
| 2 | 2016 | Trimestre 2 | Junio | 26448 | 4882 | 1190160.00 |
| 3 | 2016 | Trimestre 2 | Mayo | 80838 | 16804 | 3637710.00 |
| 4 | 2016 | Trimestre 2 | Subtotal Trimestre | 110521 | 22319 | 4973445.00 |
| 5 | 2016 | Subtotal Año | Subtotal Trimestre | 110521 | 22319 | 4973445.00 |
| 6 | TOTAL HISTÓRICO | Subtotal Año | Subtotal Trimestre | 110521 | 22319 | 4973445.00 |

### Drill-down: de mes a fecha

Partiendo de un mes de interés, se desciende al nivel de fecha para identificar los días con mayor ausencia. Los valores de año y mes son parámetros de ejemplo y pueden modificarse.

**Código 3.6.** *Operación drill-down.*

```
CREATE OR ALTER VIEW dw.vw_Cubo_Atenciones AS
SELECT
    f.ID_Hecho,
    t.Fecha,
    t.Anio,
    t.Mes,
    t.Trimestre,
    t.NombreMes,
    t.Dia_Semana,
    p.Barrio,
    m.Especialidad,
    tr.Descripcion AS Tratamiento,
    f.Tiempo_Espera_Min,
    f.Monto_Pagado,
    f.Es_Atendido,
    f.Es_Ausencia
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON f.SK_Tiempo = t.SK_Tiempo
JOIN dw.Dim_Paciente p ON f.SK_Paciente = p.SK_Paciente
JOIN dw.Dim_Medico m ON f.SK_Medico = m.SK_Medico
JOIN dw.Dim_Tratamiento tr ON f.SK_Tratamiento = tr.SK_Tratamiento;
GO
```

### Slice: una sola especialidad

El *slice* fija una dimensión en un valor concreto y mantiene el resto del cubo. En este caso se analiza la evolución mensual de una única especialidad.

**Código 3.7.** *Operación slice.*

```
SELECT
    Anio,
    Mes,
    NombreMes,
    COUNT(*) AS TotalCitas,
    SUM(Es_Ausencia) AS Ausencias,
    -- Calculamos el ingreso en riesgo multiplicando la ausencia (1 o 0) por el monto
    SUM(Es_Ausencia * Monto_Pagado) AS IngresosEnRiesgo
FROM dw.vw_Cubo_Atenciones
WHERE Especialidad = N'Ortodoncia'
GROUP BY Anio, Mes, NombreMes
ORDER BY Anio, Mes;
```

| | Anio | Mes | NombreMes | TotalCitas | Ausencias | IngresosEnRiesgo |
|---|---|---|---|---|---|---|
| 1 | 2016 | 4 | Abril | 1030 | 200 | 9000.00 |
| 2 | 2016 | 5 | Mayo | 27024 | 5683 | 255735.00 |
| 3 | 2016 | 6 | Junio | 8827 | 1647 | 74115.00 |

### Dice: subcubo por varias dimensiones

El *dice* restringe varias dimensiones simultáneamente: especialidad, género y rango etario (este último ya calculado en Dim_Paciente). La cláusula HAVING descarta grupos con muy pocas citas, cuyos porcentajes no serían representativos.

**Código 3.8.** *Operación dice.*

```
CREATE OR ALTER VIEW dw.vw_Cubo_Atenciones AS
SELECT
    m.Especialidad,
    p.Genero,
    CASE
        WHEN p.Edad < 18 THEN 'Menor de 18'
        WHEN p.Edad BETWEEN 18 AND 35 THEN '18 a 35'
        WHEN p.Edad BETWEEN 36 AND 60 THEN '36 a 60'
        ELSE 'Mayor de 60'
    END AS Rango_Edad,
    COUNT(f.ID_Hecho) AS Total_Citas,
    SUM(CAST(f.Es_Atendido AS INT)) AS Total_Atendidos,
    SUM(CAST(f.Es_Ausencia AS INT)) AS Total_Ausencias,
    ROUND(CAST(SUM(CAST(f.Es_Ausencia AS INT)) AS FLOAT) / NULLIF(COUNT(f.ID_Hecho), 0) * 100, 2) AS
Pct_Ausentismo,
```

```
    ROUND(AVG(CAST(f.Tiempo_Espera_Min AS FLOAT)), 2) AS Promedio_Espera_Min,
    SUM(f.Monto_Pagado) AS Monto_Total
FROM dw.Fact_Atenciones f
JOIN dw.Dim_Tiempo t ON f.SK_Tiempo = t.SK_Tiempo
JOIN dw.Dim_Paciente p ON f.SK_Paciente = p.SK_Paciente
JOIN dw.Dim_Medico m ON f.SK_Medico = m.SK_Medico
JOIN dw.Dim_Tratamiento tr ON f.SK_Tratamiento = tr.SK_Tratamiento
WHERE
    -- Operación DICE: Selección multidimensional simultánea
    m.Especialidad IN ('Ortodoncia', 'Endodoncia', 'Odontopediatría')
    AND p.Genero IN ('F', 'M')
    AND p.Edad BETWEEN 18 AND 60
GROUP BY
    m.Especialidad,
    p.Genero,
    CASE
        WHEN p.Edad < 18 THEN 'Menor de 18'
        WHEN p.Edad BETWEEN 18 AND 35 THEN '18 a 35'
        WHEN p.Edad BETWEEN 36 AND 60 THEN '36 a 60'
        ELSE 'Mayor de 60'
    END
HAVING
    COUNT(f.ID_Hecho) >= 10;
GO
```

## Pivot: ausencias por especialidad y día de la semana

El *pivot* gira el eje de los días de la semana para mostrarlos como columnas y compararlos lado a lado entre especialidades. Los nombres de los días coinciden con los almacenados en `Dim_Tiempo`, que se generan en español durante el ETL.

**Código 3.9.** *Operación pivot.*

```
SELECT Especialidad,
       [Lunes], [Martes], [Miercoles], [Jueves], [Viernes], [Sabado], [Domingo]
FROM (
    SELECT Especialidad, Dia_Semana, Es_Ausencia
    FROM dw.vw_Cubo_Atenciones
) AS Origen
PIVOT (
    SUM(Es_Ausencia)
    FOR Dia_Semana IN ([Lunes], [Martes], [Miercoles], [Jueves], [Viernes], [Sabado], [Domingo])
) AS TablaPivote
ORDER BY Especialidad;
```

| | Especialidad | Lunes | Martes | Miercoles | Jueves | Viernes | Sabado | Domingo |
|---|---|---|---|---|---|---|---|---|
| 1 | Endodoncia | 1548 | 1699 | NULL | 1144 | 1332 | NULL | NULL |
| 2 | Odontología General | 1548 | 1700 | NULL | 1079 | 1379 | NULL | NULL |
| 3 | Ortodoncia | 1594 | 1753 | NULL | 1115 | 1326 | NULL | NULL |

## Cubo completo: todas las combinaciones

`CUBE` calcula las agregaciones de todas las combinaciones de las columnas indicadas: el detalle por especialidad y trimestre, los totales por especialidad, los totales por trimestre y el total general.

**Código 3.10.** *Agregación con CUBE.*

```
SELECT
    Especialidad,
    Trimestre,
    COUNT(*) AS TotalCitas,
    -- Reemplazamos Ingreso_En_Riesgo por la fórmula matemática
    SUM(Es_Ausencia * Monto_Pagado) AS IngresosEnRiesgo,
    GROUPING_ID(Especialidad, Trimestre) AS Nivel
FROM dw.vw_Cubo_Atenciones
GROUP BY CUBE (Especialidad, Trimestre)
ORDER BY Nivel, Especialidad, Trimestre;
```

| | Especialidad | Trimestre | TotalCitas | IngresosEnRiesgo | Nivel |
|---|---|---|---|---|---|
| 1 | Endodoncia | 2 | 36793 | 333765.00 | 0 |
| 2 | Odontología General | 2 | 36847 | 331740.00 | 0 |
| 3 | Ortodoncia | 2 | 36881 | 338850.00 | 0 |
| 4 | Endodoncia | NULL | 36793 | 333765.00 | 1 |
| 5 | Odontología General | NULL | 36847 | 331740.00 | 1 |
| 6 | Ortodoncia | NULL | 36881 | 338850.00 | 1 |
| 7 | NULL | 2 | 110521 | 1004355.00 | 2 |
| 8 | NULL | NULL | 110521 | 1004355.00 | 3 |

### 3.15.5 Optimización del rendimiento

Al ser un cubo ROLAP, cada consulta recalcula las agregaciones sobre la tabla de hechos. Para acelerar este tipo de consultas analíticas, que leen pocas columnas sobre muchas filas, se propone un índice *columnstore* no agrupado sobre las columnas que intervienen en los cálculos.

**Código 3.11.** *Índice columnstore sobre la tabla de hechos.*

```
CREATE NONCLUSTERED COLUMNSTORE INDEX NCCI_Fact_Atenciones
ON dw.Fact_Atenciones (
    SK_Paciente, SK_Medico, SK_Tratamiento, SK_Tiempo,
    Estado_Cita, Tiempo_Espera_Min, Monto_Pagado, Es_Atendido, Es_Ausencia
);
```

Dado que el Script 1 elimina y vuelve a crear las tablas del Data Mart, este índice debe crearse después de la carga inicial, y conviene recrearlo cuando se reconstruya la estructura.

### 3.15.6 Modelo semántico en Power BI

Para la exploración visual, Power BI se conecta a las tablas del esquema dm y reproduce el cubo mediante un modelo semántico: las relaciones del esquema estrella, las jerarquías de cada dimensión y las medidas calculadas en DAX.

**Tabla 3.23.** *Relaciones del modelo semántico.*

| Tabla (lado 1) | Tabla (lado N) | Columna y cardinalidad |
|---|---|---|
| Dim_Paciente | Fact_Atenciones | SK_Paciente; uno a muchos. |
| Dim_Medico | Fact_Atenciones | SK_Medico; uno a muchos. |
| Dim_Tratamiento | Fact_Atenciones | SK_Tratamiento; uno a muchos. |
| Dim_Tiempo | Fact_Atenciones | SK_Tiempo; uno a muchos. |
| Fact_Atenciones | Resultados_Prediccion_IA | IdCita; uno a muchos (uno a uno si cada cita se evalúa una sola vez), para cruzar el riesgo predicho con las dimensiones. |

En el modelo, Dim_Tiempo se marca como tabla de fechas (columna Fecha) y se define la jerarquía de calendario Año → Trimestre → Mes → Fecha. El nombre del mes se ordena por la columna Mes, y el día de la semana por una columna numérica auxiliar, de modo que las visualizaciones respeten el orden cronológico en lugar del alfabético.

**Tabla 3.24.** *Medidas DAX del modelo.*

| Medida | Expresión DAX | Descripción |
|---|---|---|
| Total Citas | COUNTROWS(Fact_Atenciones) | Número de citas. |
| Citas Atendidas | SUM(Fact_Atenciones[Es_Atendido]) | Citas a las que el paciente asistió. |
| Ausencias | SUM(Fact_Atenciones[Es_Ausencia]) | Citas a las que el paciente no asistió. |
| % Ausencia | DIVIDE([Ausencias], [Total Citas]) | Tasa de abandono. |
| Ingreso Cobrado | SUM(Fact_Atenciones[Monto_Pagado]) | Ingreso efectivamente cobrado (las ausencias aportan 0). |
| Ingresos en Riesgo | SUMX(FILTER(Fact_Atenciones, Fact_Atenciones[Es_Ausencia] = 1), RELATED(Dim_Tratamiento[Costo_Total])) | Costo del tratamiento de las citas con ausencia. |
| Espera Promedio (días) | AVERAGE(Fact_Atenciones[Tiempo_Espera_Dias]) | Tiempo de espera promedio, en días. |

Con este modelo, el usuario puede hacer *drill-down* sobre la jerarquía de tiempo, segmentar por barrio, especialidad o tratamiento, y combinar los indicadores históricos con la probabilidad de ausencia calculada por el modelo de inteligencia artificial, que alimenta además el simulador financiero (*What-If*) del tablero.

**[Insertar aquí la captura del modelo de relaciones de Power BI]**

**[Insertar aquí la captura de una matriz o tablero de Power BI con drill-down por año, trimestre y mes]**

### 3.15.7 Preguntas de negocio que responde el cubo

La siguiente tabla relaciona preguntas de gestión de la clínica con la operación OLAP que las resuelve.

**Tabla 3.25.** *Preguntas de negocio y operación OLAP asociada.*

| Pregunta de negocio | Operación | Dimensiones involucradas |
|---|---|---|
| ¿Cómo evoluciona la tasa de ausencia de mes a mes, por trimestre y por año? | Roll-up | Tiempo |
| ¿Qué días concretos de un mes concentran más ausencias? | Drill-down | Tiempo |
| ¿Cuántos ingresos se pierden en una especialidad determinada? | Slice | Médico, Tiempo |
| ¿En qué barrios es más alta la ausencia de mujeres jóvenes atendidas en endodoncia y ortodoncia? | Dice | Médico, Paciente |
| ¿Qué especialidad tiene más ausencias los | Pivot | Médico, Tiempo |

| | | |
|---|---|---|
| lunes frente a los viernes? | | |
| ¿Cuál es el total general, por especialidad y por trimestre, de ingresos en riesgo? | Cube | Médico, Tiempo |

3.16 Campos calculados y KPI.

Los indicadores del sistema se calculan en tres niveles: (a) campos calculados durante el ETL y almacenados en las dimensiones y en la tabla de hechos; (b) indicadores agregados expuestos por las vistas analíticas del Script 2; y (c) medidas del modelo semántico de Power BI, definidas en la sección 3.15.6. Esta organización traslada la lógica de negocio a la capa de datos, de modo que cualquier herramienta de consulta obtenga los mismos valores. La Tabla 3.26 detalla cada campo e indicador, su lógica de cálculo y su utilidad para la gestión de la clínica.

**Tabla 3.26.** *Campos calculados e indicadores clave (KPI) del Data Mart.*

| Nombre | Nivel / objeto | Lógica o fórmula (según el SQL) | Interpretación y utilidad para el negocio |
|---|---|---|---|
| Estado_Cita | Campo calculado, dm.Fact_Atenciones | CASE WHEN NoShow = 'Yes' THEN 'Ausencia/No-Show' ELSE 'Atendido' END | Traduce el resultado Yes/No del origen a una etiqueta legible. Se usa como categoría en segmentadores y leyendas. |
| Es_Atendido | Campo calculado (indicador), dm.Fact_Atenciones | CASE WHEN NoShow = 'Yes' THEN 0 ELSE 1 END | Vale 1 si el paciente asistió. Es aditivo: su suma da el número de citas atendidas. |
| Es_Ausencia | Campo calculado (indicador), dm.Fact_Atenciones | CASE WHEN NoShow = 'Yes' THEN 1 ELSE 0 END | Vale 1 si el paciente no asistió. Su suma da las ausencias y, dividida entre el total de citas, la tasa de inasistencia. Es la base de la variable objetivo del modelo predictivo. |
| Tiempo_Espera_Dias | Campo calculado (medida), dm.Fact_Atenciones | DATEDIFF(DAY, CAST(FechaPrograma cion AS DATE), FechaCita) | Días entre la programación y la fecha de la cita. No es aditivo: se analiza con promedio, mínimo y máximo. Permite evaluar si una mayor anticipación se asocia con más ausencias. |
| Monto_Pagado | Campo calculado (medida), dm.Fact_Atenciones | CASE WHEN NoShow = 'Yes' THEN 0 ELSE CostoAplicado END | Ingreso efectivamente percibido. Es aditivo y vale 0 en las ausencias, por lo que mide el ingreso cobrado y no el ingreso potencial. |

| | | | |
|---|---|---|---|
| SMSRecibido | Indicador copiado, dm.Fact_Atenciones | CASE WHEN SMS_received = '1' THEN 1 ELSE 0 END (en la carga al OLTP) | Indica si el paciente recibió el recordatorio. Permite comparar la asistencia entre quienes lo recibieron y quienes no. |
| Rango_Etario | Campo calculado, dm.Dim_Paciente | CASE sobre Edad: 0-17, 18-29, 30-44, 45-59 y 60 años a más | Segmenta a los pacientes por tramo de edad para identificar los perfiles con mayor inasistencia. |
| SK_Tiempo, Anio, Mes, NombreMes, Trimestre, Dia_Semana | Campos derivados, dm.Dim_Tiempo | CONVERT(VARCHAR(8), FechaCita, 112), YEAR, MONTH, DATENAME(MONTH, …), DATEPART(QUARTER, …), DATENAME(WEEKDAY, …) | Habilitan la jerarquía Año → Trimestre → Mes → Fecha y el análisis de patrones estacionales y por día de la semana. |
| TotalCitas | KPI, dm.vw_KPI_TasaAbandono | COUNT(*) por año, mes y barrio | Volumen de citas programadas en cada corte. Es el denominador de la tasa de abandono. |
| CitasAbandonadas | KPI, dm.vw_KPI_TasaAbandono | SUM(Es_Ausencia) por año, mes y barrio | Número de citas a las que el paciente no asistió. Cuantifica el problema en cada barrio y periodo. |
| PorcentajeAbandono | KPI, dm.vw_KPI_TasaAbandono | CAST(SUM(Es_Ausencia) * 100.0 / NULLIF(COUNT(*), 0) AS DECIMAL(5,2)) | Porcentaje de citas ausentes. Es el KPI principal de retención. Se recalcula en cada nivel y no debe sumarse. |
| Costo_Tratamiento_Sugerido | Variable explicativa, dm.vw_Dataset_ML | dm.Dim_Tratamiento.Costo_Total | Costo de catálogo del tratamiento. Se usa en lugar de Monto_Pagado porque este vale 0 en las ausencias y revelaría la variable objetivo. |
| Mes_Cita, DiaSemana_Cita | Variables explicativas, dm.vw_Dataset_ML | DATEPART(MONTH, Fecha) y DATEPART(WEEKDAY, Fecha) | Capturan la estacionalidad mensual y semanal para el modelo predictivo. |
| Target_Inasistencia | Variable objetivo, dm.vw_Dataset_ML | Es_Ausencia AS Target_Inasistencia | Etiqueta supervisada: 1 si la cita terminó en ausencia y 0 si el paciente asistió. |
| Ingreso_En_Riesgo | Campo calculado, dm.vw_Cubo_Atenciones (sección 3.15.3) | CASE WHEN Es_Ausencia = 1 THEN Costo_Total ELSE 0 END | Ingreso que la clínica deja de percibir por las citas ausentes, valorado con el costo del tratamiento. Es la base de la medida de ingresos en riesgo y del simulador. |

| | | | |
|---|---|---|---|
| Probabilidad_Inasistencia, Nivel_Riesgo, Prediccion_Binary | Resultado del modelo, dm.Resultados_Prediccion_IA | Escritos por el proceso de scoring en Python por cada cita evaluada (Probabilidad_Inasistencia con formato DECIMAL(5,4)) | Estiman la probabilidad de ausencia de cada cita, su nivel de alerta (Alto, Medio o Bajo) y la clasificación binaria. Permiten priorizar las acciones de recordatorio y fidelización. |

Los KPI de las filas 9 a 11 provienen de la vista dm.vw_KPI_TasaAbandono, que agrega la tabla de hechos por Dim_Tiempo y Dim_Paciente. El Script 2 define únicamente dos vistas analíticas, dm.vw_KPI_TasaAbandono y dm.vw_Dataset_ML. El indicador de ingresos en riesgo se obtiene de la vista del cubo OLAP, que se crea después del Script 3. Las medidas de Power BI (Total Citas, Citas Atendidas, Ausencias, % Ausencia, Ingreso Cobrado, Ingresos en Riesgo y Espera Promedio en días) reproducen estos cálculos en DAX, tal como se detalla en la Tabla 3.24.

## 3.17 Diseño de dashboards y reportes.

El tablero de Power BI consume el esquema estrella del esquema dm (Fact_Atenciones y las dimensiones Dim_Tiempo, Dim_Paciente, Dim_Medico y Dim_Tratamiento) y la tabla dm.Resultados_Prediccion_IA, relacionada con la tabla de hechos por IdCita. Se organiza en tres páginas lógicas que siguen un recorrido de lo descriptivo a lo predictivo y prescriptivo: (1) resumen ejecutivo, (2) análisis de inasistencias y perfiles, y (3) predicción de riesgo y simulador What-If. Todas las páginas comparten un panel de segmentadores sincronizados (año, trimestre, especialidad y barrio), de modo que los filtros aplicados en una página se mantienen en las demás. El diseño busca responder las preguntas de negocio de la sección 3.2 y permitir el recorrido *drill-down* desde el indicador agregado hasta la cita individual.

## 3.18 Módulo de Machine Learning.

Para abordar la retención de pacientes, el problema se modeló como una tarea de aprendizaje supervisado de clasificación binaria. El objetivo fue predecir si un paciente completaría su tratamiento (Clase 0) o lo abandonaría (Clase 1), utilizando el historial clínico y transaccional consolidado en el Data Mart.

**Selección y Preparación de Datos**

Se extrajo la sábana de datos consolidada cruzando la tabla de hechos *Fact_Atenciones* con las dimensiones de Paciente y Tratamiento. Durante el Análisis Exploratorio de Datos (EDA), se evaluaron variables como el tiempo promedio de espera, las ausencias acumuladas, la edad del paciente y el porcentaje del monto pagado respecto al costo total del tratamiento. La variable objetivo, *Target_Abandono*, se definió empíricamente: si la proporción de ausencias de un paciente supera el 25% del total de sus citas programadas, se etiquetó como abandono (Clase 1).

**Comparación de Algoritmos**

El conjunto de datos se dividió en entrenamiento (80%) y validación (20%), aplicando estratificación para mantener la proporción de la clase minoritaria (abandonos). Se entrenaron y evaluaron dos algoritmos supervisados:

- Regresión Logística: Seleccionada como modelo base (baseline) por su interpretabilidad matemática y simplicidad computacional.
- Random Forest: Seleccionado por su capacidad intrínseca para manejar variables con distribuciones no normales y capturar interacciones complejas no lineales entre predictores, común en el comportamiento humano.

**Justificación y Selección del Modelo**

La evaluación no se limitó a la exactitud global (Accuracy), sino que se priorizó el Recall (Sensibilidad). En el contexto del centro dental, el costo de oportunidad de perder un paciente sin intentar retenerlo (Falso Negativo) es significativamente mayor que el esfuerzo operativo de

realizar una llamada de seguimiento a un paciente que finalmente sí iba a continuar (Falso Positivo).

Tras evaluar las métricas en el conjunto de prueba, Random Forest demostró un desempeño superior, especialmente en la métrica F1-score (que equilibra Precision y Recall). Adicionalmente, este algoritmo permitió extraer la importancia de las variables (Feature Importance), confirmando cuantitativamente que factores como el "*Costo_Tratamiento*" y el "*Prom_Tiempo_Espera*" son los determinantes principales del abandono, alineándose con estudios previos en clínicas odontológicas (Meza Rincón, 2025).

**Integración y Scoring Predictivo**

El modelo Random Forest entrenado se utilizó para calificar (scoring) a todos los pacientes activos. Las predicciones probabilísticas (de 0.0 a 1.0) se categorizaron en tres niveles de alerta: Riesgo Alto (> 0.65), Riesgo Medio (0.35 - 0.64) y Riesgo Bajo (< 0.35). Estos resultados se inyectaron directamente en la tabla *Resultados_Prediccion_IA* del Data Mart, permitiendo que el dashboard de Power BI consuma esta clasificación para habilitar el simulador de retornos económicos y la toma de decisiones gerenciales.

## 3.19 Integración BI + IA.

## 3.20 Resultados y recomendaciones.

**El Desafío del Desbalance de Clases (Accuracy Paradox)**

Durante la fase inicial de entrenamiento, se identificó un marcado desbalance en la variable objetivo, dado que históricamente la gran mayoría de las citas resultan en asistencia. Esto generó un fenómeno conocido como la "paradoja de la exactitud" (Accuracy Paradox): los modelos base alcanzaban una exactitud (Accuracy) cercana al 80% simplemente asumiendo que todos los pacientes asistirían, resultando en una sensibilidad (Recall) operativa del 0%. El modelo era incapaz de detectar los verdaderos casos de inasistencia.

**Ajuste Estratégico y Reglas de Negocio**

Para alinear el algoritmo con los objetivos de la clínica, se priorizó la métrica de Sensibilidad (Recall) sobre la Exactitud Global. En el contexto odontológico, el costo de un Falso Positivo (enviar un SMS o realizar una llamada preventiva a un paciente que sí iba a asistir) es operativo y marginal. Por el contrario, el costo de un Falso Negativo (no detectar a un paciente que terminará dejando la silla vacía) representa una pérdida financiera directa.

Se aplicó una técnica de penalización algorítmica (class_weight='balanced') y se ajustó el umbral de decisión lógico al 40% (0.40). Con esta calibración, el modelo Random Forest logró un Recall del 92.29%, demostrando una altísima capacidad para capturar proactivamente a los pacientes en riesgo de inasistencia.

**Análisis de Variables Determinantes (Feature Importance)**

La extracción de la importancia de variables del modelo Random Forest proporciona la evidencia empírica que sustenta las nuevas políticas de gestión de la clínica. El análisis arrojó los siguientes

factores críticos:

- **Tiempo de Espera (Tiempo_Espera_Dias):** Destaca como el predictor más fuerte con una importancia relativa cercana al 70%. Se comprueba cuantitativamente que la brecha de días entre el momento del agendamiento y la fecha efectiva de la cita es el mayor detonante del ausentismo.
- **Edad del Paciente:** Se posiciona como el segundo factor más relevante, demostrando que el nivel de compromiso y asistencia varía significativamente según el rango demográfico.
- **Gestión de Comunicación (SMSRecibido):** Ocupa el tercer lugar en importancia, validando matemáticamente que el envío de recordatorios no es un esfuerzo en vano, sino una variable que altera directamente la probabilidad de asistencia del paciente.

# Referencias Bibliográficas


[1] E. E. Arosemena Doss, "Indicadores claves de desempeño y su aplicación en la gerencia estratégica de las empresas de salud," *Odontología Vital*, vol. 2, no. 37, pp. 50–66, 2022. [En línea]. Disponible en: https://www.scielo.sa.cr/pdf/odov/n37/1659-0775-odov-37-50.pdf

[2] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.

[3] S. Chaudhuri and U. Dayal, "An overview of data warehousing and OLAP technology," *ACM SIGMOD Record*, vol. 26, no. 1, pp. 65–74, 1997, doi: 10.1145/248603.248616.

[4] J. Curto Díaz and J. Conesa Caralt, *Introducción al business intelligence*. Barcelona, España: Editorial UOC, 2010.

[5] J. Hernández Orallo, M. J. Ramírez Quintana, and C. Ferri Ramírez, *Introducción a la minería de datos*. Madrid, España: Pearson Educación, 2004.

[6] M. D. Hernández Ramírez, "Procedimiento para el desarrollo de un sistema de inteligencia de negocios en la gestión de ensayos clínicos en el Centro de Inmunología Molecular," *Revista Cubana de Información en Ciencias de la Salud*, vol. 22, no. 4, pp. 349–361, 2011. [En línea]. Disponible en: https://acimed.sld.cu/index.php/acimed/article/download/208/183/1603

[7] R. S. Kaplan and D. P. Norton, *El cuadro de mando integral*, 2.ª ed. Barcelona, España: Gestión 2000, 2000.

[8] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Hoboken, NJ, USA: Wiley, 2013.

[9] A. J. Meza Rincón, "Factores vinculados al abandono del tratamiento dental en una clínica odontológica docente, Lima 2024," tesis de licenciatura, Universidad Privada Norbert Wiener, Lima, Perú, 2025. [En línea]. Disponible en: https://hdl.handle.net/20.500.13053/13269

[10] E. Prada Madrid, "Los insumos invisibles de decisión: Datos, información y conocimiento," *Anales de Documentación*, vol. 11, pp. 183–196, 2008. [En línea]. Disponible en: https://revistas.um.es/analesdoc/article/view/24881

[11] G. R. Rivadera, “La metodología de Kimball para el diseño de almacenes de datos (Data warehouses),” *Cuadernos de Ingeniería*, no. 5, pp. 56–71, 2010. [En línea]. Disponible en: https://revistas.ucasal.edu.ar/index.php/CI/article/view/169

[12] H. M. Rodríguez Rey, A. León Quintela, and M. L. Duque de Estrada Bertot, “Principales causas relacionadas con el abandono del tratamiento ortodóncico por escolares y adultos jóvenes según tipos de aparatos utilizados,” *MEDISAN*, vol. 21, no. 3, pp. 321–329, 2017. [En línea]. Disponible en: https://medisan.sld.cu/index.php/san/article/download/1334/pdf

[13] C. I. Valenzuela-Núñez, F. H. Troncoso-Espinosa, and G. O. Latorre-Núñez, “Predicción del ausentismo en citas médicas mediante Machine Learning,” *Universidad, Ciencia y Tecnología*, vol. 27, no. 120, pp. 19–30, 2023, doi: 10.47460/uct.v27i120.728.